

İstatistiksel Yazılımlar Ders Notları

*Bir istatistikçi deneyi gerçekleştirdikten sonra çağırmak, ondan otopsi gerçekleştirmesini istemekten fazlası değildir:
Size deneyinizin neden öldüğünü söyleyebilir.*

1938

PROFESOR SIR RONALD AYMLER FISHER

Tolga BERBER
İstatistik ve Bilgisayar
Bilimleri Bölümü
tberber@ktu.edu.tr

İçindekiler

İçindekiler	i
1 İstatistiksel Yazılımlar	1
1.1 Uygulama Amaçlarına Göre İstatistiksel Yazılımlar	1
1.1.1 Veri Madenciliği Yazılımları	1
1.1.1.1 Örnekler	1
1.1.2 Veri Analizi Yazılımları	2
1.1.2.1 Örnekler	2
1.2 Türlerine Göre İstatistiksel Yazılımlar	2
1.2.1 İstatistiksel Eklentiler	2
1.2.1.1 Örnekler	2
1.2.2 Paket Programlar	2
1.2.2.1 Örnekler	2
1.2.3 Programlama Dili Eklentileri	2
1.2.3.1 Örnekler	3
1.2.4 İstatistiksel Programlama Dilleri	3
1.2.4.1 Örnekler	3
1.3 R Programlama Dili	3
1.3.1 Tarihçesi	3
1.4 İlk R Programınız	4
2 R ile Çalışma	5
2.1 R Çalışma Ortamı	5
2.2 R Veri Türleri	5
2.2.1 Atomik Vektörler	5
2.2.2 R Nesneleri	7
2.2.2.1 Vektörler	7
2.2.2.2 Listeler	11
2.2.2.3 Matrisler	14

2.2.2.4	Diziler	16
2.2.2.5	Faktörler	18
2.2.2.6	Veri Çerçevesi	19
2.2.2.7	Uygulama	22
2.2.3	R Değişkenleri	25
2.2.4	R Operatörleri	26
2.2.4.1	Aritmetik İşlemler	27
2.2.4.2	İlişkisel Operatörler	28
2.2.4.3	Mantıksal Operatörler	29
2.2.4.4	Atama Operatörleri	29
2.2.4.5	Diğer Operatörler	30
3	Uygulama: R ile Veri Kümesi İşlemleri	33
4	R ile Tanımlayıcı İstatistikler ve Nominal Değerlerin İncelenmesi	45
4.1	Veri Yükleme	45
4.2	Veri Bölme	45
4.3	Nominal Değerler İçin Tanımlayıcı İstatistikler	50
4.3.1	Tablo Oluşturma	50
4.3.2	Marjinal Değerleri Ekleme	51
4.3.3	Oran Tabloları Oluşturma	52
4.3.4	Çapraz Tablo Oluşturma	53
4.3.5	Çapraz Tablo Kullanarak Bağımsızlık Testleri	55
4.3.5.1	Ki-Kare Testi	55
4.3.5.2	Fisher Exact Testi	56
4.3.5.3	İlişkinin Gücünün Belirlenmesi	56
4.3.5.4	Karar Verme İşeminin Otomatize Edilmesi	57
4.3.5.5	Hazır Paketler Kullanılması	57
4.4	R Grafikleri	59
4.4.1	Pasta Grafikleri	60
4.4.1.1	Temel Pasta Grafiği	60
4.4.1.2	Grafikte Görünecek Değerleri Belirlemek	60
4.4.1.3	3-Boyutlu Pasta Grafiği	61
4.4.1.4	Grafikleri PNG Olarak Kaydetmek	62
4.4.1.5	Verideki Bütün Nominal Değerlerin 3B Pasta Grafiklerinin Oluşturulması	62
5	İstatistiksel Analize Hazırlık	63
5.1	Hipotez Testleri	63
5.2	Hipotez Testinin Aşamaları	63
5.3	Normallik Testleri	64
5.3.1	Kolmogorov-Smirnov Testi	67
5.3.2	Shapiro-Wilk Testi	69
5.3.3	Veri Düzeltmesi	70
5.4	Dağılım Testleri	72

5.4.1	Rastsallık Testi	72
5.4.2	Varyans Homojenliği Testi	73
6	Tek Örnek Testleri	75
6.1	Parametrik Testler	75
6.1.1	Ortalamaların Testi	75
6.1.2	Oranların Testi	77
6.2	Parametrik Olmayan Testler	79
6.2.1	Wilcoxon İşaretli Sıra Sayıları Testi	79
6.2.2	Binom Testi	80
7	İki Örnek Testleri	83
7.1	Parametrik Testler	84
7.1.1	İki Ortalamanın Testi	84
7.1.1.1	İki Bağımsız Ortalamanın Testi	84
7.1.1.2	İki Bağımlı Ortalamanın Testi	89
7.1.2	İki Oranın Testi	90
7.2	Parametrik Olmayan Testler	91
7.2.1	Mann Whitney U Testi	92
7.2.2	Wilcoxon İşaretli Sıra Testi	94
7.2.3	Kolmogorov-Smirnov İki Örnek Testi	96
8	Uygulama: Uyku Anketi Değerlendirmesi	99
9	Çok Örnek Testleri	101
9.1	Tek Yönlü ANOVA Testi	102
9.1.1	Eşit Varyans Varsayımı ile Kullanılacak Post Hoc Testler	104
9.1.1.1	Tukey Testi	104
9.1.1.2	Scheffe Testi	106
9.1.1.3	Aile Çapı Hata Oranı (Family-Wise Error Rate, FWER)	107
9.1.2	Eşit Varyans Varsayımı Sağlanmadığında Kullanılan Post Hoc Testler . . .	110
9.1.2.1	Dunnet C Testi	110
9.1.2.2	Dunnet T3 Testi	111
9.2	Bağımlı Örnekler için Tek Yönlü ANOVA Testi	112
9.3	İki Yönlü ANOVA Testi	113
9.4	Tek Yönlü MANOVA Testi	115
9.5	İki Yönlü MANOVA Testi	121
9.6	Kruskal Wallis Testi	122
9.7	Friedman Testi	124
9.8	Welch ve Brown-Forsythe Testleri	126
10	Uygulama: New York Belediyesi Eğitim Durumu Değerlendirmesi	129
10.1	Uygulama 1: Tanımlayıcı İstatistikler	130
10.2	Uygulama 2: Çapraz Tablolar	130
10.3	Uygulama 3: Tek Örnek Testleri	130

10.4	Uygulama 4: İki Örnek Testleri	131
10.5	Uygulama 5: Çok Örnek Testleri	131
11	Korelasyon ve Regresyon Analizi	133
11.1	Korelasyon	133
11.1.1	Korelasyon Katsayısının Hesaplanması	133
11.1.2	İki Değişken Arasındaki Korelasyonun Test Edilmesi	136
11.2	Regresyon Analizi	143
11.2.1	Basit Doğrusal Regresyon	143
11.2.2	Belirlilik Katsayısı	146
11.2.3	Katsayıların Testi	147
11.2.4	Regresyon Modeli ile Tahmin	147
11.2.5	Gerçek Veri ile Uygulama	148
11.2.6	Doğrusal Olmayan Modeller	149
11.2.6.1	Kareli Model	150
11.2.6.2	Tam Logaritmik Model	154
11.2.6.3	Doğrusal Logaritmik Model	157
11.2.6.4	Logaritmik Doğrusal Model	159
11.2.6.5	Ters Model	161

İstatistiksel Yazılımlar

- Bu güne kadar gördüğünüz yöntemlerin uygulaması için kullanılırlar
- Uygulama amaçlarına göre;
 - Veri Madenciliği Yazılımları
 - Analiz Yazılımları
- Türlerine göre;
 - Mevcut Yazılımların İstatistiksel Eklentileri
 - Paket Programlar
 - Programlama Dili Eklentileri
 - Programlama Dilleri

1.1 Uygulama Amaçlarına Göre İstatistiksel Yazılımlar

1.1.1 Veri Madenciliği Yazılımları

- Büyük miktardaki verilerden bilgi ayıklamak
- Akıllı sistemler oluşturmak
- Kümeleme ve sınıflama gibi makine öğrenmesi yöntemlerini uygulamak
- Metin, görüntü gibi bilgilerden bilgi ayıklayıp anlamlandırmak

1.1.1.1 Örnekler

- SPSS Modeler
- R
- S
- RapidMiner
- Weka
- SQL Server Analysis Services
- Oracle Data Mining

1.1.2 Veri Analizi Yazılımları

- Anket sonuçları değerlendirmek
- Hipotez testleri gerçekleştirmek
- Tanımlayıcı istatistikler ve grafikler oluşturmak

1.1.2.1 Örnekler

- SPSS
- R
- SAS
- Excel
- Libre Office Calc
- MiniTab
- STATA

Bu ders kapsamında çoğunlukla Veri Analizi yazılımlarından bahsedilecektir.

1.2 Türlerine Göre İstatistiksel Yazılımlar

1.2.1 İstatistiksel Eklentiler

- Genellikle elektronik tablolaştırma programlarında bulunurlar
- Formüller veya fonksiyonlar yardımıyla bazı istatistiksel işlemlerin yapılmasını sağlarlar

1.2.1.1 Örnekler

- Microsoft Excel
- Libre Office Calc

1.2.2 Paket Programlar

- Tamamıyla istatistiksel analizler gerçekleştirmek amacıyla geliştirilmişlerdir
- Kullanımları eklentilere göre daha kolaydır (?)

1.2.2.1 Örnekler

- SPSS
- SAS
- MiniTAB

1.2.3 Programlama Dili Eklentileri

- Mevcut yazılım geliştirme dillerine ek fonksiyon kütüphanesi olarak gelirler

1.2.3.1 Örnekler

- Matlab: Statistics ToolBox
- C++: Boost İstatistik Kütüphanesi
- C#: IMSL .NET
- GNU Octave: Statistics ToolBox
- Java: IMSL .NET

1.2.4 İstatistiksel Programlama Dilleri

- Tamamıyla istatistiksel analiz ve veri madenciliği yapmak amacıyla geliştirilmişlerdir

1.2.4.1 Örnekler

- GNU R
- S

1.3 R Programlama Dili

- Açık Kaynak
- Ücretsiz
- Platform Bağımsız
- Güncel İleri İstatistiksel Yöntemleri İçerir
- Güçlü Grafik Kabiliyetleri Vardır
- Yeni İstatistiksel Yöntemler Geliştirilmesine Olanak Sunar
- Bir İnteraktif Programlama Dili'dir

1.3.1 Tarihçesi

- Bell Laboratuvarlarında Geliştirilmeye Başlandı
 - İlk dilin adı S'tir
 - 1988 - S2: RA Becker, JM Chambers, A Wilks
 - 1992 - S3: JM Chambers, TJ Hastie
 - 1998 - S4: JM Chambers
- İlk R sürümü, S dilinden esinlenerek 1990 yılında geliştirildi
 - Ross Ishaka, Robert Gentleman
- 1997'den itibaren 15 Çekirdek R geliştiricisi yazılımı geliştirmektedir.
- R'ı kullanabilmek için önce R yorumlayıcısı kurmanız gerekiyor, bunun için
 - 32/64 bit işletim sistemleri:
 - * <https://cran.r-project.org/bin/windows/base/>

* Burada hem işletim sisteminize uygun R yorumlayıcısı hem de RTools paketini indirin.

- R'ın görsel olarak kullanabilmek için de Rstudio yazılımını kullanacağız

– <https://download1.rstudio.org/RStudio-1.0.136.exe>

Yazılımlarını indirip kurun

1.4 İlk R Programınız

R Studio'yu açın ve aşağıdaki komutları girin. Her komuttan sonra Enter tuşuna basınız.

```
a <- "Merhaba Dünya"  
print(a)
```

```
## [1] "Merhaba Dünya"
```

R Studio'dan çıkmak için iki yolunuz var.

1- Pencereyi kapatabilirsiniz. 2- Konsoldan **q()** komutunu girebilirsiniz.

R ile Çalışma

2.1 R Çalışma Ortamı

- R ile yaptığınız çalışmaların kaydedildiği klasördür
 - setwd() fonksiyonu ile değiştirilir
 - getwd() fonksiyonu ile öğrenilir
- Önerceğim yol;
 - Çalışmaya başlamadan önce bir klasör oluşturun
 - Çalışma ortamınızı ayarlayın
 - Analizinizi Gerçekleştirin

2.2 R Veri Türleri

- Her programlama dili veri tutmaya ihtiyaç duyar
- R istatistiksel olarak kullanılabilecek veri türleri tanımlar
- C/C++ aksine R da değişken tanımlarken tür belirtmek zorunda değilsiniz
- R Programlama dilinde temelde iki farklı veri türü yer alır
 - Atomik Vektörler
 - R Nesneleri

2.2.1 Atomik Vektörler

- Sadece bir değer saklayabilen veri türleridir
 - Vektörlerin Altı Sınıfı olarak ta adlandırılırlar
- Altı adet atomik vektör türü vardır
 - Logical (Mantıksal)

- Numeric (Sayısal)
- Integer (Tamsayı)
- Complex (Karmaşık Sayı)
- Character (Metin)
- Raw (Ham)

```
v <- TRUE  
print(class(v))
```

```
## [1] "logical"
```

```
v <- 23.5  
print(class(v))
```

```
## [1] "numeric"
```

```
v <- 2L  
print(class(v))
```

```
## [1] "integer"
```

```
v <- 2+5i  
print(class(v))
```

```
## [1] "complex"
```

```
v <- "TRUE"  
print(class(v))
```

```
## [1] "character"
```

```
v <- charToRaw("Merhaba")  
print(class(v))
```

```
## [1] "raw"
```

```
print(v)
```

```
## [1] 4d 65 72 68 61 62 61
```

2.2.2 R Nesneleri

- R programlama dilinde bir çok nesne bulunmaktadır
- En sık kullanılanları
 - Vektörler
 - Listeler
 - Matrisler
 - Diziler
 - Faktörler
 - Veri Çerçevesi (Data Frames)

2.2.2.1 Vektörler

- R programlama dilindeki en temel nesnedir
- Tek türde veri saklarlar
 - Atomik Türler
 - R Nesneleri
- Birden çok değer saklayabilirler
- c() fonksiyonu ile oluşturulurlar
- Bir yada birden fazla elemana sahip olabilirler

```
v <- 5
```

```
print(v)
```

```
## [1] 5
```

```
v <- c(1,2,3)
```

```
print(v)
```

```
## [1] 1 2 3
```

- Bir seri içerebilirler

```
v <- 6.6:12.6
```

```
print(v)
```

```
## [1] 6.6 7.6 8.6 9.6 10.6 11.6 12.6
```

```
v <- 3.8:11.4
```

```
print(v)
```

```
## [1] 3.8 4.8 5.8 6.8 7.8 8.8 9.8 10.8
```

```
v <- seq(10.5, 2.7, by=-0.2)
```

```
print(v)
```

```
## [1] 10.5 10.3 10.1 9.9 9.7 9.5 9.3 9.1 8.9 8.7 8.5 8.3 8.1 7.9
## [15] 7.7 7.5 7.3 7.1 6.9 6.7 6.5 6.3 6.1 5.9 5.7 5.5 5.3 5.1
## [29] 4.9 4.7 4.5 4.3 4.1 3.9 3.7 3.5 3.3 3.1 2.9 2.7
```

- Vektör elemanlarına aşağıdaki gibi erişilebilir

```
t <- c("Pzt", "Sal", "Çar", "Per", "Cum", "Cmt", "Paz")
```

```
# 2. 3. ve 6. elemanları al
```

```
u <- t[c(2,3,6)]
```

```
print(u)
```

```
## [1] "Sal" "Çar" "Cmt"
```

```
# Değeri True olan elemanları al
```

```
v <- t[c(TRUE,FALSE,FALSE,FALSE,FALSE,TRUE,FALSE)]
```

```
print(v)
```

```
## [1] "Pzt" "Cmt"
```

```
# 2. ve 5. elemanları çıkart
```

```
x <- t[c(-2,-5)]
```

```
print(x)
```

```
## [1] "Pzt" "Çar" "Per" "Cmt" "Paz"
```

- Vektör elemanları aşağıdaki şekilde değiştirilir

```
t[1] <- "Pazartesi"
```

```
print(t)
```

```
## [1] "Pazartesi" "Sal"      "Çar"      "Per"      "Cum"      "Cmt"
## [7] "Paz"
```

```
t[c(2,3,5)] <- c("Salı", "Çarşamba", "Cuma")
```

```
print(t)
```

```
## [1] "Pazartesi" "Salı"      "Çarşamba" "Per"      "Cuma"      "Cmt"
## [7] "Paz"
```

```
t[c(FALSE, FALSE, FALSE, TRUE, FALSE, TRUE, TRUE)] =  
  c("Perşembe", "Cumartesi", "Pazar")
```

```
print(t)
```

```
## [1] "Pazartesi" "Salı"      "Çarşamba" "Perşembe" "Cuma"      "Cumartesi"
## [7] "Pazar"
```

- Vektör Aritmetiği

```
v1 <- c(3,8,4,5,0,11)
```

```
v2 <- c(4,11,0,8,1,2)
```

```
ekle.sonuc <- v1+v2
```

```
print(ekle.sonuc)
```

```
## [1]  7 19  4 13  1 13
```

```
fark.sonuc <- v1-v2
```

```
print(fark.sonuc)
```

```
## [1] -1 -3  4 -3 -1  9
```

```
carp.sonuc <- v1*v2
```

```
print(carp.sonuc)
```

```
## [1] 12 88  0 40  0 22
```

```
bol.sonuc <- v1/v2  
print(bol.sonuc)
```

```
## [1] 0.7500000 0.7272727      Inf 0.6250000 0.0000000 5.5000000
```

- R Vektörleri Aritmetik işlemlere girerken, eğer bir vektörün eleman sayısı ötekine eşit değilse, R eşitsizliği eleman tekrar ederek tamamlar.

```
v2 <- c(4,11)  
  
ekle.sonuc <- v1+v2  
print(ekle.sonuc)
```

```
## [1]  7 19  8 16  4 22
```

```
fark.sonuc <- v1-v2  
print(fark.sonuc)
```

```
## [1] -1 -3  0 -6 -4  0
```

```
carp.sonuc <- v1*v2  
print(carp.sonuc)
```

```
## [1] 12 88 16 55  0 121
```

```
bol.sonuc <- v1/v2  
print(bol.sonuc)
```

```
## [1] 0.7500000 0.7272727 1.0000000 0.4545455 0.0000000 1.0000000
```

- Elemanların sıralanması

```
v <- c(3,8,4,5,0,11, -9, 304)  
  
sirala.sonuc <- sort(v)  
  
print(sirala.sonuc)
```

```
## [1] -9  0  3  4  5  8 11 304
```



```
azalan.sirala.sonuc <- sort(v, decreasing = TRUE)

print(azalan.sirala.sonuc)
```

```
## [1] 304 11 8 5 4 3 0 -9
```

```
t <- c("Pzt", "Sal", "Çar", "Per", "Cum", "Cmt", "Paz")

sirala.sonuc <- sort(t)

print(sirala.sonuc)
```

```
## [1] "Cmt" "Cum" "Çar" "Paz" "Per" "Pzt" "Sal"
```

```
azalan.sirala.sonuc <- sort(t, decreasing = TRUE)

print(azalan.sirala.sonuc)
```

```
## [1] "Sal" "Pzt" "Per" "Paz" "Çar" "Cum" "Cmt"
```

2.2.2.2 Listeler

- Vektörler gibi birden çok değer saklayabilirler
- Değerler aynı türde olmak zorunda değildir
- *list()* komutu ile oluşturulurlar
- Sakladıkları her eleman isimlendirilebilir

```
list_data <- list(c("Oca", "Şub", "Mar"),
                 matrix(c(3,9,5,1,-2,8), nrow=2),
                 list("green", 12.3))

names(list_data) <- c("İlk Çeyrek", "Bir Matris", "Bir İç Liste")

print(list_data)
```

```
## $`İlk Çeyrek`
## [1] "Oca" "Şub" "Mar"
##
## $`Bir Matris`
##      [,1] [,2] [,3]
## [1,]    3    5  -2
## [2,]    9    1    8
##
## $`Bir İç Liste`
```

```
## $`Bir İç Liste`[[1]]
## [1] "green"
##
## $`Bir İç Liste`[[2]]
## [1] 12.3
```

- Liste Elemanlarına Erişim Yöntemleri

```
print(list_data[1])
```

```
## $`İlk Çeyrek`
## [1] "Oca" "Şub" "Mar"
```

```
print(list_data$`Bir Matris`)
```

```
##      [,1] [,2] [,3]
## [1,]    3    5  -2
## [2,]    9    1    8
```

- Eleman değerlerinin değiştirilmesi

```
list_data[4] <- "Yeni Eleman"
print(list_data[4])
```

```
## [[1]]
## [1] "Yeni Eleman"
```

```
list_data[4] <- NULL
print(list_data[4])
```

```
## $<NA>
## NULL
```

```
list_data[3] <- "Artık Bir Metin"
print(list_data[3])
```

```
## $`Bir İç Liste`
## [1] "Artık Bir Metin"
```

- Listelerin birleştirilmesi

```
list1 <- list(1,2,3)
list2 <- list("Pzt","Sal","Çar")

bir.liste <- c(list1, list2)

print(bir.liste)
```

```
## [[1]]
## [1] 1
##
## [[2]]
## [1] 2
##
## [[3]]
## [1] 3
##
## [[4]]
## [1] "Pzt"
##
## [[5]]
## [1] "Sal"
##
## [[6]]
## [1] "Çar"
```

- Listeleri vektöre dönüştürme

```
list1 <- list(1:5)
print(list1)
```

```
## [[1]]
## [1] 1 2 3 4 5
```

```
list2 <-list(10:14)
print(list2)
```

```
## [[1]]
## [1] 10 11 12 13 14
```

```
v1 <- unlist(list1)
v2 <- unlist(list2)
print(v1)
```

```
## [1] 1 2 3 4 5
```

```
print(v2)
```

```
## [1] 10 11 12 13 14
```

2.2.2.3 Matrisler

- Matris iki boyutlu dikdörtgensel veri kümeleridir
- Aynı türde veri saklarlar
- Bir vektörün satır ve sütunlara ayrılması ile oluşturulabilirler
- *matrix()* fonksiyonu ile oluşturulurlar
- Matrisler dikdörtgensel veri saklamaya yarar

```
M <- matrix(c(3:14), nrow=4, byrow=TRUE)
print(M)
```

```
##      [,1] [,2] [,3]
## [1,]    3    4    5
## [2,]    6    7    8
## [3,]    9   10   11
## [4,]   12   13   14
```

```
N <- matrix(c(3:14), nrow=4, byrow=FALSE)
print(N)
```

```
##      [,1] [,2] [,3]
## [1,]    3    7   11
## [2,]    4    8   12
## [3,]    5    9   13
## [4,]    6   10   14
```

- Satır ve sütunlarına isim verilebilir

```
isim.satır = c("sat1", "sat2", "sat3", "sat4")
isim.sütun = c("süt1", "süt2", "süt3")

P <- matrix(c(3:14), nrow=4, byrow=TRUE,
             dimnames=list(isim.satır, isim.sütun))

print(P)
```

```
##      süt1 süt2 süt3
## sat1    3    4    5
## sat2    6    7    8
## sat3    9   10   11
## sat4   12   13   14
```

- Matrislere Erişim

```
print(P[1,3])
```

```
## [1] 5
```

```
P[1,3] = 255
print(P[1,3])
```

```
## [1] 255
```

```
print(P[2,])
```

```
## süt1 süt2 süt3
##    6    7    8
```

```
P[2,] = c(1,2,3)
print(P[2,])
```

```
## süt1 süt2 süt3
##    1    2    3
```

```
print(P[,2])
```

```
## sat1 sat2 sat3 sat4
##    4    2   10   13
```

```
P[,2] = c(1,2,3,4)
print(P[,2])
```

```
## sat1 sat2 sat3 sat4
##    1    2    3    4
```



```
## , , Matris1
##
##      SAT1 SAT2 SAT3
## SÜT1    5   10   13
## SÜT2    9   11   14
## SÜT3    3   12   15
##
## , , Matris2
##
##      SAT1 SAT2 SAT3
## SÜT1    5   10   13
## SÜT2    9   11   14
## SÜT3    3   12   15
```

- Fonksiyonlar dizilerin istenilen boyutuna uygulanabilir

```
vector1 <- c(5,9,3)
vector2 <- c(10,11,12,13,14,15)

yeni.dizi <- array(c(vector1,vector2),dim=c(3,4,2))

print(yeni.dizi)
```

```
## , , 1
##
##      [,1] [,2] [,3] [,4]
## [1,]    5   10   13    5
## [2,]    9   11   14    9
## [3,]    3   12   15    3
##
## , , 2
##
##      [,1] [,2] [,3] [,4]
## [1,]   10   13    5   10
## [2,]   11   14    9   11
## [3,]   12   15    3   12
```

```
# Bütün Satırların Toplamının Hesaplanması
result <- apply(yeni.dizi, c(1), sum)
print(result)
```

```
## [1] 71 88 75
```

```
# Bütün Sütunların Toplamının Hesaplanması
result <- apply(yeni.dizi, c(2), sum)
print(result)
```

```
## [1] 50 75 59 50
```

```
# Bütün Matrislerin Toplamının Hesaplanması
result <- apply(yeni.dizi, c(3), sum)
print(result)
```

```
## [1] 109 125
```

2.2.2.5 Faktörler

- Bir vektör kullanılarak oluşturulurlar
- Bir vektördeki;
 - Tekrar etmeyen elemanları etiket olarak,
 - Vektörün elemanlarını tamsayı olarak saklarlar
- *factor()* fonksiyonu ile oluşturulurlar
- *nlevels()* fonksiyonu ile tekrar etmeyen elemanların sayısı elde edilebilir
- *levels()* fonksiyonu ile tekrar etmeyen elemanlar elde edilebilir
- Nominal Veri Saklarlar
- Bir veri çerçevesine koyduğunuz metinler faktöre çevirilir.

```
boy <- c(132,151,162,139,166,147,122)
kilo <- c(48,49,66,53,67,52,40)
cinsiyet <- c("erkek","erkek","kadın","kadın","erkek","kadın","erkek")

giriş.verisi <- data.frame(boy,kilo,cinsiyet)
print(giriş.verisi)
```

```
##   boy kilo cinsiyet
## 1 132  48   erkek
## 2 151  49   erkek
## 3 162  66   kadın
## 4 139  53   kadın
## 5 166  67   erkek
## 6 147  52   kadın
## 7 122  40   erkek
```

```
print(is.factor(giriş.verisi$cinsiyet))
```

```
## [1] TRUE
```



```
print(giriş.verisi$scinsiyet)
```

```
## [1] erkek erkek kadın kadın erkek kadın erkek
## Levels: erkek kadın
```

- Faktörlerin sırası faktör fonksiyonu ile değiştirilebilir

```
veri <- c("Doğu","Batı","Doğu","Kuzey","Kuzey",
          "Doğu","Batı","Batı","Batı","Doğu","Kuzey")
```

```
factor_veri <- factor(veri)
print(factor_veri)
```

```
## [1] Doğu Batı Doğu Kuzey Kuzey Doğu Batı Batı Batı Doğu Kuzey
## Levels: Batı Doğu Kuzey
```

```
yeni.faktör.veri <- factor(factor_veri,
                           levels = c("Kuzey","Doğu","Batı"))
print(yeni.faktör.veri)
```

```
## [1] Doğu Batı Doğu Kuzey Kuzey Doğu Batı Batı Batı Doğu Kuzey
## Levels: Kuzey Doğu Batı
```

- Yeni faktörler *gl()* fonksiyonu ile üretilebilir.

```
v <- gl(3, 4, labels = c("Kırmızı", "Beyaz","Yeşil"))
print(v)
```

```
## [1] Kırmızı Kırmızı Kırmızı Kırmızı Beyaz Beyaz Beyaz Beyaz
## [9] Yeşil Yeşil Yeşil Yeşil
## Levels: Kırmızı Beyaz Yeşil
```

2.2.2.6 Veri Çerçevesi

- Tablo şeklindeki veri nesneleridir
- Matrislere benzerler
 - Fakat sütunlar farklı türlerde olabilir
 - Örneğin;
 - * İlk Sütun Karakter
 - * İkinci Sütun Sayısal
 - Olabilir
- *data.frame()* fonksiyonu ile oluşturulurlar

- Bir çerçeveden istediğiniz sütunları ve satırları çıkarabilirsiniz

```
yeni <- data.frame(personel.verisi$personel.adi,
                    personel.verisi$personel.ucreti)
print(yeni)
```

```
##  personel.verisi.personel.adi personel.verisi.personel.ucreti
## 1                               Tolga                623.30
## 2                               Mustafa               515.20
## 3                               Uğur                 611.00
## 4                               Erdiñç               729.00
## 5                               Yavuz                 843.25
```

```
yeni <- personel.verisi[1:2,]
print(yeni)
```

```
##  personel.no personel.adi personel.ucreti personel.baslama_tarihi
## 1           1      Tolga          623.3      2012-01-01
## 2           2    Mustafa          515.2      2013-09-23
```

```
yeni <- personel.verisi[c(3,5),c(2,4)]
print(yeni)
```

```
##  personel.adi personel.baslama_tarihi
## 3      Uğur      2014-11-15
## 5    Yavuz      2015-03-27
```

- Veri çerçevelerine yeni sütunlar ekleyebilirsiniz

```
personel.verisi$bölüm <- c("BT","Satış","BT","İK","Finans")
print(personel.verisi)
```

```
##  personel.no personel.adi personel.ucreti personel.baslama_tarihi bölüm
## 1           1      Tolga          623.30      2012-01-01      BT
## 2           2    Mustafa          515.20      2013-09-23    Satış
## 3           3      Uğur          611.00      2014-11-15      BT
## 4           4    Erdiñç          729.00      2014-05-11      İK
## 5           5    Yavuz          843.25      2015-03-27    Finans
```

- Veri Çerçevelerine yeni satırlar ekleyebilirsiniz

```

yeni.personel <- data.frame(
  personel.no = c (6:8),
  personel.adi = c("Mehmet Ali","Buğra","Ali Hikmet"),
  personel.ucreti = c(623.3,515.2,611.0),
  personel.baslama_tarihi = as.Date(c("2012-01-01","2013-09-23",
                                     "2014-11-15")),
  bölüm = c("IT","Satış","Finans"),
  stringsAsFactors=FALSE
)

personel.birlestirilmis <- rbind(personel.verisi, yeni.personel)

print(personel.birlestirilmis)

```

```

##  personel.no personel.adi personel.ucreti personel.baslama_tarihi  bölüm
## 1           1      Tolga       623.30      2012-01-01      BT
## 2           2    Mustafa       515.20      2013-09-23    Satış
## 3           3      Uğur       611.00      2014-11-15      BT
## 4           4    Erдің       729.00      2014-05-11      İK
## 5           5     Yavuz       843.25      2015-03-27    Finans
## 6           6 Mehmet Ali       623.30      2012-01-01      IT
## 7           7     Buğra       515.20      2013-09-23    Satış
## 8           8  Ali Hikmet       611.00      2014-11-15    Finans

```

2.2.2.7 Uygulama

```

# Vektör Oluştur
elma <- c('Kırmızı', 'Yeşil', "Mavi")
print(elma)

```

```
## [1] "Kırmızı" "Yeşil"  "Mavi"
```

```

# Vektörün Elemanlarının Türü
print(class(elma))

```

```
## [1] "character"
```

```

# Liste oluştur
liste1 <- list(c(2,5,3), 21.3, sin)

# Liste yazdır
print(liste1)

```

```
## [[1]]
## [1] 2 5 3
##
## [[2]]
## [1] 21.3
##
## [[3]]
## function (x) .Primitive("sin")
```

```
# Matris oluştur Satırlara göre
M <- matrix(c('a','a','b','c','b',"a"), nrow = 2, ncol = 3, byrow = TRUE)

print(M)
```

```
##      [,1] [,2] [,3]
## [1,] "a"  "a"  "b"
## [2,] "c"  "b"  "a"
```

```
# Matris oluştur Sütunlara göre
M <- matrix(c('a','a','b','c','b',"a"), nrow = 2, ncol = 3)

print(M)
```

```
##      [,1] [,2] [,3]
## [1,] "a"  "b"  "b"
## [2,] "a"  "c"  "a"
```

```
# Dizi oluştur
a <- array(c('yeşil', 'sarı'), dim = c(3,3,2))

print(a)
```

```
## , , 1
##
##      [,1] [,2] [,3]
## [1,] "yeşil" "sarı" "yeşil"
## [2,] "sarı"  "yeşil" "sarı"
## [3,] "yeşil" "sarı" "yeşil"
##
## , , 2
##
##      [,1] [,2] [,3]
## [1,] "sarı" "yeşil" "sarı"
## [2,] "yeşil" "sarı" "yeşil"
## [3,] "sarı" "yeşil" "sarı"
```

```
# Bir vektör oluştur
```

```
elma_renkleri <- c('yeşil','yeşil','sarı','kırmızı','kırmızı','kırmızı', 'yeşil')
```

```
# Faktör nesnesi oluştur
```

```
elma_faktorleri <- factor(elma_renkleri)
```

```
print(elma_faktorleri)
```

```
## [1] yeşil yeşil sarı kırmızı kırmızı kırmızı yeşil
```

```
## Levels: kırmızı sarı yeşil
```

```
print(nlevels(elma_faktorleri))
```

```
## [1] 3
```

```
print(levels(elma_faktorleri))
```

```
## [1] "kırmızı" "sarı" "yeşil"
```

```
# Veri Çerçevesi oluştur
```

```
bmi <- data.frame(
  cinsiyet <- c("Erkek","Erkek","Kadın"),
  boy <- c(152, 171.5, 165),
  kilo <- c(81, 93, 78),
  yaş <- c(42, 38, 28)
)
```

```
print(bmi)
```

```
## cinsiyet....c..Erkek....Erkek....Kadın.. boy....c.152..171.5..165.
```

```
## 1 Erkek 152.0
```

```
## 2 Erkek 171.5
```

```
## 3 Kadın 165.0
```

```
## kilo....c.81..93..78. yaş....c.42..38..28.
```

```
## 1 81 42
```

```
## 2 93 38
```

```
## 3 78 28
```

2.2.3 R Değişkenleri

- R programlama dili, sizin kullanmanız için isimlendirilmiş bir depolama mekanizması sunar
- Bu depolama mekanizmasında her bir eleman bir değişken olarak adlandırılır
- Değişkenlerin isimleri
 - Harfler, Sayılar, Nokta ve Alt Çizgiden Oluşabilir
 - Sayı ve alt çizgi ile başlayamazlar
 - Noktadan sonra sayı gelemmez
- Bir değişkenin içeriği `print()` veya `cat()` fonksiyonu ile yazdırılabilir.
- `cat()` fonksiyonu birden fazla değişkeni ekrana yazdırabilir.

```
# Eşittir ile atama
```

```
var.1 = c(0,1,2,3)
```

```
# Sol operatörü ile atama
```

```
var.2 <- c("program","R")
```

```
# Sağ operatörü ile atama
```

```
c(TRUE,1) -> var.3
```

```
print(var.1)
```

```
## [1] 0 1 2 3
```

```
cat ("var.1 değeri, ", var.1 ," dir.\n")
```

```
## var.1 değeri, 0 1 2 3 dir.
```

```
cat ("var.2 değeri, ", var.2 ," dir.\n")
```

```
## var.2 değeri, program R dir.
```

```
cat ("var.3 değeri, ", var.3 ," dir.\n")
```

```
## var.3 değeri, 1 1 dir.
```

- Değişkenlerin türleri yoktur
- En son atanan değer değişken türünü belirler
- Değişken türü `class()` fonksiyonu ile öğrenilebilir

```
var_x <- "Merhaba"
cat("var_x'in türü ",class(var_x)," dir\n")
```

```
## var_x'in türü character dir
```

```
var_x <- 34.5
cat("var_x'in türü şimdi ",class(var_x)," dir\n")
```

```
## var_x'in türü şimdi numeric dir
```

```
var_x <- 27L
cat("var_x'in türü şimdi ",class(var_x)," oldu\n")
```

```
## var_x'in türü şimdi integer oldu
```

- Çalışma ortamınızdaki tüm değişkenleri öğrenmek için *ls()* fonksiyonu kullanılır

```
ls()
```

```
## [1] "a"           "bmi"         "boy"
## [4] "cinsiyet"    "elma"        "elma_faktorleri"
## [7] "elma_renkleri" "kilo"        "liste1"
## [10] "M"          "v"           "var.1"
## [13] "var.2"      "var.3"       "var_x"
## [16] "yaş"
```

- Çalışma ortamınızdaki değişkenleri silmek için *rm()* fonksiyonu kullanılır

```
rm(var_x)
```

2.2.4 R Operatörleri

- R programlama dilinde 5 farklı operatör grubu bulunmaktadır
 - Aritmetik Operatörler
 - İlişkisel Operatörler
 - Mantıksal Operatörler
 - Atama Operatörleri
 - Diğer Operatörler (Miscellaneous, Kategorize edilemeyen ?)
- Operatörler aksi belirtilmediği sürece eleman bazlı işlem yaparlar.

2.2.4.1 Aritmetik İşlemler

- Aritmetik işlemleri gerçekleştirmek için kullanılırlar

- +, -, *, /
- %% Mod alma operatörü
- %/% Bölüm bulma operatörü
- ^ Üs alma operatörü

```
v <- c( 2, 5.5, 6)
t <- c( 8, 3, 4)
```

```
cat("v=", v, "\n")
```

```
## v= 2 5.5 6
```

```
cat("t=", t, "\n")
```

```
## t= 8 3 4
```

```
cat("v+t=", v+t, "\n")
```

```
## v+t= 10 8.5 10
```

```
cat("v-t=", v-t, "\n")
```

```
## v-t= -6 2.5 2
```

```
cat("v*t=", v*t, "\n")
```

```
## v*t= 16 16.5 24
```

```
cat("v/t=", v/t, "\n")
```

```
## v/t= 0.25 1.833333 1.5
```

```
cat("v%%t=", v%%t, "\n")
```

```
## v%%t= 2 2.5 2
```

```
cat("v%%/t=", v%%/t, "\n")
```

```
## v%%/t= 0 1 1
```

```
cat("v^t=", v^t, "\n")
```

```
## v^t= 256 166.375 1296
```

2.2.4.2 İlişkisel Operatörler

- İki değişkenin arasındaki ilişkiyi belirlemek için kullanırlar

```
v <- c(2, 5.5, 6, 9)
```

```
t <- c(8, 2.5, 14, 9)
```

```
cat("v=", v, "\n")
```

```
## v= 2 5.5 6 9
```

```
cat("t=", t, "\n")
```

```
## t= 8 2.5 14 9
```

```
cat("v>t =", v>t, "\n")
```

```
## v>t = FALSE TRUE FALSE FALSE
```

```
cat("v<t =", v<t, "\n")
```

```
## v<t = TRUE FALSE TRUE FALSE
```

```
cat("v==t =", v==t, "\n")
```

```
## v==t = FALSE FALSE FALSE TRUE
```

```
cat("v<=t =", v<=t, "\n")
```

```
## v<=t = TRUE FALSE TRUE TRUE
```

```
cat("v>=t =", v>=t, "\n")
```

```
## v>=t = FALSE TRUE FALSE TRUE
```

```
cat("v!=t =", v!=t, "\n")
```

```
## v!=t = TRUE TRUE TRUE FALSE
```

2.2.4.3 Mantıksal Operatörler

- Sadece Mantıksal (TRUE/FALSE) değişkenlere uygulanabilir
- R programlama dilinde, 0 ve dengi değerler FALSE, diğer değerler TRUE kabul edilir

```
v <- c(3,0,TRUE,2+3i)
t <- c(4,0,FALSE,2+3i)
```

```
cat("v=",v,"\n")
```

```
## v= 3+0i 0+0i 1+0i 2+3i
```

```
cat("t=",t,"\n")
```

```
## t= 4+0i 0+0i 0+0i 2+3i
```

```
# Eleman Bazlı Karşılaştırma
```

```
cat("v&t = ",v&t,"\n")
```

```
## v&t = TRUE FALSE FALSE TRUE
```

```
cat("v|t = ",v|t,"\n")
```

```
## v|t = TRUE FALSE TRUE TRUE
```

```
cat("!v = ",!v,"\n")
```

```
## !v = FALSE TRUE FALSE FALSE
```

```
# Sadece ilk elemanı karşılaştırma
```

```
cat("v&& t =", v&&t, "\n")
```

```
## v&&t = TRUE
```

```
cat("v||t =", v||t, "\n")
```

```
## v||t = TRUE
```

2.2.4.4 Atama Operatörleri

```
v1 <- c(3,1,TRUE,2+3i)
v2 <- c(3,1,TRUE,2+3i)
v3 = c(3,1,TRUE,2+3i)
```

```
cat("v1 = ",v1,"\n")
```

```
## v1 = 3+0i 1+0i 1+0i 2+3i
```

```
cat("v2 = ",v2,"\n")
```

```
## v2 = 3+0i 1+0i 1+0i 2+3i
```

```
cat("v3 = ",v3,"\n")
```

```
## v3 = 3+0i 1+0i 1+0i 2+3i
```

```
c(3,1,TRUE,2+3i) -> v1
c(3,1,TRUE,2+3i) ->> v2
```

```
cat("v1 = ",v1,"\n")
```

```
## v1 = 3+0i 1+0i 1+0i 2+3i
```

```
cat("v2 = ",v2,"\n")
```

```
## v2 = 3+0i 1+0i 1+0i 2+3i
```

2.2.4.5 Diğer Operatörler

- **:** Operatörü
 - Sıra sayıları üretmek için kullanılır, seq() fonksiyonunun kısaltılmış halidir.
- **%in%** Operatörü
 - Bir elemanın vektörde olup olmadığını belirlemek için kullanılır
- **%*%** Operatörü
 - Matris çarpma için kullanılır

```
v <- 2:8
cat("v = ",v,"\n")
```

```
## v = 2 3 4 5 6 7 8
```

```
v1 <- 8
v2 <- 12
t <- 1:10
cat(v1, " vektörde var mı ? ", v1 %in% t, "\n")
```

```
## 8 vektörde var mı ? TRUE
```

```
cat(v2, " vektörde var mı ? ", v2 %in% t, "\n")
```

```
## 12 vektörde var mı ? FALSE
```

```
M = matrix( c(2,6,5,1,10,4), nrow=2,ncol=3,byrow = TRUE)
N = matrix( c(1,2,3,4,5,6), nrow=3,ncol=2,byrow = TRUE)
t = M %*% N
print("Matris Çarpımı:")
```

```
## [1] "Matris Çarpımı:"
```

```
print(t)
```

```
##      [,1] [,2]
## [1,]  45  58
## [2,]  51  66
```


Uygulama: R ile Veri Kümesi İşlemleri

Aşağıdaki komutları çalıştırınız.

```
# Verinin Yüklenmesi
veri <- read.csv2("imports-85.csv")

str(veri)
```

```
## 'data.frame':    159 obs. of  26 variables:
## $ SiraNo          : int  1 2 3 4 5 6 7 8 9 10 ...
## $ RiskDerecesi    : int  2 2 1 1 2 0 0 0 2 1 ...
## $ KayipDegeri     : int  164 164 158 158 192 192 188 188 121 98 ...
## $ Uretici         : Factor w/ 18 levels "audi","bmw","chevrolet",...: 1 1 1 1 2 2 2 2 ...
## $ YakıtTuru       : Factor w/ 2 levels "diesel","gas": 2 2 2 2 2 2 2 2 2 2 ...
## $ Enjeksiyon      : Factor w/ 2 levels "std","turbo": 1 1 1 2 1 1 1 1 1 1 ...
## $ KapiSayisi      : Factor w/ 2 levels "four","two": 1 1 1 1 2 1 2 1 2 2 ...
## $ GovdeTuru       : Factor w/ 5 levels "convertible",...: 4 4 4 4 4 4 4 4 3 3 ...
## $ Cekis           : Factor w/ 3 levels "4wd","fwd","rwd": 2 1 2 2 3 3 3 3 2 2 ...
## $ DingilAcikligi  : num  99.8 99.4 105.8 105.8 101.2 ...
## $ Uzunluk         : num  177 177 193 193 177 ...
## $ Genislik        : num  66.2 66.4 71.4 71.4 64.8 64.8 64.8 64.8 60.3 63.6 ...
## $ Yukseklik       : num  54.3 54.3 55.7 55.9 54.3 54.3 54.3 54.3 53.2 52 ...
## $ AzamiAgirlik    : int  2337 2824 2844 3086 2395 2395 2710 2765 1488 1874 ...
## $ MotorTuru       : Factor w/ 5 levels "dohc","l","ohc",...: 3 3 3 3 3 3 3 3 2 3 ...
## $ SilindirSayisi  : Factor w/ 5 levels "eight","five",...: 3 2 2 2 3 3 4 4 5 3 ...
## $ MotorHacmi      : int  109 136 136 131 108 108 164 164 61 90 ...
## $ YakıtSistemi    : Factor w/ 6 levels "1bbl","2bbl",...: 5 5 5 5 5 5 5 5 2 2 ...
## $ SilindirCapi    : num  3.19 3.19 3.19 3.13 3.5 3.5 3.31 3.31 2.91 3.03 ...
## $ Zamanlama       : num  3.4 3.4 3.4 3.4 2.8 2.8 3.19 3.19 3.03 3.11 ...
## $ SikistirmaOrani : num  10 8 8.5 8.3 8.8 8.8 9 9 9.5 9.6 ...
```

```
## $ BeygirGucu      : int  102 115 110 140 101 101 121 121 48 70 ...
## $ MaximumDevir    : int  5500 5500 5500 5500 5800 5800 4250 4250 5100 5400 ...
## $ SehirIciHarcama : int   24 18 19 17 23 23 21 21 47 38 ...
## $ SehirDisiHarcama: int   30 22 25 20 29 29 28 28 53 43 ...
## $ Fiyat           : int 13950 17450 17710 23875 16430 16925 20970 21105 5151 6295 .
```

```
print(summary(veri))
```

```
##      SiraNo      RiskDerecesi      KayipDegeri      Uretici
## Min.   : 1.0    Min.   : -2.0000    Min.   : 65.0    toyota :31
## 1st Qu.: 40.5   1st Qu.: 0.0000    1st Qu.: 94.0    nissan  :18
## Median : 80.0   Median : 1.0000    Median :113.0    honda  :13
## Mean   : 80.0   Mean   : 0.7358    Mean   :121.1    subaru :12
## 3rd Qu.:119.5   3rd Qu.: 2.0000    3rd Qu.:148.0    mazda  :11
## Max.   :159.0   Max.   : 3.0000    Max.   :256.0    volvo  :11
##                                     (Other):63
##      YakitTuru   Enjeksiyon   KapiSayisi      GovdeTuru   Cekis
## diesel: 15     std  :132     four:95      convertible: 2    4wd: 8
## gas   :144     turbo: 27     two :64      hardtop      : 5    fwd:105
##                                     hatchback   :56    rwd: 46
##                                     sedan        :79
##                                     wagon         :17
##
##      DingilAcikligi      Uzunluk      Genislik      Yukseklik
## Min.   : 86.60    Min.   :141.1    Min.   :60.30    Min.   :49.40
## 1st Qu.: 94.50    1st Qu.:165.7    1st Qu.:64.00    1st Qu.:52.25
## Median : 96.90    Median :172.4    Median :65.40    Median :54.10
## Mean   : 98.26    Mean   :172.4    Mean   :65.61    Mean   :53.90
## 3rd Qu.:100.80    3rd Qu.:177.8    3rd Qu.:66.50    3rd Qu.:55.50
## Max.   :115.60    Max.   :202.6    Max.   :71.70    Max.   :59.80
##
##      AzamiAgirlik   MotorTuru   SilindirSayisi   MotorHacmi   YakitSistemi
## Min.   :1488     dohc: 8     eight: 1      Min.   : 61.0    1bbl:11
## 1st Qu.:2066     l   : 8     five : 7      1st Qu.: 97.0    2bbl:63
## Median :2340     ohc :123    four :136     Median :110.0    idi :15
## Mean   :2461     ohcf: 12    six  : 14     Mean   :119.2    mfi : 1
## 3rd Qu.:2810     ohcv: 8     three: 1      3rd Qu.:135.0    mpfi:64
## Max.   :4066                                     Max.   :258.0    spdi: 5
##
##      SilindirCapi      Zamanlama      SikistirmaOrani      BeygirGucu
## Min.   :2.54    Min.   :2.070    Min.   : 7.00    Min.   : 48.00
## 1st Qu.:3.05    1st Qu.:3.105    1st Qu.: 8.70    1st Qu.: 69.00
## Median :3.27    Median :3.270    Median : 9.00    Median : 88.00
```



```
## Mean :3.30 Mean :3.236 Mean :10.16 Mean : 95.84
## 3rd Qu.:3.56 3rd Qu.:3.410 3rd Qu.: 9.40 3rd Qu.:114.00
## Max. :3.94 Max. :4.170 Max. :23.00 Max. :200.00
##
## MaximumDevir SehirIciHarcama SehirDisiHarcama Fiyat
## Min. :4150 Min. :15.00 Min. :18.00 Min. : 5118
## 1st Qu.:4800 1st Qu.:23.00 1st Qu.:28.00 1st Qu.: 7372
## Median :5200 Median :26.00 Median :32.00 Median : 9233
## Mean :5114 Mean :26.52 Mean :32.08 Mean :11446
## 3rd Qu.:5500 3rd Qu.:31.00 3rd Qu.:37.00 3rd Qu.:14720
## Max. :6600 Max. :49.00 Max. :54.00 Max. :35056
##
```

```
# Toyota marka araçların bulunması
```

```
toyotalar <- veri$Uretici=="toyota"
```

```
toyota.veri <- veri[toyotalar,]
```

```
print(toyota.veri)
```

```
##      SiraNo RiskDerecesi KayipDegeri Uretici YakitTuru Enjeksiyon
## 110      110           1          87  toyota      gas      std
## 111      111           1          87  toyota      gas      std
## 112      112           1          74  toyota      gas      std
## 113      113           0          77  toyota      gas      std
## 114      114           0          81  toyota      gas      std
## 115      115           0          91  toyota      gas      std
## 116      116           0          91  toyota      gas      std
## 117      117           0          91  toyota      gas      std
## 118      118           0          91  toyota    diesel      std
## 119      119           0          91  toyota    diesel      std
## 120      120           0          91  toyota      gas      std
## 121      121           0          91  toyota      gas      std
## 122      122           0          91  toyota      gas      std
## 123      123           1         168  toyota      gas      std
## 124      124           1         168  toyota      gas      std
## 125      125           1         168  toyota      gas      std
## 126      126           1         168  toyota      gas      std
## 127      127           2         134  toyota      gas      std
## 128      128           2         134  toyota      gas      std
## 129      129           2         134  toyota      gas      std
## 130      130           2         134  toyota      gas      std
## 131      131           2         134  toyota      gas      std
```

## 132	132	2	134	toyota	gas	std	
## 133	133	-1	65	toyota	gas	std	
## 134	134	-1	65	toyota	diesel	turbo	
## 135	135	-1	65	toyota	gas	std	
## 136	136	-1	65	toyota	gas	std	
## 137	137	-1	65	toyota	gas	std	
## 138	138	3	197	toyota	gas	std	
## 139	139	3	197	toyota	gas	std	
## 140	140	-1	90	toyota	gas	std	
##	KapiSayisi	GovdeTuru	Cekis	DingilAcikligi	Uzunluk	Genislik	Yukseklik
## 110	two	hatchback	fwd	95.7	158.7	63.6	54.5
## 111	two	hatchback	fwd	95.7	158.7	63.6	54.5
## 112	four	hatchback	fwd	95.7	158.7	63.6	54.5
## 113	four	wagon	fwd	95.7	169.7	63.6	59.1
## 114	four	wagon	4wd	95.7	169.7	63.6	59.1
## 115	four	wagon	4wd	95.7	169.7	63.6	59.1
## 116	four	sedan	fwd	95.7	166.3	64.4	53.0
## 117	four	hatchback	fwd	95.7	166.3	64.4	52.8
## 118	four	sedan	fwd	95.7	166.3	64.4	53.0
## 119	four	hatchback	fwd	95.7	166.3	64.4	52.8
## 120	four	sedan	fwd	95.7	166.3	64.4	53.0
## 121	four	hatchback	fwd	95.7	166.3	64.4	52.8
## 122	four	sedan	fwd	95.7	166.3	64.4	52.8
## 123	two	sedan	rwd	94.5	168.7	64.0	52.6
## 124	two	hatchback	rwd	94.5	168.7	64.0	52.6
## 125	two	sedan	rwd	94.5	168.7	64.0	52.6
## 126	two	hatchback	rwd	94.5	168.7	64.0	52.6
## 127	two	hardtop	rwd	98.4	176.2	65.6	52.0
## 128	two	hardtop	rwd	98.4	176.2	65.6	52.0
## 129	two	hatchback	rwd	98.4	176.2	65.6	52.0
## 130	two	hardtop	rwd	98.4	176.2	65.6	52.0
## 131	two	hatchback	rwd	98.4	176.2	65.6	52.0
## 132	two	convertible	rwd	98.4	176.2	65.6	53.0
## 133	four	sedan	fwd	102.4	175.6	66.5	54.9
## 134	four	sedan	fwd	102.4	175.6	66.5	54.9
## 135	four	hatchback	fwd	102.4	175.6	66.5	53.9
## 136	four	sedan	fwd	102.4	175.6	66.5	54.9
## 137	four	hatchback	fwd	102.4	175.6	66.5	53.9
## 138	two	hatchback	rwd	102.9	183.5	67.7	52.0
## 139	two	hatchback	rwd	102.9	183.5	67.7	52.0
## 140	four	sedan	rwd	104.5	187.8	66.5	54.1
##	AzamiAgirlik	MotorTuru	SilindirSayisi	MotorHacmi	YakitSistemi		
## 110	1985	ohc	four	92	2bbl		
## 111	2040	ohc	four	92	2bbl		
## 112	2015	ohc	four	92	2bbl		

## 113	2280	ohc	four	92	2bbl
## 114	2290	ohc	four	92	2bbl
## 115	3110	ohc	four	92	2bbl
## 116	2081	ohc	four	98	2bbl
## 117	2109	ohc	four	98	2bbl
## 118	2275	ohc	four	110	idi
## 119	2275	ohc	four	110	idi
## 120	2094	ohc	four	98	2bbl
## 121	2122	ohc	four	98	2bbl
## 122	2140	ohc	four	98	2bbl
## 123	2169	ohc	four	98	2bbl
## 124	2204	ohc	four	98	2bbl
## 125	2265	dohc	four	98	mpfi
## 126	2300	dohc	four	98	mpfi
## 127	2540	ohc	four	146	mpfi
## 128	2536	ohc	four	146	mpfi
## 129	2551	ohc	four	146	mpfi
## 130	2679	ohc	four	146	mpfi
## 131	2714	ohc	four	146	mpfi
## 132	2975	ohc	four	146	mpfi
## 133	2326	ohc	four	122	mpfi
## 134	2480	ohc	four	110	idi
## 135	2414	ohc	four	122	mpfi
## 136	2414	ohc	four	122	mpfi
## 137	2458	ohc	four	122	mpfi
## 138	2976	dohc	six	171	mpfi
## 139	3016	dohc	six	171	mpfi
## 140	3131	dohc	six	171	mpfi
##	SilindirCapi	Zamanlama	SikistirmaOrani	BeygirGucu	MaximumDevir
## 110	3.05	3.03	9.0	62	4800
## 111	3.05	3.03	9.0	62	4800
## 112	3.05	3.03	9.0	62	4800
## 113	3.05	3.03	9.0	62	4800
## 114	3.05	3.03	9.0	62	4800
## 115	3.05	3.03	9.0	62	4800
## 116	3.19	3.03	9.0	70	4800
## 117	3.19	3.03	9.0	70	4800
## 118	3.27	3.35	22.5	56	4500
## 119	3.27	3.35	22.5	56	4500
## 120	3.19	3.03	9.0	70	4800
## 121	3.19	3.03	9.0	70	4800
## 122	3.19	3.03	9.0	70	4800
## 123	3.19	3.03	9.0	70	4800
## 124	3.19	3.03	9.0	70	4800
## 125	3.24	3.08	9.4	112	6600

## 126	3.24	3.08	9.4	112	6600
## 127	3.62	3.50	9.3	116	4800
## 128	3.62	3.50	9.3	116	4800
## 129	3.62	3.50	9.3	116	4800
## 130	3.62	3.50	9.3	116	4800
## 131	3.62	3.50	9.3	116	4800
## 132	3.62	3.50	9.3	116	4800
## 133	3.31	3.54	8.7	92	4200
## 134	3.27	3.35	22.5	73	4500
## 135	3.31	3.54	8.7	92	4200
## 136	3.31	3.54	8.7	92	4200
## 137	3.31	3.54	8.7	92	4200
## 138	3.27	3.35	9.3	161	5200
## 139	3.27	3.35	9.3	161	5200
## 140	3.27	3.35	9.2	156	5200

##	SehirIciHarcama	SehirDisiHarcama	Fiyat
## 110	35	39	5348
## 111	31	38	6338
## 112	31	38	6488
## 113	31	37	6918
## 114	27	32	7898
## 115	27	32	8778
## 116	30	37	6938
## 117	30	37	7198
## 118	34	36	7898
## 119	38	47	7788
## 120	38	47	7738
## 121	28	34	8358
## 122	28	34	9258
## 123	29	34	8058
## 124	29	34	8238
## 125	26	29	9298
## 126	26	29	9538
## 127	24	30	8449
## 128	24	30	9639
## 129	24	30	9989
## 130	24	30	11199
## 131	24	30	11549
## 132	24	30	17669
## 133	29	34	8948
## 134	30	33	10698
## 135	27	32	9988
## 136	27	32	10898
## 137	27	32	11248
## 138	20	24	16558

```
## 139          19          24 15998
## 140          20          24 15690
```

Toyota Marka Araçların Dizel yakıt kullananlarının bulunması yöntem 1

```
toyota.dizeller <- toyota.veri$YakitTuru=="diesel"

dizel.toyotalar <- toyota.veri[toyota.dizeller,]

print(dizel.toyotalar)
```

```
##      SiraNo RiskDerecesi KayipDegeri Uretici YakitTuru Enjeksiyon
## 118      118           0           91  toyota   diesel      std
## 119      119           0           91  toyota   diesel      std
## 134      134          -1           65  toyota   diesel   turbo
##      KapiSayisi GovdeTuru Cekis DingilAcikligi Uzunluk Genislik Yukseklik
## 118      four      sedan   fwd           95.7   166.3   64.4   53.0
## 119      four hatchback   fwd           95.7   166.3   64.4   52.8
## 134      four      sedan   fwd          102.4   175.6   66.5   54.9
##      AzamiAgirlik MotorTuru SilindirSayisi MotorHacmi YakitSistemi
## 118      2275      ohc           four          110      idi
## 119      2275      ohc           four          110      idi
## 134      2480      ohc           four          110      idi
##      SilindirCapi Zamanlama SikistirmaOrani BeygirGucu MaximumDevir
## 118      3.27      3.35           22.5          56      4500
## 119      3.27      3.35           22.5          56      4500
## 134      3.27      3.35           22.5          73      4500
##      SehirIciHarcama SehirDisiHarcama Fiyat
## 118           34           36  7898
## 119           38           47  7788
## 134           30           33 10698
```

Toyota Marka Araçların Dizel yakıt kullananlarının bulunması yöntem 2

```
dizeller <- veri$YakitTuru == "diesel"

toyota.dizeller <- toyotalar & dizeller

dizel.toyotalar = veri[toyota.dizeller,]

print(dizel.toyotalar)
```

```
##      SiraNo RiskDerecesi KayipDegeri Uretici YakitTuru Enjeksiyon
## 118      118           0           91  toyota   diesel      std
```

```
## 119      119          0          91 toyota      diesel      std
## 134      134         -1          65 toyota      diesel      turbo
##      KapiSayisi GovdeTuru Cekis DingilAcikligi Uzunluk Genislik Yukseklik
## 118      four      sedan      fwd          95.7    166.3     64.4     53.0
## 119      four hatchback      fwd          95.7    166.3     64.4     52.8
## 134      four      sedan      fwd         102.4    175.6     66.5     54.9
##      AzamiAgirlik MotorTuru SilindirSayisi MotorHacmi YakitSistemi
## 118      2275      ohc          four          110      idi
## 119      2275      ohc          four          110      idi
## 134      2480      ohc          four          110      idi
##      SilindirCapi Zamanlama SikistirmaOrani BeygirGucu MaximumDevir
## 118      3.27      3.35          22.5          56      4500
## 119      3.27      3.35          22.5          56      4500
## 134      3.27      3.35          22.5          73      4500
##      SehirIciHarcama SehirDisiHarcama Fiyat
## 118      34          36      7898
## 119      38          47      7788
## 134      30          33     10698
```

```
# Yeni bir sütun eklenmesi
```

```
veri$TLFiyat = veri$Fiyat * 3.6050

print(summary(veri$TLFiyat))
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  18450   26580   33280   41260   53060   126400
```

```
# Toyota marka araçların ortalama fiyatının bulunması
```

```
toyota.ortalama.fiyat <- mean(veri$Fiyat[veri$Uretici=="toyota"])

print(toyota.ortalama.fiyat)
```

```
## [1] 9696.645
```

```
# Kaç tane benzinli araç olduğunun bulunması
```

```
print(length(veri$SiraNo[veri$YakitTuru=='gas']))
```

```
## [1] 144
```

```
print(nrow(veri[veri$YakitTuru=='gas',]))
```

```
## [1] 144
```

```
# TL Fiyatı 100000 'den büyük araçların bulunması
```

```
print(veri[veri$TLFiyat>100000,])
```

```
##      SiraNo RiskDerecesi KayipDegeri      Uretici YakitTuru Enjeksiyon
## 33      33          0         145      jaguar      gas      std
## 46      46         -1          93 mercedes-benz  diesel  turbo
## 47      47          0          93 mercedes-benz  diesel  turbo
## 48      48         -1          93 mercedes-benz  diesel  turbo
## 49      49          3         142 mercedes-benz  gas      std
##      KapiSayisi   GovdeTuru Cekis DingilAcikligi Uzunluk Genislik Yukseklik
## 33      four      sedan   rwd      113.0    199.6    69.6    52.8
## 46      four      wagon   rwd      110.0    190.9    70.3    58.7
## 47      two       hardtop  rwd      106.7    187.5    70.3    54.9
## 48      four      sedan   rwd      115.6    202.6    71.7    56.3
## 49      two convertible rwd      96.6     180.3    70.5    50.8
##      AzamiAgirlik MotorTuru SilindirSayisi MotorHacmi YakitSistemi
## 33      4066      dohc      six      258      mpfi
## 46      3750      ohc      five     183      idi
## 47      3495      ohc      five     183      idi
## 48      3770      ohc      five     183      idi
## 49      3685      ohcv     eight    234      mpfi
##      SilindirCapi Zamanlama SikistirmaOrani BeygirGucu MaximumDevir
## 33      3.63      4.17      8.1      176      4750
## 46      3.58      3.64      21.5     123      4350
## 47      3.58      3.64      21.5     123      4350
## 48      3.58      3.64      21.5     123      4350
## 49      3.46      3.10      8.3      155      4750
##      SehirIciHarcama SehirDisiHarcama Fiyat   TLFiyat
## 33      15          19 32250 116261.2
## 46      22          25 28248 101834.0
## 47      22          25 28176 101574.5
## 48      22          25 31600 113918.0
## 49      16          18 35056 126376.9
```

```
# TL Fiyatı en pahalı ve en ucuz olan araçların bulunması
```

```
enBuyuk <- veri[veri$TLFiyat==max(veri$TLFiyat),]
enKucuk <- veri[veri$TLFiyat==min(veri$TLFiyat),]
```

```
sonuc <- rbind(enBuyuk,enKucuk)
```

```
print(sonuc)
```

```
##      SiraNo RiskDerecesi KayipDegeri      Uretici YakitTuru Enjeksiyon
## 49      49          3      142 mercedes-benz      gas      std
## 98      98          2       83      subaru      gas      std
##      KapiSayisi   GovdeTuru Cekis DingilAcikligi Uzunluk Genislik Yukseklik
## 49      two convertible   rwd      96.6   180.3    70.5    50.8
## 98      two  hatchback   fwd      93.7   156.9    63.4    53.7
##      AzamiAgirlik MotorTuru SilindirSayisi MotorHacmi YakitSistemi
## 49      3685      ohcv      eight      234      mpfi
## 98      2050      ohcf      four      97      2bbl
##      SilindirCapi Zamanlama SikistirmaOrani BeygirGucu MaximumDevir
## 49      3.46      3.10      8.3      155      4750
## 98      3.62      2.36      9.0      69      4900
##      SehirIciHarcama SehirDisiHarcama Fiyat   TLFiyat
## 49      16      18 35056 126376.88
## 98      31      36 5118 18450.39
```

```
# Araç üreticilerini listelenmesi
```

```
ureticiler <- levels(veri$Uretici)
```

```
print(ureticiler)
```

```
## [1] "audi"      "bmw"      "chevrolet" "dodge"
## [5] "honda"     "jaguar"   "mazda"     "mercedes-benz"
## [9] "mitsubishi" "nissan"   "peugot"    "plymouth"
## [13] "porsche"   "saab"     "subaru"    "toyota"
## [17] "volkswagen" "volvo"
```

```
# Araç üreticilerine göre ortalama fiyatların bulunması
```

```
ortalama.listesi = list()
```

```
length(ortalama.listesi) <- length(ureticiler)
```

```
names(ortalama.listesi) <- ureticiler
```

```
for(uretici in ureticiler) {
  ortalama.listesi[[uretici]] <- mean(veri$Fiyat[veri$Uretici==uretici])
}
```



```
print(ortalama.listesi)
```

```
## $audi
## [1] 18246.25
##
## $bmw
## [1] 18857.5
##
## $chevrolet
## [1] 6007
##
## $dodge
## [1] 7790.125
##
## $honda
## [1] 8184.692
##
## $jaguar
## [1] 32250
##
## $mazda
## [1] 9080
##
## $`mercedes-benz`
## [1] 29726.4
##
## $mitsubishi
## [1] 7813
##
## $nissan
## [1] 10415.67
##
## $peugot
## [1] 15758.57
##
## $plymouth
## [1] 7163.333
##
## $porsche
## [1] 22018
##
## $saab
## [1] 15223.33
##
```

```
## $subaru
## [1] 8541.25
##
## $toyota
## [1] 9696.645
##
## $volkswagen
## [1] 8738.125
##
## $volvo
## [1] 18063.18
```

R ile Tanımlayıcı İstatistikler ve Nominal Değerlerin İncelenmesi

R Programlama dili ile verinize ait tanımlayıcı istatistikleri aşağıdaki şekilde elde edebilirsiniz.

4.1 Veri Yükleme

İlk olarak verinizi bir klasöre indirim ve onu çalışma klasörü olarak belirleyin. Daha sonra csv dosyanızı R içerisine alın.

- NOT: Burada `read.csv2`, Türkçe Excel ile oluşturulmuş CSV'leri yüklemek için kullanılmaktadır.

```
analiz_verisi <- read.csv2('imports-85.csv')
```

4.2 Veri Bölme

`summary()` Fonksiyonuyla verimizin yapısı hakkında bilgi edinelim. Fakat burada `summary` fonksiyonunu sadece sayısal değişkenlerimiz için kullanalım. Bunun için, ilk olarak veri içerisindeki numeric ve integer alanların hangileri olduklarını bulmalısınız. Eğer tek bir vektörün veri türünü öğrenmek isteseydik, o zaman `class` fonksiyonunu kullanabilirdik. Fakat burada, bir data frame'in içerisindeki bütün sütunların veri türünü öğrenmek istiyoruz. O yüzden `sapply()` fonksiyonunu kullanmalısınız.

- NOT: `sapply()` komutu belirttiğiniz fonksiyonu data frame içerisindeki bütün sütunlara uygular ve sonuçlarını içeren bir vektör oluşturur. Burada, bütün sütunlara `class()` fonksiyonunu uygulamak için kullanılmıştır. Elde edilen sonuçların numeric veya integer değer olanları bulunup filtrelenmiştir.

```

numeric_sutunlar <- sapply(analiz_verisi, class)=="numeric"
integer_sutunlar <- sapply(analiz_verisi, class)=="integer"

sayisal_sutunlar <- numeric_sutunlar | integer_sutunlar

sayisal_veri <- analiz_verisi[,sayisal_sutunlar]

print(summary(sayisal_veri))

```

```

##      SiraNo      RiskDerecesi      KayipDegeri      DingilAcikligi
## Min.      : 1.0      Min.      :-2.0000      Min.      : 65.0      Min.      : 86.60
## 1st Qu.: 40.5      1st Qu.: 0.0000      1st Qu.: 94.0      1st Qu.: 94.50
## Median : 80.0      Median : 1.0000      Median :113.0      Median : 96.90
## Mean      : 80.0      Mean      : 0.7358      Mean      :121.1      Mean      : 98.26
## 3rd Qu.:119.5      3rd Qu.: 2.0000      3rd Qu.:148.0      3rd Qu.:100.80
## Max.      :159.0      Max.      : 3.0000      Max.      :256.0      Max.      :115.60
##      Uzunluk      Genislik      Yukseklik      AzamiAgirlik
## Min.      :141.1      Min.      :60.30      Min.      :49.40      Min.      :1488
## 1st Qu.:165.7      1st Qu.:64.00      1st Qu.:52.25      1st Qu.:2066
## Median :172.4      Median :65.40      Median :54.10      Median :2340
## Mean      :172.4      Mean      :65.61      Mean      :53.90      Mean      :2461
## 3rd Qu.:177.8      3rd Qu.:66.50      3rd Qu.:55.50      3rd Qu.:2810
## Max.      :202.6      Max.      :71.70      Max.      :59.80      Max.      :4066
##      MotorHacmi      SilindirCapi      Zamanlama      SikistirmaOrani
## Min.      : 61.0      Min.      :2.54      Min.      :2.070      Min.      : 7.00
## 1st Qu.: 97.0      1st Qu.:3.05      1st Qu.:3.105      1st Qu.: 8.70
## Median :110.0      Median :3.27      Median :3.270      Median : 9.00
## Mean      :119.2      Mean      :3.30      Mean      :3.236      Mean      :10.16
## 3rd Qu.:135.0      3rd Qu.:3.56      3rd Qu.:3.410      3rd Qu.: 9.40
## Max.      :258.0      Max.      :3.94      Max.      :4.170      Max.      :23.00
##      BeygirGucu      MaximumDevir      SehirIciHarcama      SehirDisiHarcama
## Min.      : 48.00      Min.      :4150      Min.      :15.00      Min.      :18.00
## 1st Qu.: 69.00      1st Qu.:4800      1st Qu.:23.00      1st Qu.:28.00
## Median : 88.00      Median :5200      Median :26.00      Median :32.00
## Mean      : 95.84      Mean      :5114      Mean      :26.52      Mean      :32.08
## 3rd Qu.:114.00      3rd Qu.:5500      3rd Qu.:31.00      3rd Qu.:37.00
## Max.      :200.00      Max.      :6600      Max.      :49.00      Max.      :54.00
##      Fiyat
## Min.      : 5118
## 1st Qu.: 7372
## Median : 9233
## Mean      :11446
## 3rd Qu.:14720
## Max.      :35056

```

Ayrıca R'ın genişletilebilir yapısı sayesinde sayısal değişkenleriniz için istediğiniz istatistiksel özeti, hazır paketler kullanarak alabilirsiniz. Bunları bilgisayarınıza yüklemek için bilgisayarınızda RTools yazılımının yüklü olması gerekmektedir. Şu aşamada kullanacağımız paket, *psych* paketidir. Bu paket, bilgisayarınıza aşağıdaki R komutu kullanılarak yüklenebilir.

```
install.packages('psych')
```

Bir paket bilgisayarınıza yüklendikten sonra *library* komutu ile kullanıma alınabilir.

```
library(psych)
```

Dikkat ederseniz paket bilgisayarınıza yüklenirken, tırnak işareti yazılmalıdır. Ondan sonra paketi kullanıma alırken doğrudan adını yazmanız yeterli olacaktır. *psych* paketini kullanıma aldıktan sonra, iki komut yardımıyla veri çerçevesinin sayısal değişkenleri hakkında özet bilgi alabilirsiniz. Bu komutlar *describe* ve *describeBy* komutlarıdır. *describe* komutu bütün veri çerçevesinin tanımlayıcı istatistiklerini elde etmek için kullanılırken, *describeBy* komutu veriyi bir nominal değişkene bağlı olarak gruplayarak her gruba ait tanımlayıcı istatistikleri çıkartır.

```
describe(sayisal_veri)
```

```
##          vars   n    mean     sd  median  trimmed    mad
## SiraNo      1 159   80.00  46.04   80.00    80.00   59.30
## RiskDerecesi 2 159    0.74   1.19    1.00     0.71    1.48
## KayipDegeri  3 159  121.13  35.65  113.00   118.43   32.62
## DingilAcikligi 4 159   98.26   5.17   96.90    97.72    3.56
## Uzunluk      5 159  172.41  11.52  172.40   172.49    9.04
## Genislik     6 159   65.61   1.95   65.40    65.39    1.78
## Yukseklik    7 159   53.90   2.27   54.10    53.85    2.37
## AzamiAgirlik  8 159 2461.14 481.94 2340.00  2422.71  492.22
## MotorHacmi   9 159  119.23  30.46  110.00   114.88   19.27
## SilindirCapi 10 159    3.30   0.27    3.27     3.29    0.36
## Zamanlama    11 159    3.24   0.29    3.27     3.27    0.21
## SikistirmaOrani 12 159   10.16   3.89    9.00     9.08    0.59
## BeygirGucu   13 159   95.84  30.72   88.00    92.43   29.65
## MaximumDevir 14 159 5113.84 465.75 5200.00  5114.34  444.78
## SehirIciHarcama 15 159   26.52   6.10   26.00    26.09    5.93
## SehirDisiHarcama 16 159   32.08   6.46   32.00    31.74    5.93
## Fiyat       17 159 11445.73 5877.86 9233.00 10543.25 3534.52
##          min     max  range  skew kurtosis    se
## SiraNo      1.00  159.00  158.0  0.00   -1.22   3.65
## RiskDerecesi -2.00    3.00    5.0  0.09   -0.58  0.09
## KayipDegeri  65.00  256.00  191.0  0.82    0.52  2.83
## DingilAcikligi 86.60  115.60   29.0  0.90    0.53  0.41
## Uzunluk     141.10  202.60   61.5 -0.06   -0.27  0.91
```

## Genislik	60.30	71.70	11.4	0.90	0.74	0.15
## Yukseklik	49.40	59.80	10.4	0.17	-0.34	0.18
## AzamiAgirlik	1488.00	4066.00	2578.0	0.77	0.07	38.22
## MotorHacmi	61.00	258.00	197.0	1.46	2.75	2.42
## SilindirCapi	2.54	3.94	1.4	0.15	-0.86	0.02
## Zamanlama	2.07	4.17	2.1	-0.97	2.35	0.02
## SikistirmaOrani	7.00	23.00	16.0	2.66	5.40	0.31
## BeygirGucu	48.00	200.00	152.0	0.90	0.21	2.44
## MaximumDevir	4150.00	6600.00	2450.0	0.15	0.31	36.94
## SehirIciHarcama	15.00	49.00	34.0	0.72	1.02	0.48
## SehirDisiHarcama	18.00	54.00	36.0	0.59	0.72	0.51
## Fiyat	5118.00	35056.00	29938.0	1.56	2.41	466.14

```
describeBy(sayisal_veri, group = analiz_verisi$KapiSayisi)
```

```
##
## Descriptive statistics by group
## group: four
##
```

	vars	n	mean	sd	median	trimmed	mad	min
## SiraNo	1	95	86.13	46.78	88.00	87.29	59.30	1.00
## RiskDerecesi	2	95	0.13	0.97	0.00	0.08	1.48	-2.00
## KayipDegeri	3	95	109.65	30.36	102.00	107.57	19.27	65.00
## DingilAcikligi	4	95	100.07	5.34	97.30	99.61	4.15	93.10
## Uzunluk	5	95	176.30	10.16	174.60	176.37	11.56	157.10
## Genislik	6	95	66.00	1.99	65.40	65.80	1.63	62.50
## Yukseklik	7	95	54.77	2.11	54.90	54.75	1.78	50.60
## AzamiAgirlik	8	95	2563.35	477.51	2410.00	2526.99	515.94	1909.00
## MotorHacmi	9	95	121.35	28.83	110.00	117.14	19.27	90.00
## SilindirCapi	10	95	3.35	0.26	3.31	3.34	0.34	2.91
## Zamanlama	11	95	3.23	0.30	3.27	3.25	0.21	2.19
## SikistirmaOrani	12	95	10.53	4.43	9.00	9.49	0.59	7.00
## BeygirGucu	13	95	96.59	28.59	92.00	93.45	32.62	52.00
## MaximumDevir	14	95	5049.47	451.68	5100.00	5065.58	444.78	4150.00
## SehirIciHarcama	15	95	25.69	5.33	26.00	25.60	5.93	15.00
## SehirDisiHarcama	16	95	31.23	5.98	32.00	31.10	5.93	19.00
## Fiyat	17	95	12225.56	5811.54	9988.00	11335.73	4136.45	6229.00

```
##
##
```

	max	range	skew	kurtosis	se
## SiraNo	159.00	158.00	-0.16	-1.14	4.80
## RiskDerecesi	2.00	4.00	0.23	-0.30	0.10
## KayipDegeri	192.00	127.00	0.77	-0.31	3.12
## DingilAcikligi	115.60	22.50	0.77	-0.46	0.55
## Uzunluk	202.60	45.50	0.18	-0.59	1.04
## Genislik	71.70	9.20	0.86	0.26	0.20
## Yukseklik	59.80	9.20	0.08	-0.14	0.22

```

## AzamiAgirlik      4066.00  2157.00  0.74   -0.07  48.99
## MotorHacmi        258.00   168.00  1.67    4.12   2.96
## SilindirCapi       3.78    0.87  0.13   -1.21   0.03
## Zamanlama         4.17    1.98 -0.65    1.40   0.03
## SikistirmaOrani    23.00    16.00  2.16    2.88   0.45
## BeygirGucu        176.00   124.00  0.82   -0.01   2.93
## MaximumDevir      6000.00  1850.00 -0.24   -0.59  46.34
## SehirIciHarcama    38.00    23.00  0.18   -0.46   0.55
## SehirDisiHarcama   47.00    28.00  0.29   -0.16   0.61
## Fiyat             32250.00 26021.00 1.36    1.53 596.25
## -----
## group: two
##               vars  n      mean      sd  median trimmed      mad      min
## SiraNo          1 64    70.91   43.72   63.50    70.04    53.37    5.00
## RiskDerecesi    2 64     1.64    0.88    1.50     1.63     0.74     0.00
## KayipDegeri     3 64   138.17   36.31  134.00   135.73    40.03   83.00
## DingilAcikligi  4 64    95.58    3.48   94.50    95.49     2.08   86.60
## Uzunluk         5 64   166.64   11.06  167.50   166.74    13.05  141.10
## Genislik        6 64    65.02    1.74   64.30    64.82     1.04   60.30
## Yukseklik       7 64    52.61    1.85   52.60    52.57     2.59   49.40
## AzamiAgirlik    8 64  2309.42  450.74 2215.00  2262.52   440.33 1488.00
## MotorHacmi     9 64   116.08   32.71  100.50   111.50    14.08   61.00
## SilindirCapi   10 64     3.23    0.27    3.16     3.22     0.28    2.54
## Zamanlama      11 64     3.25    0.29    3.29     3.28     0.23    2.07
## SikistirmaOrani 12 64     9.62    2.86    9.20     9.13     0.30    7.00
## BeygirGucu     13 64    94.72   33.84   84.50    90.87    25.20   48.00
## MaximumDevir   14 64  5209.38  473.41 5200.00  5181.73   444.78 4250.00
## SehirIciHarcama 15 64    27.75    6.95   26.00    27.17     7.41   16.00
## SehirDisiHarcama 16 64    33.34    6.97   32.00    32.85     6.67   18.00
## Fiyat          17 64 10288.17 5828.90 8016.50  9279.33  2779.13 5118.00
##               max    range  skew  kurtosis      se
## SiraNo          148.00   143.00  0.20   -1.33    5.46
## RiskDerecesi     3.00     3.00  0.20   -0.95    0.11
## KayipDegeri     256.00   173.00  0.79    0.57    4.54
## DingilAcikligi  106.70    20.10  0.28    1.36    0.44
## Uzunluk         187.50    46.40 -0.08   -0.66    1.38
## Genislik        70.50    10.20  0.94    1.59    0.22
## Yukseklik       56.10     6.70  0.12   -1.00    0.23
## AzamiAgirlik    3685.00  2197.00  0.92    0.36   56.34
## MotorHacmi     234.00   173.00  1.30    1.34    4.09
## SilindirCapi     3.94     1.40  0.29   -0.52    0.03
## Zamanlama       3.90     1.83 -1.47    3.85    0.04
## SikistirmaOrani  23.00    16.00  3.92   14.52    0.36
## BeygirGucu      200.00   152.00  0.97    0.21    4.23
## MaximumDevir   6600.00  2350.00  0.60    0.69   59.18

```

```
## SehirIciHarcama      49.00      33.00  0.87      0.80      0.87
## SehirDisiHarcama     54.00      36.00  0.75      0.82      0.87
## Fiyat                35056.00 29938.00  1.98      4.38 728.61
```

4.3 Nominal Değerler İçin Tanımlayıcı İstatistikler

Şimdi de nominal değişkenler için tanımlayıcı istatistikleri elde etmeye çalışalım. Geriye nominal alanlar kaldığı için, bu değişkenlerin hangi değerden kaç adet içerdiğinin bulunması yeterli olacaktır. Bu işlemi gerçekleştirebilmek için **for** döngüsü ve *table()* fonksiyonundan yararlanacağız.

4.3.1 Tablo Oluşturma

table Fonksiyonu R'in en esnek fonksiyonlarından biridir. *table()* fonksiyonu tek bir nominal değer ile kullanılırsa, size nominal değerlerin frekans tablosunu oluşturur. Şimdi bütün nominal değerlerin frekans tablolarını oluşturalım.

```
nominal_sutunlar <- !sayisal_sutunlar

nominal_veri <- analiz_verisi[,nominal_sutunlar]

for(i in 1:ncol(nominal_veri)) {
  print(table(nominal_veri[,i]))
}
```

```
##
##          audi          bmw      chevrolet      dodge      honda
##           4           4           3           8          13
##       jaguar      mazda mercedes-benz  mitsubishi      nissan
##           1          11           5          10          18
##       peugot      plymouth      porsche      saab      subaru
##           7           6           1           6          12
##       toyota      volkswagen      volvo
##          31           8          11
##
## diesel      gas
##          15      144
##
##      std turbo
##       132      27
##
## four      two
##        95      64
##
## convertible      hardtop      hatchback      sedan      wagon
```



```
##           2           5           56           79           17
##
## 4wd fwd rwd
##   8 105  46
##
## dohc     1   ohc ohcf ohcv
##    8     8  123   12    8
##
## eight  five  four   six three
##    1     7   136   14     1
##
## 1bbl 2bbl  idi  mfi mpfi spdi
##   11   63   15    1   64    5
```

4.3.2 Marjinal Değerleri Ekleme

`table()` fonksiyonu ile bir tablo oluşturduktan sonra `addmargins` fonksiyonu ile marjinal toplam-ları tablonuza ekleyebilirsiniz.

```
nominal_sutunlar <- !sayisal_sutunlar

nominal_veri <- analiz_verisi[,nominal_sutunlar]

for(i in 1:ncol(nominal_veri)) {
  frekans.tablosu <- table(nominal_veri[,i])
  marjinal.frekans.tablosu <- addmargins(frekans.tablosu)
  print(marjinal.frekans.tablosu)
}
```

```
##
##          audi          bmw    chevrolet      dodge      honda
##          4           4           3           8           13
##    jaguar      mazda mercedes-benz    mitsubishi    nissan
##          1           11           5           10           18
##    peugot    plymouth      porsche      saab      subaru
##          7           6           1           6           12
##    toyota    volkswagen      volvo      Sum
##          31           8           11          159
##
## diesel    gas    Sum
##          15    144    159
##
##    std turbo    Sum
##          132    27    159
##
```

```
## four two Sum
## 95 64 159
##
## convertible hardtop hatchback sedan wagon Sum
## 2 5 56 79 17 159
##
## 4wd fwd rwd Sum
## 8 105 46 159
##
## dohc 1 ohc ohcf ohcv Sum
## 8 8 123 12 8 159
##
## eight five four six three Sum
## 1 7 136 14 1 159
##
## 1bbl 2bbl idi mfi mpfi spdi Sum
## 11 63 15 1 64 5 159
```

4.3.3 Oran Tabloları Oluşturma

`table()` fonksiyonu ile bir tablo oluşturduktan sonra `prop.table()` fonksiyonu ile bu tablonun yüzdeliği değerlerini hesaplatırabilirsiniz. Fakat dikkat etmeniz gereken nokta, `prop.table()` fonksiyonunun 0 ile 1 arasında değer ürettiğidir. Bu sebeple, bu değeri 100 ile çarpıp, virgülden sonra iki hane olacak şekilde yuvarlalarak göstermeniz gerekebilir.

```
nominal_sutunlar <- !sayisal_sutunlar

nominal_veri <- analiz_verisi[,nominal_sutunlar]

for(i in 1:ncol(nominal_veri)) {
  frekans.tablosu <- table(nominal_veri[,i])
  yuzdelikli.frekans.tablosu <- prop.table(frekans.tablosu)
  # Yukarıda bahsedilen yuvarlamayı yapalım.
  print(round(100*yuzdelikli.frekans.tablosu,2))
}
```

```
##
## audi bmw chevrolet dodge honda
## 2.52 2.52 1.89 5.03 8.18
## jaguar mazda mercedes-benz mitsubishi nissan
## 0.63 6.92 3.14 6.29 11.32
## peugot plymouth porsche saab subaru
## 4.40 3.77 0.63 3.77 7.55
## toyota volkswagen volvo
## 19.50 5.03 6.92
```

```
##
## diesel      gas
##    9.43  90.57
##
##    std turbo
## 83.02 16.98
##
##    four      two
## 59.75 40.25
##
## convertible      hardtop      hatchback      sedan      wagon
##          1.26          3.14          35.22          49.69          10.69
##
##    4wd      fwd      rwd
## 5.03 66.04 28.93
##
## dohc      l      ohc      ohcf      ohcv
## 5.03 5.03 77.36 7.55 5.03
##
## eight      five      four      six      three
## 0.63 4.40 85.53 8.81 0.63
##
## 1bbl 2bbl      idi      mfi      mpfi      spdi
## 6.92 39.62 9.43 0.63 40.25 3.14
```

4.3.4 Çapraz Tablo Oluşturma

`table()` fonksiyonuna bir yerine iki nominal değer verirsiniz, bu iki değer oluşturacağı Çapraz Tablo'yu elde edersiniz. Çapraz Tablo, satırları A değişkeninin nominal değerlerini, sütunları B değişkeninin nominal değerlerini içeren, hücrelerinde ise, satır ve sütuna ait nominal değerlerin kesişiminin kaç kez geçtiğini gösteren bir tablodur. Örneğin, yakıt türü ve kapı sayısına ait bir çapraz tablo aşağıdaki gibi oluşturulabilir.

```
capraz.tablo <- table(nominal_veri$YakitTuru, nominal_veri$KapiSayisi)

print(capraz.tablo)
```

```
##
##          four two
## diesel    12   3
## gas       83  61
```

Tabloya göre, verimizde hem *diesel* hem de *dört* kapılı 12 araç bulunmaktadır. Yukarıda bahsedilen marjinal değerler ve oransal değerler çapraz tablolaya uygulanabilir.

```
marjinal.frekans.tablosu <- addmargins(capraz.tablo)

print("Marjinal Frekans Tablosu")
```

```
## [1] "Marjinal Frekans Tablosu"
```

```
print(marjinal.frekans.tablosu)
```

```
##
##           four two Sum
##  diesel    12   3  15
##   gas     83  61 144
##   Sum     95  64 159
```

```
yuzdelikli.frekans.tablosu <- prop.table(capraz.tablo)

print("Yüzdelikli Frekans Tablosu")
```

```
## [1] "Yüzdelikli Frekans Tablosu"
```

```
print(round(100*yuzdelikli.frekans.tablosu,2))
```

```
##
##           four   two
##  diesel  7.55  1.89
##   gas   52.20 38.36
```

Bu tablolara göre, *diesel* ve *dört* kapılı araçlar toplan araçların %7.55'ini oluşturmaktadır. Bir veri kümesinde yer alan nominal değerlerin ikili bütün çapraz tabloları ele alınmalıdır. Bu işlem nominal değerler arasındaki ilişkiyi tespit etmek için önemli bir bilgi arz etmektedir. Bu sebeple, bu işlemi bütün nominal değer ikilileri için yapmak isteyebilirsiniz. Bunun için ya bütün değerlere çapraz tablo oluşturan komutları el ile yazmalısınız veya iç içe iki adet *for* döngüsü kullanmalısınız.

- NOT: Nominal değişken çiftleri ile çalışmak istediğiniz için siz tek bir *for* yetmeyecektir. Örneği inceleyin.

```
# Burada bütün nominal değerlerin yer aldığı nominal_veri data.frame'i kullanılıyor.
# ncol fonksiyonu sütun sayısını öğrenmek için kullanılan fonksiyondur.

# İlk for döngümüzü, 1'den sütun sayısının 1 eksiğine kadar yapıyoruz
for(i in 1:(ncol(nominal_veri)-1)) {
  # Data Frame'den ilk değişkeni çıkartalım.
```

```

a <- nominal_veri[,i]
# İşteki for döngümüzde i+1'den sütun sayısına kadar yapıyoruz
for(j in (i+1):ncol(nominal_veri)) {
  # Data Frame'den ikinci değişkeni çıkartalım.
  b <- nominal_veri[,j]

  # Yukarıdaki komutları buraya yapıştırın !!!
  capraz.tablo <- table(a, b)

  marjinal.frekans.tablosu <- addmargins(capraz.tablo)

  cat("Marjinal Frekans Tablosu\n")
  print(marjinal.frekans.tablosu)

  yuzdelikli.frekans.tablosu <- prop.table(capraz.tablo)

  cat("Oransal Frekans Tablosu\n")
  print(round(100*yuzdelikli.frekans.tablosu,2))
}
}

```

4.3.5 Çapraz Tablo Kullanarak Bağımsızlık Testleri

Nominal değişkenlerin arasındaki ilişkileri bulmak için çapraz tablo istatistikleri kullanılır, bunlar Ki-Kare Testi ve Fisher'ın exact testleridir. Burada, hangi testin kullanılacağına tablo değerlerine bakılarak karar verilir. İlk olarak, çapraz tablo için Ki-Kare testi uygulanır. Eğer ki-kare testine göre çapraz tablonun bazı hücrelerin beklenen değeri 5'ten küçük ise Fisher testi yapılır. Aksi durumda Ki-Kare testinin sonuçları gösterilir. Burada test edilen yokluk (null, H0) hipotezi değişkenlerin bağımsız olduğudur. İki test sonucunda da elde edilecek p değeri 0.05'ten küçük olursa yokluk hipotezi reddedilir ve değişkenler arasında ilişki olduğuna karar verilir.

4.3.5.1 Ki-Kare Testi

Ki-Kare testi `chisq.test()` fonksiyonu ile gerçekleştirilir. Eğer sonucu bir değişkene aktarılırsa, değişken (htest türünde) liste olur. Fonksiyonun sonucunu bir değişkene aktarmazsanız, test sonucunu ekrana çıktı verecektir.

```

t <- table(nominal_veri$Enjeksiyon,nominal_veri$KapiSayisi)
chisq.test(t)

##
## Pearson's Chi-squared test with Yates' continuity correction
##
## data:  t
## X-squared = 1.0401, df = 1, p-value = 0.3078

```

Burada elde edilen p değeri 0.3078 olduğundan Yokluk hipotezi reddedilemez ve değişkenlerin bağımsız olduğu söylenir.

4.3.5.2 Fisher Exact Testi

Fisher Exact testi ise *fisher.test()* fonksiyonu ile yapılır. Eğer sonucu bir değişkene aktarılırsa, değişken (htest türünde) liste olur. Fonksiyonun sonucunu bir değişkene aktarmazsanız, test sonucunu ekrana çıktı verecektir.

```
t <- table(nominal_veri$Enjeksiyon, nominal_veri$Uretici)
fisher.test(t,workspace = 2e07)
```

```
##
## Fisher's Exact Test for Count Data
##
## data:  t
## p-value = 0.000117
## alternative hypothesis: two.sided
```

Burada elde edilen p değeri 0.000117 olduğundan Yokluk hipotezi reddedilir ve değişkenler arasında bir ilişki olduğu söylenir.

4.3.5.3 İlişkinin Gücünün Belirlenmesi

Eğer, iki *nominal* değişken arasında ilişki bulduysanız bu ilişkinin ne kadar güçlü olduğunu belirlemek için Cramer değerini kullanabilirsiniz. Bu değer 2x2'lik tablolar için [-1, 1] aralığında, diğer tablolar için [0, 1] aralığında değer alır. Hesaplanan Cramer değeri 1'e ne kadar yakınsa ilişkinin o kadar güçlü olduğu söylenebilir. Cramer değerini elde edebilmek için R'in *vcd* paketinde yer alan *assocstats()* fonksiyonuna ihtiyacınız olacaktır. Bu paket R kurulumu ile beraber gelmez, onun yerine internetten indirip kurmanız gerekecektir.

```
install.packages('vcd')
```

Komut tamamlandığında artık bilgisayarınızda vcd paket hazır olacaktır. Bu aşamayı tamamladıktan sonra *assocstats()* fonksiyonu ile Cramer değerini elde edebilirsiniz.

```
library(vcd)

istatistik <- assocstats(t)

print(istatistik$cramer)
```

```
## [1] 0.526055
```

4.3.5.4 Karar Verme İşeminin Otomatize Edilmesi

R'ın bir programlama dili olmasının avantajlarından faydalanarak, test sonuçlarını sizin adınıza değerlendirmesini sağlayabilirsiniz. Bunun için *if* komutunu kullanmanız yeterli olacaktır. If komutunun yapısı aşağıdaki şekildedir.

```
if(Şart) {
  Şart Doğruysa Çalışacak Komutlar
} else {
  Şart Yanlıışsa Çalışacak Komutlar
}
```

Bağımsızlık testi için karar şartına bakacak olursanız, ilk olarak *chisq.test()* ile ki-kare testini gerçekleştirip p değerine göre karar verilebilir. Bunun için, *chisq.test()* fonksiyonunun çıktısını bir değişkene aktarmanız yeterli olacaktır. Bu değişken bir liste olup ki-kare testinin bütün çıktılarını içerir. Özellikle, *p.value* elemanı ki kare testinin p değerini içerir ve sadece bu elemana göre karar vermeniz yeterli olacaktır. Bu arada, bütün hipotez testlerinin sonucunda *p.value* değeri hesaplanır.

- NOT: Eğer vcd paketini kuramadıysanız, “library(vcd)”, “istatistik <- assocstats(t)” ve sonrasında ki satırı yazmasanız da olur.

```
library(vcd)

t <- table(nominal_veri$Enjeksiyon,nominal_veri$KapiSayisi)
test<-chisq.test(t)

if(test$p.value<0.05) {
  cat("Değişkenler arasında ilişki vardır.\n")
  istatistik <- assocstats(t)
  cat("İlişkinin derecesi ",istatistik$cramer," dir\n")
} else {
  cat("Değişkenler bağımsızdır.\n")
}
```

```
## Değişkenler bağımsızdır.
```

4.3.5.5 Hazır Paketler Kullanılması

Bütün bu adımları, *gmodels* paketinde yer alan *Crosstable* fonksiyonu ile gerçekleştirebilirsiniz. Eğer bilgisayarınızda *gmodels* paketi yüklü değilse, *install.packages* ile yükleyebilirsiniz. Aşağıdaki örneği inceleyin.

```
library(gmodels)
```

```
CrossTable(nominal_veri$KapiSayisi, nominal_veri$Enjeksiyon,
            chisq = TRUE, fisher = TRUE, mcnemar = TRUE,
            resid = TRUE, format = "SPSS")
```

```
##
##   Cell Contents
## |-----|
## |                Count |
## | Chi-square contribution |
## |                Row Percent |
## |                Column Percent |
## |                Total Percent |
## |                Residual |
## |-----|
##
## Total Observations in Table:  159
##
##                                | nominal_veri$Enjeksiyon
## nominal_veri$KapiSayisi |      std |      turbo | Row Total |
## -----|-----|-----|-----|
##                four |      76 |      19 |      95 |
##                |    0.104 |    0.510 |          |
##                |   80.000% |   20.000% |   59.748% |
##                |   57.576% |   70.370% |          |
##                |   47.799% |   11.950% |          |
##                |   -2.868 |    2.868 |          |
## -----|-----|-----|-----|
##                two |      56 |       8 |      64 |
##                |    0.155 |    0.757 |          |
##                |   87.500% |   12.500% |   40.252% |
##                |   42.424% |   29.630% |          |
##                |   35.220% |    5.031% |          |
##                |    2.868 |   -2.868 |          |
## -----|-----|-----|-----|
##                Column Total |      132 |      27 |      159 |
##                |   83.019% |   16.981% |          |
## -----|-----|-----|-----|
##
##
## Statistics for All Table Factors
##
##
```



```
## Pearson's Chi-squared test
## -----
## Chi^2 = 1.525758      d.f. = 1      p = 0.2167503
##
## Pearson's Chi-squared test with Yates' continuity correction
## -----
## Chi^2 = 1.040126      d.f. = 1      p = 0.3077922
##
##
## McNemar's Chi-squared test
## -----
## Chi^2 = 18.25333      d.f. = 1      p = 1.933872e-05
##
## McNemar's Chi-squared test with continuity correction
## -----
## Chi^2 = 17.28      d.f. = 1      p = 3.225641e-05
##
##
## Fisher's Exact Test for Count Data
## -----
## Sample estimate odds ratio: 0.5733641
##
## Alternative hypothesis: true odds ratio is not equal to 1
## p = 0.282677
## 95% confidence interval: 0.2019521 1.49281
##
## Alternative hypothesis: true odds ratio is less than 1
## p = 0.1538223
## 95% confidence interval: 0 1.306008
##
## Alternative hypothesis: true odds ratio is greater than 1
## p = 0.9285521
## 95% confidence interval: 0.2373441 Inf
##
##
##
## Minimum expected frequency: 10.86792
```

Burada *mcnemar* testi sadece 2x2'lik çapraz tablolar için kullanılmalıdır.

4.4 R Grafikleri

R programlama dili çok esnek bir grafik kütüphanesi ile birlikte gelmektedir. R'ın grafik kütüphanesini kullanabilmek için gerekli komutları inceleyelim.

4.4.1 Pasta Grafikleri


4.4.1.1 Temel Pasta Grafiği

Pasta grafikleri verinin yüzde olarak genel dağılımı hakkında bilgi verirler. R'da oluşturmaları için *pie* komutu yeterli olacaktır. Örneğin, araçların gövde türlerine göre dağılımını göstermek için aşağıdaki komutlar kullanılabilir.

```
t <- table(analiz_verisi$GovdeTuru)

etiketler <- names(t)

pie(t, etiketler)
```



4.4.1.2 Grafikte Görünecek Değerleri Belirlemek

Güzerinde yüzdeleri gösterip renklendirmeleri yan tarafta gösterelim.

```
# Yüzdeleri Hesaplayalım
etiketler <- round(100*t/sum(t),1)


# Değerlerin sonuna % sembolü ekleyelim
etiketler <- paste(etiketler, "%", sep = "")

# Renkleri Belirleyelim
renk <- rainbow(length(etiketler), start = 0.1, end = 0.8)

pie(t, main="Araba Gövdelerinin\nDağılımı", labels=etiketler,
    cex=0.7, col = renk)

legend("topright", cex=0.7, names(t), fill = renk)
```

Araba Gövdelerinin
Dağılımı



4.4.1.3 3-Boyutlu Pasta Grafiği

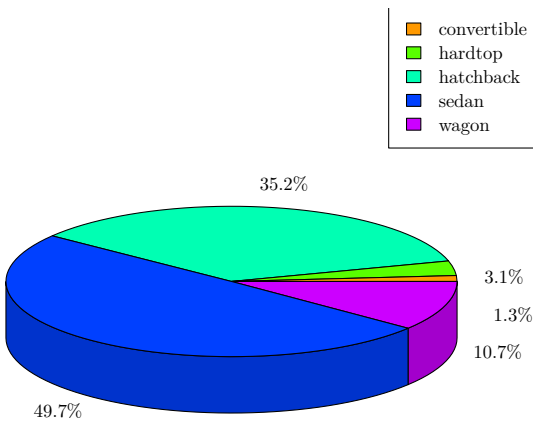
R ile 3 Boyutlu pasta grafiği çizebilmek için *plotrix* kütüphanesini kullanmalısınız. Bu kütüphanenin içerisinde bulunan *pie3D* fonksiyonu 3 boyutlu pasta grafikleri çizdirebilmeniz için yeterli olacaktır. Aşağıdaki kod bloğunu inceleyin.

```
library(plotrix)

pie3D(t, labels=etiketler, main="Araba Gövdelerinin\nDağılımı",
      col = renk, labelcex=0.7, radius = 0.8)

legend("topright", cex=0.7, names(t), fill = renk)
```

Araba Gövdelerinin
Dağılımı



4.4.1.4 Grafikleri PNG Olarak Kaydetmek

R ile oluşturacağınız grafikleri png olarak dosyalara kaydedebilirsiniz. Bunun için bir PNG dosya aygıtı oluşturup, grafiğinizi çizdirmeli ve işlem sonunda bu aygıtı kapatmalısınız. Aşağıdaki örneği inceleyin.

```
# PNG Dosyasını Oluşturalım...
png(filename = "Grafik1.png")

pie3D(t, labels=etiketler,
      main="Araba Gövdelerinin\nDağılımı",
      col = renk, labelcex=0.7, radius = 0.8)

legend("topright", cex=0.7, names(t), fill = renk)

# Dosyayı Kaydedelim.
dev.off()
```

4.4.1.5 Verideki Bütün Nominal Değerlerin 3B Pasta Grafiklerinin Oluşturulması

Bu işlem için basit bir for döngüsü yeterli olacaktır.

```
sutun_adlari <- names(nominal_veri)
for(i in 1:ncol(nominal_veri)) {
  t <- table(nominal_veri[,i])
  etiketler <- names(t)

  renk <- rainbow(length(etiketler), start = 0.1, end = 0.8)

  png(filename = paste("PastaGrafik_",sutun_adlari[i],".png", sep = ""))

  pie3D(t, labels = etiketler,
        main = paste(sutun_adlari[i],"\nDağılımı", sep = ""),
        col = renk, labelcex = 0.7, radius = 0.8)

  legend("topright", cex = 0.7, names(t), fill = renk)

  dev.off()
}
```

İstatistiksel Analize Hazırlık

5.1 Hipotez Testleri

Tanım 1 (Hipotez) *Bir konu ile ilgili varsayılan, ileri sürülen, doğruluğu kabul ediliyor olsa da ispat edilmemiş bilgiye **hipotez** denir.*

Tanım 2 (İstatistiksel Hipotez) *Karar verebilmek için öne sürülen, varsayılan ve geçerli olup olmadığına, belirlenen olasılıklarla karar verilecek sayısal bilgiye **İstatistiksel Hipotez** denir.*

İstatistiksel hipotez testleri ile yapılan için genel anlamı, anakütle ile ilgili doğruluğu kesin olmayan bir sayısal bilginin veya varsayımın, alınan örnekten elde edilen, tahmin edilen bilgi ile doğruluğunu incelemektir. Örnekten elde edilen bilgi ile anakütle hakkındaki varsayım arasında fark yoksa, test edilecek bir şey yoktur. Ancak, örnekten elde edilen bilgi ile anakütle hakkındaki varsayım arasında fark varsa, bu farkın anlamlı olup olmadığını belirleyebilmek için test işlemine gerek olacaktır. Yapılacak hipotez testi ile amaç, örnekten elde edilen bilgi ile anakütle hakkındaki varsayım arasındaki farkın, örnekten veya örneklemeden kaynaklanıp kaynaklanmadığını belirlemektir. Örneğin, bir sınıfın *İstatistiksel Yazılımlar* dersinden ortalamasının 80 olduğu iddia ediliyorsa ve bu sınıftan alınan 25 öğrencinin ortalaması da 78 olarak hesaplanmışsa, aradaki 2 birimlik farkın örneklemeden kaynaklanıp kaynaklanmadığını bulmak için hipotez testleri yapılmalıdır. Test sonucunda, aradaki farkın örneklemeden kaynaklanıp kaynaklanmadığına yani istatistiksel olarak anlamlı olup olmadığına karar verilir. Bu karar, α olasılık seviyesi ile verilir ve bu olasılığa *hata payı* veya *anlam seviyesi* adı verilir. Bu olasılığın, tümleyeni ise $(1 - \alpha)$ *güven olasılığı* olarak adlandırılır.

5.2 Hipotez Testinin Aşamaları

Hipotez Testleri ister parametrik ister parametrik olmayan test olsun, izlenecek adımlar birbirlerine çok benzerdir ve şöyle sıralanabilir.

- *Hipotezlerin Oluşturulması:* Bu aşamada iki hipotez oluşturulur ve kullanılacak testin parametrik mi, yoksa parametrik olmayan test mi olacağına karar verilir.

- *Hipotezlerden Birinin Kabul Kararı için Tablo Değerlerinin Belirlenmesi:* Bu aşamada testin çift yada tek taraflı oluşu, parametrik veya parametrik olmayan test oluşu dikkate alınarak belirlenen hata payı ile tablo değerleri bulunur. Yazılımlardan elde edilen **p** değeri bu amaçla kullanılır.
- *Test İstatistiğinin Hesaplanması:* Uygun test türü seçildiğinde, eldeki verinin özellikleri de göz önüne alınarak test istatistiği hesaplanır. Genellikle paket programlar bu değeri otomatik olarak hesaplarlar.
- *Kabul Kararı Verilmesi:* Hesaplanan test istatistiği ile tablo değerleri karşılaştırılarak, kurulan hipotezlerden biri kabul diğeri reddedilir.

Hipotez testinin ilk aşaması iki adet hipotezin kurulması ile başlar, bunlar H_0 (yokluk hipotezi, temel hipotez, sıfır hipotezi) ve H_1 (alternatif hipotez, karşıt hipotez) hipotezleridir. Burada önemli olan H_1 hipotezinin yönüdür. H_1 hipotezi tek yanlı veya çift yanlı olarak kurulabilir. Çift yanlı H_1 eşit olmamayı, tek yanlı hipotez büyük veya küçük olmayı ifade eder. Yukarıdaki örnek ile ilgili kurulan örnek hipotezler aşağıdaki gibi olabilir.

- İki yanlı hipotez

$$H_0 : \mu = 80$$

$$H_1 : \mu \neq 80$$

- Tek yanlı hipotez

$$H_0 : \mu = 80$$

$$H_1 : \mu < 80$$

Hipotez testleri sonucunda 4 adet durum söz konusudur bunlar aşağıdaki tabloda belirtilmiştir.

	H_0 Kabul	H_1 Kabul
H_0 Doğru	Doğru Karar	I. Tip Hata veya α hatası
H_1 Doğru	II. Tip Hata veya β hatası	Doğru Karar

5.3 Normallik Testleri

Hipotez testlerinin en önemli aşamalarından biri de kullanılacak teste karar verilmesi aşamasıdır. Burada iki alternatifiniz bulunmaktadır; Parametrik Testler ve Parametrik Olmayan Testler. Parametrik testlerin uygulanabilmesi için örnekleme dağılımının *Normal Dağılım*, *t-Dağılımı* olması veya *Normal Dağılım* olarak kabul edilebilmesi gereklidir. Bir örneklemin, normal olup olmadığı veya normal kabul edilip edilemeyeceğine, normal dağılımın özelliklerine bakılarak veya istatistiksel olarak bakılarak karar verilebilir. Bir örneklemin normal dağılıma sahip olup olmadığına karar verebilmek için aşağıdaki özelliklerine bakabilirsiniz.

- Verinin dağılımı çan eğrisine benzer

- Aritmetik ortalama, mod ve medyan birbirine eşittir
- Normal dağılımın belirli oranları, standart aralıklarda yer alır
- Basıklık (α_3) ve çarpıklık (α_4) ölçüleri sırasıyla 0 ve 3 değerini alır


Bu özellikleri bir örnekte deneyelim. Önce örnek histogramına bakalım.

```
veri = read.csv2('wine.csv', row.names = NULL)
sayisal.sutunlar = sapply(veri, class) != 'factor'
sayisal.veri = veri[,sayisal.sutunlar]

v = sayisal.veri$Alcohol

ort = mean(v)
ssapma = sqrt(var(v))


hist(v, probability = TRUE, xlab = "Alkol Oranı",
     main = "Alkol Histogramı", ylim = c(0,0.5))
curve(dnorm(x, mean = ort, sd = ssapma),
      col = "darkblue", lwd=2, add = TRUE)
```



Şimdide QQ grafiğini inceleyelim.

```
qqnorm(v)
qqline(v)
```

Normal Q-Q Plot



Aritmetik ortalama, mod ve medyanın durumlarını inceleyelim.

```
ort<-mean(v)
medyan<-median(v)
t <- table(v)
mod<-t[which.max(t)]

cat("Ortalama=",ort,"\nMedyan=",medyan,"\nMod=",names(mod))

## Ortalama= 13.00062
## Medyan= 13.05
## Mod= 12.37
```

Basıklık ve Çarpıklık ölçülerini inceleyelim. (Moments paketi bilgisayarınızda olmayabilir, yüklemeniz gerekebilir)

```
library(moments)

carpiklik = skewness(v)
basiklik = kurtosis(v)

cat("Çarpıklık = ",carpiklik,"\nBasıklık = ",basiklik)

## Çarpıklık = -0.05148233
## Basıklık = -0.8524996
```


Bu değerlere göre, verinizin normal olduğu kanısına varabilirsiniz, fakat bu işlemin daha doğrusu verinizin normalliğini istatistiksel olarak test etmenizdir. Bunun için iki adet istatistiksel test kullanılır. Bunlar, Kolmogorov-Smirnov testi ve Shapiro-Wilk Testidir.

5.3.1 Kolmogorov-Smirnov Testi

Bu test, parametrik olmayan bir testtir ve temeli incelenen örneklem dağılımının birikimli olasılık yoğunluk fonksiyonunun, herhangi bir sürekli dağılımın olasılık yoğunluk fonksiyonu ile karşılaştırılmasına dayanır. Bu testin yokluk ve alternatif hipotezleri aşağıdaki gibidir.

H_0 :	Dağılım İstenilen Sürekli Dağılımdır
H_1 :	Dağılım İstenilen Sürekli Dağılım Değildir

Kullanılan test istatistiği ise;

$$D = \max_{1 \leq i \leq N} \left| F(Y_i) - \frac{i}{N} \right|$$

Burada, F sürekli dağılımın olasılık yoğunluk fonksiyonu, Y_i i. gözlem değeri, N eleman sayısıdır. Burada, teorik dağılımın parametreleri örnekleme dağılımından hesaplanarak elde edilir. Kolmogorov-Smirnov testi genel amaçlı bir test olmasına rağmen burada ilgilenilen dağılımın normal dağılım olup olmadığını test etmek amacı ile kullanılacaktır. Dolayısıyla, burada F fonksiyonu normal dağılımın olasılık yoğunluk fonksiyonu olacaktır. Şimdi, verinin normal dağılıma sahip olup olmadığına bakalım.

```
test <- ks.test(v, 'pnorm')
if(test$p.value<0.05) {
  cat('Dağılım Normal Dağılım Değildir (p=',test$p.value,")")
} else {
  cat('Dağılım Normal Dağılımdır (p=',test$p.value,")")
}
```

```
## Dağılım Normal Dağılım Değildir (p= 0 )
```

Buradaki verinin standart normal dağılıma sahip olduğu test edilmektedir, yani $v \sim N(0, 1)$. Bu sebeple, Kolmogorov-Smirnov testinin teorik dağılımlarının parametre tahminlerini kullanan hali olan Lilliefors testinin kullanılması önerilmektedir (Eğer teorik dağılımın parametreleri biliniyorsa, Kolmogorov-Smirnov testinin kullanılmasında bir sorun bulunmamaktadır). Burada amaç, değişkenin normalliği olduğu için, Lilliefors testinin kullanılması daha doğru olacaktır. Aşağıdaki komutlar ile Lilliefors testi gerçekleştirilebilir.

```
library(nortest)
test <- lillie.test(v)
if(test$p.value<0.05) {
  cat('Dağılım Normal Dağılım Değildir (p=',
      test$p.value,")\n")
}
```

```


} else {
  cat('Dağılım Normal Dağılımdır (p=',
      test$p.value,")\n")
}

```

```
## Dağılım Normal Dağılım Değildir (p= 0.04404785 )
```

İsterseniz bu durumu grafik ile de inceleyelim.

Alkol Değişkeninin Olasılık Yoğunluk Fonksiyonu



Bu yaptıklarımızı, bütün değişkenlere uygulayalım.

```

degisken.isimleri = names(sayisal.veri)
for(i in 1:ncol(sayisal.veri)) {
  degisken = sayisal.veri[,i]
  degisken.adi = degisken.isimleri[i]

  test <- lillie.test(degisken)
  if(test$p.value<0.05) {
    cat(degisken.adi,' dağılımı Normal Dağılım Değildir (p=',
        test$p.value,")\n")
  } else {
    cat(degisken.adi,' dağılımı Normal Dağılımdır (p=',
        test$p.value,")\n")
  }
}

```

```
## Class dağılımı Normal Dağılım Değildir (p= 3.47753e-23 )
## Alcohol dağılımı Normal Dağılım Değildir (p= 0.04404785 )
## Malic.Acid dağılımı Normal Dağılım Değildir (p= 1.555976e-17 )
## Ash dağılımı Normal Dağılımdır (p= 0.1446116 )
## Aash dağılımı Normal Dağılımdır (p= 0.07713065 )
## Magnesium dağılımı Normal Dağılım Değildir (p= 0.001403261 )
## TotPhenol dağılımı Normal Dağılım Değildir (p= 0.02491662 )
## Flavonoids dağılımı Normal Dağılım Değildir (p= 0.003005415 )
## Nphenols dağılımı Normal Dağılım Değildir (p= 5.543312e-06 )
## Proant dağılımı Normal Dağılımdır (p= 0.174296 )
## Color dağılımı Normal Dağılım Değildir (p= 0.001162927 )
## Hue dağılımı Normal Dağılımdır (p= 0.08829705 )
## OD280 dağılımı Normal Dağılım Değildir (p= 3.304797e-06 )
## Proline dağılımı Normal Dağılım Değildir (p= 1.205789e-07 )
```

5.3.2 Shapiro-Wilk Testi

Bu test de verinin normalliği için kullanılan testlerden biridir, hatta yapılan çalışmalar ışığında bu testin gücünün Kolmogorov-Smirnov testinin gücünden daha fazla olduğu bulunmuştur. Uygulamada genellikle iki testin sonucuna da bakılır. İki test sonucunun farklı olması durumunda, Shapiro-Wilk testinin sonucunun kullanılması tavsiye edilir. Bu testin hipotezleri de Kolmogorov-Smirnov testi ile aynıdır. Fakat hesaplanan istatistik aşağıdaki gibidir.

$$W = \frac{(\sum_{i=1}^m a_i (x_{n+1-i} - x_i))^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Burada m eleman sayısı çift ise $\frac{n}{2}$, tek ise $\frac{(n-1)}{2}$; a_i ise teorik dağılımdan elde edilen sıra istatistikleridir. Bu testin R ile uygulanması aşağıdaki gibi olur.

```
test<-shapiro.test(v)
if(test$p.value<0.05) {
  cat('Dağılım Normal Dağılım Değildir (p=',test$p.value,")\n")
} else {
  cat('Dağılım Normal Dağılımdır (p=',test$p.value,")\n")
}
```

```
## Dağılım Normal Dağılım Değildir (p= 0.02004798 )
```

Bu yaptıklarımızı, bütün değişkenlere uygulayalım.

```
degisken.isimleri = names(sayisal.veri)
for(i in 1:ncol(sayisal.veri)) {
  degisken = sayisal.veri[,i]
  degisken.adi = degisken.isimleri[i]
```

```

test <- shapiro.test(degisken)
if(test$p.value<0.05) {
  cat(degisken.adi, ' dağılımı Normal Dağılım Değildir (p=',
      test$p.value,")\n")
} else {
  cat(degisken.adi, ' dağılımı Normal Dağılımdır (p=',
      test$p.value,")\n")
}
}

## Class dağılımı Normal Dağılım Değildir (p= 3.52658e-14 )
## Alcohol dağılımı Normal Dağılım Değildir (p= 0.02004798 )
## Malic.Acid dağılımı Normal Dağılım Değildir (p= 2.945801e-10 )
## Ash dağılımı Normal Dağılım Değildir (p= 0.03868278 )
## Aash dağılımı Normal Dağılımdır (p= 0.2638688 )
## Magnesium dağılımı Normal Dağılım Değildir (p= 6.345694e-07 )
## TotPhenol dağılımı Normal Dağılım Değildir (p= 0.004395305 )
## Flavanoids dağılımı Normal Dağılım Değildir (p= 1.678853e-05 )
## Nphenols dağılımı Normal Dağılım Değildir (p= 0.00010551 )
## Proant dağılımı Normal Dağılım Değildir (p= 0.01445402 )
## Color dağılımı Normal Dağılım Değildir (p= 9.22921e-07 )
## Hue dağılımı Normal Dağılım Değildir (p= 0.0174255 )
## OD280 dağılımı Normal Dağılım Değildir (p= 2.316064e-06 )
## Proline dağılımı Normal Dağılım Değildir (p= 1.74126e-07 )

```

5.3.3 Veri Düzeltmesi

Eğer verinizdeki bazı değişkenler normal dağılıma sahip değilse, bazı dönüşümler yardımı ile bu değişkenleri normalleştirmeyi deneyebilirsiniz. Buradaki kural, sağa çarpık değişkenlerin karekök veya logaritma fonksiyonları ile, sola çarpık değişkenlerin üstel (e^{-x}) veya $\frac{1}{x}$ fonksiyonu ile normal dağılıma dönüşebilmeleridir. Şimdi, bu ifadelerin R ile uygulamasına bakalım.

```

degisken.isimleri = names(sayisal.veri)
for(i in 1:ncol(sayisal.veri)) {
  degisken = sayisal.veri[,i]
  degisken.adi = degisken.isimleri[i]

  degisken = degisken[!is.na(degisken)]

  test <- shapiro.test(degisken)
  if(test$p.value<0.05) {

    log.d = log(degisken)
    log.test = shapiro.test(log.d)

```

```
if(!is.nan(log.test$p.value)) {
  if(log.test$p.value>0.05) {
    cat(degisken.adi," log dönüşümü ile normal dağılıma sahiptir (p=",
      log.test$p.value,")\n")
    next
  }
}

sqrt.d = sqrt(degisken)
sqrt.test = shapiro.test(sqrt.d)
if(!is.nan(sqrt.test$p.value)) {
  if(sqrt.test$p.value>0.05) {
    cat(degisken.adi," karekök dönüşümü ile normal dağılıma sahiptir(p=",
      sqrt.test$p.value,")\n")
    next
  }
}

ustel.d = exp(-degisken)
ustel.test = shapiro.test(ustel.d)
if(!is.nan(ustel.test$p.value)) {
  if(ustel.test$p.value>0.05) {
    cat(degisken.adi," üstel dönüşümü ile normal dağılıma sahiptir (p=",
      ustel.test$p.value,")\n")
    next
  }
}

bx.d = 1/degisken
bx.test = shapiro.test(bx.d)
if(!is.nan(bx.test$p.value)) {
  if(bx.test$p.value>0.05) {
    cat(degisken.adi," 1/x dönüşümü ile normal dağılıma sahiptir (p=",
      bx.test$p.value,")\n")
    next
  }
}

cat(degisken.adi,' dağılımı Normal Dağılım Değildir (p=',
  test$p.value,")\n")
} else {
  cat(degisken.adi,' dağılımı Normal Dağılımdır (p=',
    test$p.value,")\n")
}
```

}

```
## Class dağılımı Normal Dağılım Değildir (p= 3.52658e-14 )
## Alcohol dağılımı Normal Dağılım Değildir (p= 0.02004798 )
## Malic.Acid dağılımı Normal Dağılım Değildir (p= 2.945801e-10 )
## Ash dağılımı Normal Dağılım Değildir (p= 0.03868278 )
## Aash dağılımı Normal Dağılımdır (p= 0.2638688 )
## Magnesium 1/x dönüşümü ile normal dağılıma sahiptir (p= 0.3556347 )
## TotPhenol dağılımı Normal Dağılım Değildir (p= 0.004395305 )
## Flavanoids dağılımı Normal Dağılım Değildir (p= 1.678853e-05 )
## Nphenols dağılımı Normal Dağılım Değildir (p= 0.00010551 )
## Proant karekök dönüşümü ile normal dağılıma sahiptir (p= 0.6160586 )
## Color log dönüşümü ile normal dağılıma sahiptir (p= 0.2456765 )
## Hue dağılımı Normal Dağılım Değildir (p= 0.0174255 )
## OD280 dağılımı Normal Dağılım Değildir (p= 2.316064e-06 )
## Proline dağılımı Normal Dağılım Değildir (p= 1.74126e-07 )
```

5.4 Dağılım Testleri

5.4.1 Rastsallık Testi

Test edeceğimiz hipotez ister parametrik ister parametrik olmayan bir test olsun, verinizin rast-sallığından emin olmalısınız. Bu durum için kullanabileceğiniz parametrik olmayan bir test mevcuttur. Wald-Wolfowitz Runs Testi bir verinin rastsallığını istatistiksel olarak belirlemek için kullanılabilir. Testi kullanabilmeniz için ilk olarak verinizi belirli bir sırada sıralamanız gerekmektedir. Örneğin, zamana göre bir anket yaptığınızda, elde ettiğiniz verilerin zaman alanına göre rastsal olması beklenmektedir. Bu sebeple, verinizin rastsallığını ölçmeden önce rastsallık için belirleyeceğimiz bir ölçüte göre sıralama yapıp, rastsallığı bu şekilde ölçmeniz gerekmektedir. Bu özelliği ile sadece kısıtlı miktarda verilere uygulanması söz konusudur.

Wald-Wolfowitz testi için test istatistiği aşağıdaki şekilde hesaplanır. Sıralı veri, bir değere göre (genellikle medyan veya ortalama) değerlendirilir ve bu değerden yüksek elemanlar +, düşük elemanlar - olarak işaretlenir. Aynı işaretlerin kümesine Run adı verilir. Örneğin, 22 elemanlık bir dizideki elemanların değerlendirmesi “++++- - -++++- - - -” şeklindeyse, bu veride 6 adet run bulunmaktadır ve bunlardan üçü + üçü de - run dır. Testin varsayımı, verinin runlarının dağılımının aşağıdaki parametrelerle normal dağılıma sahip olmasıdır.

$$\mu = \frac{2N_-N_+}{N} + 1$$

$$\sigma^2 = \frac{2N_-N_+(2N_-N_+ - N)}{N^2(N-1)} = \frac{(\mu-1)(\mu-2)}{N-1}$$

Bu testin hipotezleri aşağıdaki gibidir.

H_0 :	Değişken, mevcut sırasıyla rastsaldır.
H_1 :	Değişken, mevcut sırasıyla rastsal değildir.

Runs testinin R ile gerçekleştirilebilmesi için, verinizin önce sıralanması ve randtest kütüphanesinde yüklenmesi gerekmektedir.

```
library(randtests)
# Önce Proline'ın sıra bilgisi oluşturulur
proline.sira = order(sayisal.veri$Proline)
# Sonra bu sıra bilgisi Alchol'e uygulanır
degisken = sayisal.veri$Alcohol[proline.sira]
# Ve test gerçekleştirilir
test = runs.test(degisken)

if(test$p.value<0.05) {
  cat("Alkol proline'a göre rastsal değildir (p=",test$p.value,")\n")
} else {
  cat("Alkol proline'a göre rastsaldır (p=",test$p.value,")\n")
}
```

Alkol proline'a göre rastsal değildir (p= 2.135012e-06)

Bütün sayısal değişkenlerin birbirlerine göre rastsalılığı ise aşağıdaki gibi olacaktır.

	Clas	Alco	Mali	Ash	Aash	Magn	TotP	Flav	Nphe	Proa	Colo	Hue	OD28	Prol
Class		-	-	+	-	-	-	-	-	-	-	-	-	-
Alcohol	+		+	+	+	+	+	+	+	-	-	+	+	-
Malic.Acid	-	-		+	-	+	-	-	+	-	+	-	+	+
Ash	+	+	+		+	+	-	+	+	+	-	+	+	+
Aash	-	-	+	+		+	-	-	-	-	-	-	-	-
Magnesium	+	-	+	+	+		+	+	+	+	-	+	+	-
TotPhenol	-	-	+	+	-	+		-	-	-	-	-	-	-
Flavanoids	-	-	+	+	+	+	-		-	-	-	-	-	-
Nphenols	-	-	-	+	-	+	-	-		+	-	-	-	-
Proant	-	+	-	+	+	+	-	-	-		-	-	-	-
Color	-	-	+	+	+	+	-	+	+	+		-	+	-
Hue	-	+	-	+	-	+	-	-	+	+	-		-	-
OD280	-	+	+	+	+	+	-	-	-	-	-	-		+
Proline	-	-	+	+	-	-	-	-	-	-	-	-	-	

5.4.2 Varyans Homojenliği Testi

Araştırmanızda iki farklı örneklemin karşılaştırılması isteniyorsa, bu örneklerin dağılımlarının sadece normal dağılım olması yeterli değildir. Ayrıca, değişkenlerin varyanslarının Homojen (eşit) olmasıda beklenmektedir. Örneklerin varyanslarını test edebilmek için, Levene testini kullanmanız gerekmektedir. Test istatistiği, aşağıdaki gibidir.

$$W = \frac{(N-k)}{(k-1)} \frac{\sum_{i=1}^k N_i (Z_{i.} - Z_{..})^2}{\sum_{i=1}^k \sum_{j=1}^{N_i} (Z_{ij} - Z_{i.})^2}$$

Bu testin, hipotezleri aşağıdaki gibidir.

H_0 :	Değişkenlerin varyansları homojendir.
H_1 :	Değişkenlerin varyansları homojen değildir.

Bu testi, R ile kullanabilmeniz için iki ayrı verinin birleştirip tek veri haline getirmeniz ve bu verideki elemanların hangi örnekleme ait olduğunu gösteren bir factor değişkeni oluşturmanız gerekmektedir. Aşağıdaki örneği inceleyin.

```
library(car)

degisken1 = sayisal.veri$Alcohol
degisken2 = sayisal.veri$Malic.Acid

birlestirilmis.degisken = c(degisken1, degisken2)

degisken1.uzunluk = length(degisken1)
degisken2.uzunluk = length(degisken2)

degisken1.belirtec = rep(1, degisken1.uzunluk)
degisken2.belirtec = rep(2, degisken2.uzunluk)

degisken.bileske.belirtec = c(degisken1.belirtec, degisken2.belirtec)

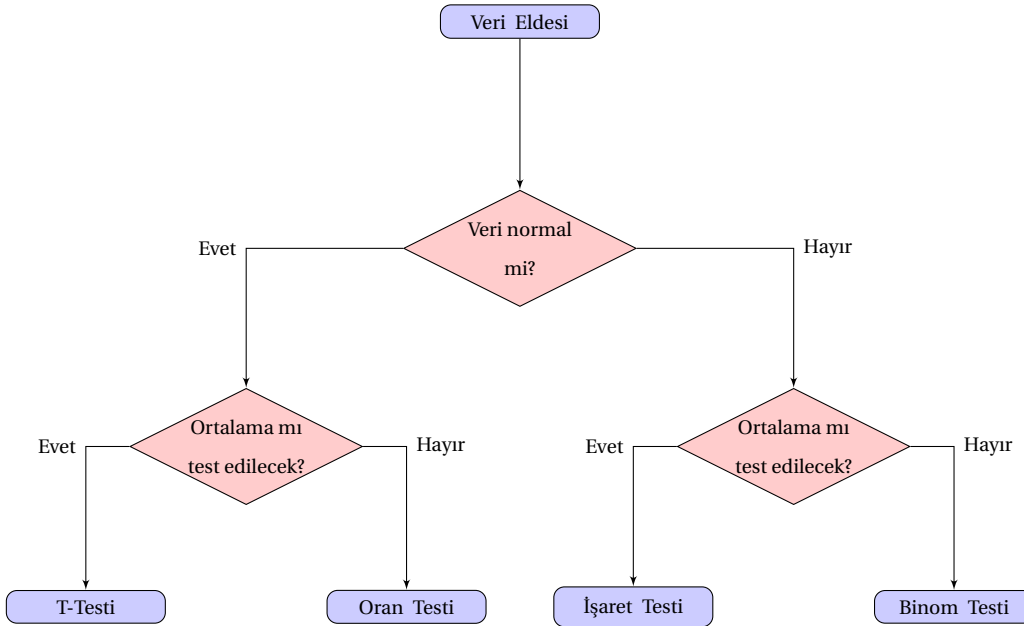
test = leveneTest(birlestirilmis.degisken, degisken.bileske.belirtec)
p.degeri = test$`Pr(>F)`[1]

if(p.degeri<0.05) {
  cat("Alkol ve Malik asitin varyansları homojen değildir (p=",
      p.degeri,")\n")
} else {
  cat("Alkol ve Malik asitin varyansları homojendir (p=",
      p.degeri,")\n")
}

## Alkol ve Malik asitin varyansları homojen değildir (p= 0.03568517 ).
```


Tek Örnek Testleri

Anakütle ortalaması veya oranı için ortaya atılan hipotezlerin gerçekliğinin incelenmesi için kullanılan testlerdir. Bu testlerin uygulanması için aşağıdaki adımlar kullanılmalıdır.



6.1 Parametrik Testler

6.1.1 Ortalamaların Testi

Bu test ile anakütle ortalaması μ ile ilgili bilinen veya ileri sürülen μ_0 ile örneklemden elde edilen \bar{X} arasındaki farkın istatistiksel olarak anlamlı olup olmadığı değerlendirilir.

Ortalaması μ , varyansı σ^2 olduğu iddia edilen bir anakütleden n elemanlı bir örneklem çekilmiş olsun. Çekilen örneklem, ortalaması \bar{X} ve varyansı da S^2 olarak bulunmuş olsun. Bu durumda aşağıdaki hipotezler kurulabilir.

$H_0 :$	$\mu = \mu_0$
$H_1 :$	$\mu \neq \mu_0$ (Çift Yanlı)
$H_1 :$	$\mu < \mu_0$ (Tek Yanlı)
$H_1 :$	$\mu > \mu_0$ (Tek Yanlı)

Burara Anakütlenin varyansı bilinmediği için t-Dağılımı kullanılacaktır. Test istatistiği aşağıdaki gibi hesaplanır.

$$t = \frac{\bar{x} - \mu_0}{\sigma_{\bar{x}}}$$

Eğer anakütle ortalaması biliniyorsa - ki bu durumda normal dağılım testi de kullanabilirsiniz - $\sigma_{\bar{x}}$ aşağıdaki gibi hesaplanır.

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Ancak anakütle standart sapması bilinemeyeceğinden, σ nın S tamin edicisi kullanılır.

$$S^2 = \frac{\sum (c - \bar{x})^2}{n - 1}$$

$$S^2 = \frac{n\tilde{\sigma}^2}{n - 1}$$

Burada elde edilecek olan **p** değeri α değerinden küçükse H_0 hipotezi, aksi durumda H_1 hipotezi reddedilir. Şimdi Bu testi R ile uygulayalım. Örnek olarak parkinson verisindeki Fo alanının ortalamasının 150 olup olmadığını test edelim.

```
veri = read.csv2('parkinsons.csv')
test = t.test(veri$Fo, alternative = "two.sided", mu = 150)
if(test$p.value<0.05) {
  cat("Fo alanının ortalaması 150 değildir p=",test$p.value)
} else {
  cat("Fo alanının ortalaması 150 dir p=",test$p.value)
}
```

```
## Fo alanının ortalaması 150 dir p= 0.1552838
```

Şimdi de Fo alanının ortalamasının 160'tan büyük veya küçük olması hipotezlerini test edelim.

```
test = t.test(veri$Fo, alternative = "greater", mu = 160)
if(test$p.value<0.05) {
  cat("Fo alanının ortalaması 160'tan büyüktür p=",test$p.value)
} else {
  cat("Fo alanının ortalaması 160'tan büyük değildir dir p=",test$p.value)
}
```

```
## Fo alanının ortalaması 160'tan büyük değildir dir p= 0.9735198
```

```
test = t.test(veri$Fo, alternative = "less", mu = 160)
if(test$p.value<0.05) {
  cat("Fo alanının ortalaması 160'tan küçüktür p=",test$p.value)
} else {
  cat("Fo alanının ortalaması 160'tan küçük değildir dir p=",test$p.value)
}
```

```
## Fo alanının ortalaması 160'tan küçüktür p= 0.02648018
```

6.1.2 Oranların Testi

Bu test aracılığı ile örnekleminizi kullanarak ana kütlede yer alan bilgilerin birbirlerine olan oranlarını test edebilirsiniz. Örneğin, bir doktorun trafik kazası geçirmiş hastaların hayatta kalma oranının %75 olduğunu iddiasının test etmek için kullanabilirsiniz. Bu testin varsayımı, uğraştığınız veri kümesinin eleman sayısının yüksek olmasıdır (genel kanı bildiğiniz gibi $N > 30$ olmasıdır). Bu durumda binom dağılımı normal dağılıma yaklaşacağından aşağıdaki test istatistiği kullanılabilir.

$$z = \frac{p_0 - p_e}{\sqrt{\frac{p_0 q}{n}}}$$

Oran testi için kurulacak yokluk hipotezi aşağıdaki gibidir.

$$H_0 : p_0 = p_e$$

Oran testi R ile aşağıdaki şekilde gerçekleştirilir.

```
kurtulanlar = c(3224)
toplam.hasta = c(3406)

test = prop.test(kurtulanlar, toplam.hasta, p=0.75)

if(test$p.value < 0.05) {
  cat("Trafik kazalarından kurtulanların oranı %75 değildir p=",test$p.value)
} else {
  cat("Trafik kazalarından kurtulanların oranı %75'tir p=", test$p.value)
}
```

```
## Trafik kazalarından kurtulanların oranı %75 değildir p= 1.983575e-154
```

```
test
```

```
##
## 1-sample proportions test with continuity correction
##
## data: kurtulanlar out of toplam.hasta, null probability 0.75
## X-squared = 700.82, df = 1, p-value < 2.2e-16
## alternative hypothesis: true p is not equal to 0.75
## 95 percent confidence interval:
## 0.9383400 0.9537641
## sample estimates:
## p
## 0.9465649
```

```
test = prop.test(kurtulanlar, toplam.hasta, p=0.75, alternative = "g")

if(test$p.value < 0.05) {
  cat("Trafik kazalarından kurtulanların oranı %75'ten büyüktür p=",test$p.value)
} else {
  cat("Trafik kazalarından kurtulanların oranı %75'tir p=", test$p.value)
}
```

```
## Trafik kazalarından kurtulanların oranı %75'ten büyüktür p= 9.917876e-155
```

```
test
```

```
##
## 1-sample proportions test with continuity correction
##
## data: kurtulanlar out of toplam.hasta, null probability 0.75
## X-squared = 700.82, df = 1, p-value < 2.2e-16
## alternative hypothesis: true p is greater than 0.75
## 95 percent confidence interval:
## 0.9397096 1.0000000
## sample estimates:
## p
## 0.9465649
```

```
test = prop.test(kurtulanlar, toplam.hasta, p=0.75, alternative = "l")

if(test$p.value < 0.05) {
  cat("Trafik kazalarından kurtulanların oranı %75'ten küçüktür p=",test$p.value)
} else {
  cat("Trafik kazalarından kurtulanların oranı %75'tir p=", test$p.value)
}
```

```
## Trafik kazalarından kurtulanların oranı %75'tir p= 1

test

##
## 1-sample proportions test with continuity correction
##
## data: kurtulanlar out of toplam.hasta, null probability 0.75
## X-squared = 700.82, df = 1, p-value = 1
## alternative hypothesis: true p is less than 0.75
## 95 percent confidence interval:
##  0.0000000 0.9526949
## sample estimates:
##           p
## 0.9465649
```

6.2 Parametrik Olmayan Testler

6.2.1 Wilcoxon İşaretli Sıra Sayıları Testi

Normal dağılıma sahip olmayan anakütlelerin ortalamaları ile ilgili hipotezlerin test edilmesi amacıyla kullanılır. Burada merkezi dağılım ölçüsü olarak ortalama yerine, dağılımın uç değerlerinden ve çarpıklığından daha az etkilendiği için **medyan** kullanılır. Medyan hesaplandıktan sonra bütün değerlerden medyan çıkartılarak oluşan farkların işaret sayıları belirlenir. Test istatistiği hesaplanırken, bulunan işaretlerin sayıları kullanılır. H_0 hipotezinin kabul edilebilmesi için işaret sayılarının $p=0.5$ olan Binom Dağılımına sahip olması beklenmektedir. Hipotezler, t-Testindeki gibi kurulur.

R ile Wilcoxon testinin gerçekleştirilmesi aşağıdaki şekilde yapılır (Örnek olması açısından, t-Testi ile aynı değişken kullanılmıştır, normalde uygun değişken seçimi yapılmalıdır).

```
test = wilcox.test(veri$Fo, alternative = "two.sided", mu = 150)
if(test$p.value<0.05) {
  cat("Fo alanının ortalaması 150 değildir p=",test$p.value)
} else {
  cat("Fo alanının ortalaması 150 dir p=",test$p.value)
}
```

```
## Fo alanının ortalaması 150 dir p= 0.5459381
```

```
test = wilcox.test(veri$Fo, alternative = "greater", mu = 160)
if(test$p.value<0.05) {
  cat("Fo alanının ortalaması 160'tan büyüktür p=",test$p.value)
} else {
```

```
cat("Fo alanının ortalaması 160'tan büyük değildir p=",test$p.value)
}
```

```
## Fo alanının ortalaması 160'tan büyük değildir p= 0.9914166
```

```
test = wilcox.test(veri$Fo, alternative = "less", mu = 160)
if(test$p.value<0.05) {
  cat("Fo alanının ortalaması 160'tan küçüktür p=",test$p.value)
} else {
  cat("Fo alanının ortalaması 160'tan küçük değildir p=",test$p.value)
}
```

```
## Fo alanının ortalaması 160'tan küçüktür p= 0.008612979
```

6.2.2 Binom Testi

Binom testi, oran testinin parametrik olmayan halidir ve eleman sayısı küçük olduğunda kullanılması tavsiye edilir ($N < 30$). Hipotezleri oran testi ile aynıdır. Bu testin R ile uygulanması aşağıdaki gibi olacaktır.

```
kurtulanlar = c(28)
toplam.hasta = c(30)

test = binom.test(kurtulanlar, toplam.hasta, p=0.75)

if(test$p.value < 0.05) {
  cat("Trafik kazalarından kurtulanların oranı %75 değildir p=",test$p.value)
} else {
  cat("Trafik kazalarından kurtulanların oranı %75'tir p=", test$p.value)
}
```

```
## Trafik kazalarından kurtulanların oranı %75 değildir p= 0.01877506
```

```
test
```

```
##
## Exact binomial test
##
## data: kurtulanlar and toplam.hasta
## number of successes = 28, number of trials = 30, p-value = 0.01878
## alternative hypothesis: true probability of success is not equal to 0.75
## 95 percent confidence interval:
## 0.7792646 0.9918219
## sample estimates:
```

```
## probability of success
##          0.9333333
```

```
test = binom.test(kurtulanlar, toplam.hasta, p=0.75, alternative = "g")

if(test$p.value < 0.05) {
  cat("Trafik kazalarından kurtulanların oranı %75'ten büyüktür p=",test$p.value)
} else {
  cat("Trafik kazalarından kurtulanların oranı %75'tir p=", test$p.value)
}
```

```
## Trafik kazalarından kurtulanların oranı %75'ten büyüktür p= 0.01059587
```

```
test
```

```
##
## Exact binomial test
##
## data: kurtulanlar and toplam.hasta
## number of successes = 28, number of trials = 30, p-value = 0.0106
## alternative hypothesis: true probability of success is greater than 0.75
## 95 percent confidence interval:
##  0.804674 1.000000
## sample estimates:
## probability of success
##          0.9333333
```

```
test = binom.test(kurtulanlar, toplam.hasta, p=0.75, alternative = "l")

if(test$p.value < 0.05) {
  cat("Trafik kazalarından kurtulanların oranı %75'ten küçüktür p=",test$p.value)
} else {
  cat("Trafik kazalarından kurtulanların oranı %75'tir p=", test$p.value)
}
```

```
## Trafik kazalarından kurtulanların oranı %75'tir p= 0.9980356
```

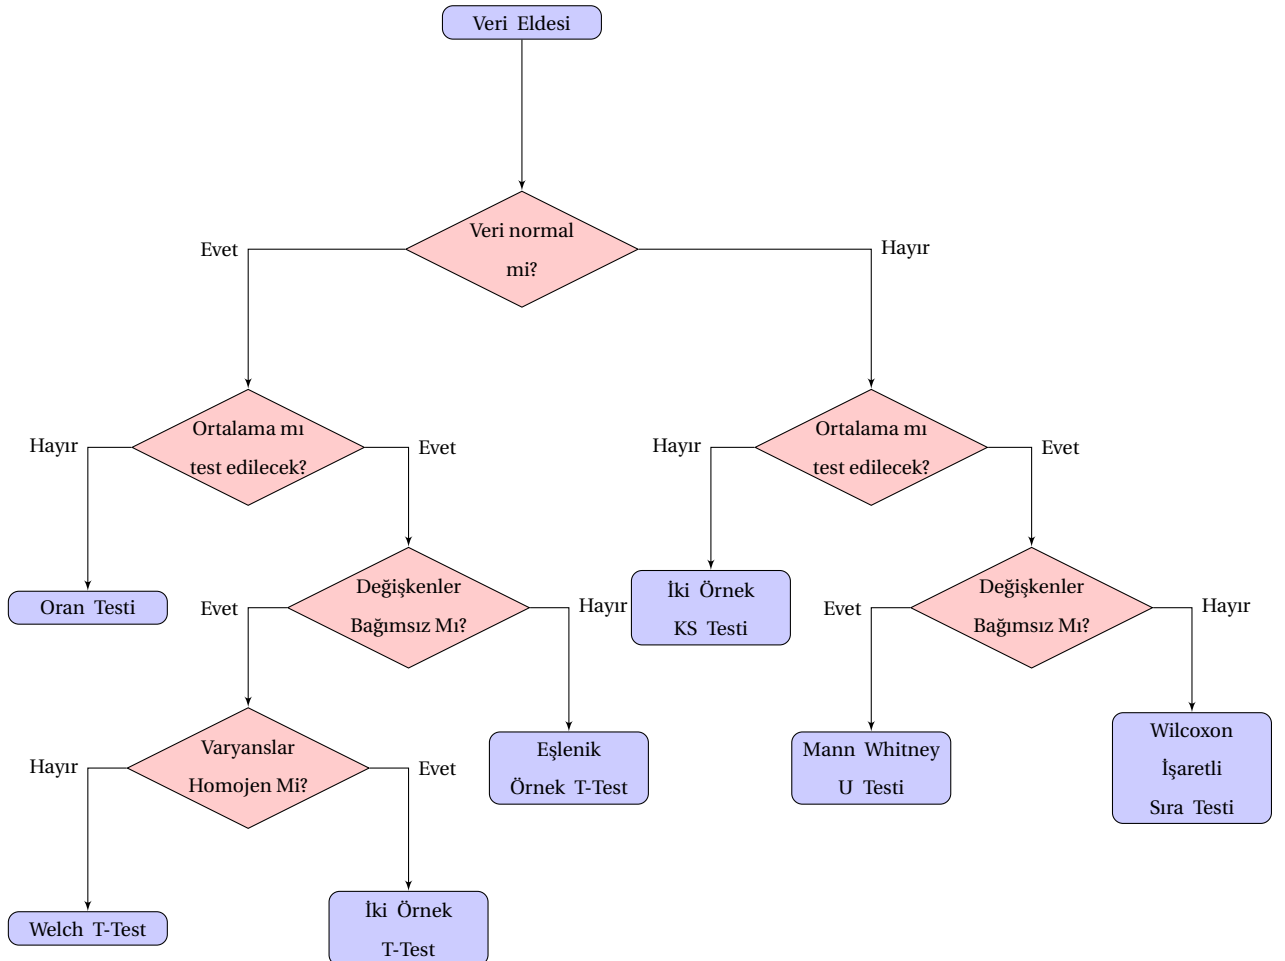
```
test
```

```
##
## Exact binomial test
##
## data: kurtulanlar and toplam.hasta
## number of successes = 28, number of trials = 30, p-value = 0.998
```

```
## alternative hypothesis: true probability of success is less than 0.75
## 95 percent confidence interval:
##  0.0000000 0.9880242
## sample estimates:
## probability of success
##                0.9333333
```


İki Örnek Testleri

İki anakütle ile ilgili parametrelerin karşılaştırılması için kullanılacak testlerdir. Aşağıdaki algoritmaya göre seçilirler. Ancak, duruma göre parametrik olmayan yöntemlerin doğrudan kullanılması söz konusu olabilir.



7.1 Parametrik Testler

Karşılaştırılacak anakütlelerin normal dağılıma sahip olduğu belirlenmişse, parametrelerinin karşılaştırılması amacıyla parametrik testler kullanılır. Bu parametreler anakütlelerin ortalamaları ve oranları olabilir.

7.1.1 İki Ortalamanın Testi

İki anakütle ortalaması, bu anakütlelerden alınacak örneklemelerin ortalamaları kullanılarak birbirleri ile karşılaştırılabilirler. Ancak, incelenen örneklerin bağımlı veya bağımsız olması durumuna göre farklı testler gerçekleştirilmelidir.

7.1.1.1 İki Bağımsız Ortalamanın Testi

Farklı anakütlelerden alınan bağımsız iki n_1 ve n_2 elemanlı iki adet örneklem, ana kütle ortalamalarının test edilmesi için yeterli olacaktır. Bu test için yokluk hipotezi aşağıdaki gibi kurulur.

$$H_0 = \mu_1 = \mu_2$$

veya μ_1 ve μ_2 eşit ise aralarındaki fark 0 olacağından;

$$H_0 = \mu_1 - \mu_2 = 0$$

olur. Alternatif hipotez duruma göre oluşturulmalıdır.

Bu amaçla iki örnek t-Testi kullanılır. Bu testin iki farklı sürümü bulunmaktadır. İlk olarak varyansların homojen olması durumunu inceleyelim. Bu durumda test istatistiği aşağıdaki şekilde olacaktır.

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sigma_{\bar{x}_1 - \bar{x}_2}}$$

Anakütle ortalamalarının aynı olduğu ($\mu_1 = \mu_2$) varsayımı altında, test istatistiği aşağıdaki gibi olacaktır.

$$t = \frac{(\bar{x}_1 - \bar{x}_2)}{\sigma_{\bar{x}_1 - \bar{x}_2}}$$

Burada, ortalama farklarının standart hatası $\sigma_{\bar{x}_1 - \bar{x}_2}$ varyansların homojen olduğu durumda;

- Anakütle varyansları ($\sigma_1 = \sigma_2 = \sigma$) biliniyorsa;

$$\sigma_{\bar{x}_1 - \bar{x}_2} = \sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

- Anakütle varyansları bilinmiyorsa;

$$S_{\bar{x}_1 - \bar{x}_2} = S \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

$$S = \sqrt{\frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}}$$

şeklinde olacaktır. Ancak varyans homojenliği her zaman sağlanabilen bir durum değildir. Bu sebeple, varyans homojenliğinin sağlanamadığı durumda kullanılabilecek bir alternatife ihtiyacınız olacaktır. Bu alternatif Welch tarafından önerilen t-Testidir. Bu test, varyans homojenliği sağlanamadığı durumda t-Dağılımının serbestlik derecesini, standart hatanın aşağıdaki yöntemle hesaplanması ile değiştirir ve t-Testinin gerçekleştirilmesini sağlar. Bu durumda ortalama farkının standart hatası;

- Anakütle varyansları (σ_1, σ_2) biliniyorsa;

$$\sigma_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$$

- Anakütle varyansları bilinmiyorsa;

$$S_{\bar{x}_1 - \bar{x}_2} = \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$$

olur. Şimdi bu testi bu iki durumu inceleyerek R ile gerçekleştirelim. Yalnız unutulmaması gereken en önemli nokta, eğer incelediğiniz değişkenleri bir dönüşüm yardımıyla normalleştirmişseniz, ortalama farklarını inceleyeceğiniz değişkenlerin ikisinde **aynı** dönüşüm ile normal dağılıma dönmesidir.

```
# Parkinson verisinde D2 ve PPE değişkenleri logaritma dönüşümü
# ile normalleşmektedir.
d2.norm = log(veri$D2)
ppe.norm = log(veri$PPE)

# Normallik testlerini gerçekleştirelim.
d2.norm.test = shapiro.test(d2.norm)
ppe.norm.test = shapiro.test(ppe.norm)
```

```
if(d2.norm.test$p.value<0.05 || ppe.norm.test$p.value<0.05) {
  print("Değişkenler normal dağılmıyor, t-Testi uygulanamaz.")
} else {
  # Varyans Homojenliğini test edelim.
  birlestirilmis.degisken = c(d2.norm, ppe.norm)

  d2.uzunluk = length(d2.norm)
  ppe.uzunluk = length(ppe.norm)

  d2.belirtec = rep(1, d2.uzunluk)
  ppe.belirtec = rep(2, ppe.uzunluk)

  bileske.belirtec = c(d2.belirtec, ppe.belirtec)

  test = leveneTest(birlestirilmis.degisken, bileske.belirtec)

  p.degeri = test$`Pr(>F)`[1]

  if(p.degeri<0.05) {
    # Varyanslar Homojen Değil İki Yönlü Welch T-Test
    test = t.test(d2.norm, ppe.norm, var.equal = FALSE)

    # Testi Değerlendirelim
    if(test$p.value<0.05) {
      print("d2 ortalaması ppe'den farklıdır")
      print(test)
    } else {
      print("d2 ortalaması ppe ile aynıdır")
      print(test)
    }
  }

  # Varyanslar Homojen Değil Tek Yönlü Welch T-Test
  test = t.test(d2.norm, ppe.norm, var.equal = FALSE, alternative = "g")

  # Testi Değerlendirelim
  if(test$p.value<0.05) {
    print("d2 ortalaması ppe'den büyüktür")
    print(test)
  } else {
    print("d2 ortalaması ppe ile aynıdır")
    print(test)
  }

  # Varyanslar Homojen Değil Tek Yönlü Welch T-Test
```

```
test = t.test(d2.norm, ppe.norm, var.equal = FALSE, alternative = "l")

# Testi Değerlendirelim
if(test$p.value<0.05) {
  print("d2 ortalaması ppe'den küçüktür")
  print(test)
} else {
  print("d2 ortalaması ppe ile aynıdır")
  print(test)
}
} else {
  # Varyanslar Homojen İki Yönlü Two Sample T-Test
  test = t.test(d2.norm, ppe.norm, var.equal = TRUE)

  # Testi Değerlendirelim
  if(test$p.value<0.05) {
    print("d2 ortalaması ppe'den farklıdır")
    print(test)
  } else {
    print("d2 ortalaması ppe ile aynıdır")
    print(test)
  }
}

# Varyanslar Homojen Tek Yönlü Two Sample T-Test
test = t.test(d2.norm, ppe.norm, var.equal = TRUE, alternative = "g")

# Testi Değerlendirelim
if(test$p.value<0.05) {
  print("d2 ortalaması ppe'den büyüktür")
  print(test)
} else {
  print("d2 ortalaması ppe ile aynıdır")
  print(test)
}

# Varyanslar Homojen Tek Yönlü Two Sample T-Test
test = t.test(d2.norm, ppe.norm, var.equal = TRUE, alternative = "l")

# Testi Değerlendirelim
if(test$p.value<0.05) {
  print("d2 ortalaması ppe'den küçüktür")
  print(test)
} else {
  print("d2 ortalaması ppe ile aynıdır")
  print(test)
}
```

```

    print(test)
  }
}

## [1] "d2 ortalaması ppe'den farklıdır"
##
## Welch Two Sample t-test
##
## data: d2.norm and ppe.norm
## t = 73.507, df = 241.87, p-value < 2.2e-16
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
##  2.461529 2.597088
## sample estimates:
## mean of x mean of y
##  0.8551138 -1.6741948
##
## [1] "d2 ortalaması ppe'den büyüktür"
##
## Welch Two Sample t-test
##
## data: d2.norm and ppe.norm
## t = 73.507, df = 241.87, p-value < 2.2e-16
## alternative hypothesis: true difference in means is greater than 0
## 95 percent confidence interval:
##  2.472493      Inf
## sample estimates:
## mean of x mean of y
##  0.8551138 -1.6741948
##
## [1] "d2 ortalaması ppe ile aynıdır"
##
## Welch Two Sample t-test
##
## data: d2.norm and ppe.norm
## t = 73.507, df = 241.87, p-value = 1
## alternative hypothesis: true difference in means is less than 0
## 95 percent confidence interval:
##    -Inf 2.586124
## sample estimates:
## mean of x mean of y
##  0.8551138 -1.6741948

```

7.1.1.2 İki Bağımlı Ortalamanın Testi

Bazı araştırmalarda, bir sürecin mevcut duruma etkisinin gözlenmesi gerekmektedir. Örneğin bir eğitim yönteminin öğrencilerin başarımı üzerine etkisi, bir tedavinin bir hastalığa olan etkisi gibi. Bu durumda Eşleştirilmiş veya Eşlenik Örnek t-Testi (paired sample T-Test) gerçekleştirilir. Bu test ile, iki bağımlı örneklemin ortalamaları arasındaki fark incelenmektedir. Buna göre, ölçümler arası farkı D_i ile ifade edersek;

$$D_i = x_{1i} - x_{2i}$$

olacaktır. Bu testin hipotezleri iki bağımsız örnek testi hipotezleri ile aynıdır. Fakat, burada araştırılması gereken normallik değişkenlerin ayrı ayrı normalliği değildir. **Onun yerine yeni oluşturulan farkın yani D_i 'nin normalliğine bakılarak bu teste karar verilir.** Kullanılacak test istatistiği aşağıdaki gibi olacaktır.

$$t = \frac{\sum D_i}{\sqrt{\frac{n \sum D_i^2 - (\sum D_i)^2}{n-1}}}$$

Buradaki örnek veri, bir SPSS dosyası olacaktır. Bu durumda, R ile veriyi yüklemek için *foreign* kütüphanesini kullanmanız gerekmektedir. Örnek veriyi, dersin sayfasından indirebilirsiniz. İstenen bilgi, bir derse ait not ortalamasının, öğrencilere uygulamalı eğitim verildiğinde arttığının kanıtlanmasıdır. Aşağıdaki R kodlarını inceleyiniz.

```
library(foreign)

veri = read.spss('egitim.sav')

eo = veri$egitimoncesi
es = veri$egitimsonrası

D = eo - es

test = shapiro.test(D)

if(test$p.value<0.05) {
  cat("Veri Normal Dağılıma sahip değildir, t-Testi Yapılamaz.\n")
} else {
  # Eşlenik Örnek İki Yönlü T Testi
  test = t.test(eo, es, paired = TRUE)

  if(test$p.value<0.05) {
    cat("Eğitim öncesi ile eğitim sonrası arasında fark vardır p=",
        test$p.value, "\n")
  }
}
```

```

} else {
  cat("Eğitim öncesi ile eğitim sonrası arasında fark yoktur p=",
      test$p.value, "\n")
}

# Eşlenik Örnek Tek Yönlü T Testi
test = t.test(eo, es, paired = TRUE, alternative = "g")

if(test$p.value<0.05) {
  cat("Eğitim öncesi, eğitim sonrasında büyüktür p=",
      test$p.value, "\n")
} else {
  cat("Eğitim öncesi ile eğitim sonrası arasında fark yoktur p=",
      test$p.value, "\n")
}

# Eşlenik Örnek Tek Yönlü T Testi
test = t.test(eo, es, paired = TRUE, alternative = "l")

if(test$p.value<0.05) {
  cat("Eğitim öncesi, eğitim sonrasında küçüktür p=",
      test$p.value, "\n")
} else {
  cat("Eğitim öncesi ile eğitim sonrası arasında fark yoktur p=",
      test$p.value, "\n")
}
}

```

```

## Eğitim öncesi ile eğitim sonrası arasında fark vardır p= 0.01639007
## Eğitim öncesi ile eğitim sonrası arasında fark yoktur p= 0.991805
## Eğitim öncesi, eğitim sonrasında küçüktür p= 0.008195035

```

7.1.2 İki Oranın Testi

Oran testi ayrıca iki oranın testi içinde kullanılan bir testtir. Örneğin, bir doktor emniyet kemeri kullanımının trafik kazalarındaki kurtulma oranını arttırdığını iddia etsin. Bu durumda kullanılacak test istatistiği aşağıdaki gibi olacaktır.

$$t = \frac{p_A - p_B}{\sqrt{\frac{pq}{n_A} + \frac{pq}{n_B}}}$$

Burada p ve q genel oranları ifade eder. Kurulacak yokluk hipotezi aşağıdaki gibi olacaktır. Alternatif hipotezler istenilen ifadeye uygun olarak kurulmalıdır.

$$H_0: p_A = p_B$$

```

kurtulanlar = c(1443, 1781)
toplaml.hasta = c(1490, 1916)

test = prop.test(kurtulanlar, toplaml.hasta )
if(test$p.value<0.05) {
  cat("Emniyet kemeri kullananlar ile kullanmayanlar arasında fark vardır p=",
      test$p.value)
} else {
  cat("Emniyet kemeri kullananlar ile kullanmayanlar arasında fark yoktur p=",
      test$p.value)
}

## Emniyet kemeri kullananlar ile kullanmayanlar arasında fark vardır p= 8.104882e-07

test = prop.test(kurtulanlar, toplaml.hasta, alternative = "greater")
if(test$p.value<0.05) {
  cat("Emniyet kemeri kullananların kurtulma oranı daha fazladır p=", test$p.value)
} else {
  cat("Emniyet kemeri kullananların kurtulma oranı aynıdır p=", test$p.value)
}

## Emniyet kemeri kullananların kurtulma oranı daha fazladır p= 4.052441e-07

test=prop.test(kurtulanlar, toplaml.hasta, alternative = "less")
if(test$p.value<0.05) {
  cat("Emniyet kemeri kullananların kurtulma oranı daha azdır p=", test$p.value)
} else {
  cat("Emniyet kemeri kullananların kurtulma oranı aynıdır p=", test$p.value)
}

## Emniyet kemeri kullananların kurtulma oranı aynıdır p= 0.9999996

```

7.2 Parametrik Olmayan Testler

Parametrik testlerin uygulanamadığı durumlarda kullanılacak testlerdir. Verinin bağımlı veya bağımsız olmasına göre, Mann Whitney U, Wald Wolfowitz ve Wilcoxon testleri uygulanır. Bunu yanı sıra, bu testler normallik testleri gerçekleştirmeden araştırmacının isteğine göre veya veri türüne göre doğrudan uygulanabilirler.

7.2.1 Mann Whitney U Testi

Bağımsız örnek T-Testinin parametrik olmayan karşılığıdır. Bağımlı değişkenin aralıklı veya oransal ölçek olmadığı durumlarda, bağımlı değişkenin aralıklı veya oransal ölçek olduğu ancak örnek birim sayısının 30'dan küçük olduğu durumlarda, gözlem sayısı yeterli olduğu halde parametrik test varsayımlarının sağlanmadığı durumlarda kullanılmaktadır.

Testin hipotezleri bağımsız örnek t-Testi ile aynıdır. Test istatistiğinin iki farklı hesaplanması söz konusudur.

- $n_1 + n_2 < 20$ olduğu durumda

İki veri birleştirilir ve sıralanır. Bütün değerlere sıra sayıları verilir. Aynı değerli elemanların tümüne ortalama sıra sayısı değeri verilir. U_1 ve U_2 test istatistikleri aşağıdaki şekilde hesaplanır.

$$U_1 = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - \sum_{i=0}^{n_1} S_{1i}$$

$$U_2 = n_2 n_1 + \frac{n_2(n_2 + 1)}{2} - \sum_{i=0}^{n_2} S_{2i}$$

$$U = \min \{U_1, U_2\}$$

Burada S_{ij} i. veriye ait j. sıra sayısını ifade eder.

- $n_1 + n_2 > 20$ olduğu durumda

Bu durumda birleştirilmiş verinin normal dağılıma sahip olması olasılığı artmaktadır. Bu sebeple test istatistiği aşağıdaki şekilde olacaktır.

$$Z = \frac{U - \frac{n_1 n_2}{2}}{\sqrt{\frac{n_1 n_2 (n_1 + n_2 + 1)}{12}}}$$

Burada, U örneklerin birinden hesaplanacak olan U değeridir. Kullanılacak olan U değerinin hangi örnekten hesaplanacağı önemli değildir, çünkü yapılacak seçim sadece Z istatistiğinin işaretini değiştirecektir.

Yukarıda kullandığımız veriler için Mann-Whitney U testi gerçekleştirmek için aşağıdaki R kodunu inceleyebilirsiniz.

```
# Parkinson verisinde yer alan d2 ve ppe'yi inceleyelim
veri = read.csv2('parkinsons.csv')

d2 = veri$d2
ppe = veri$ppe

# Mann-Whitney U testini Uygulayalım
test = wilcox.test(d2, ppe, paired = FALSE)
```

```
# Testi Yorumlayalım
if(test$p.value<0.05) {
  cat("d2 ve ppe ortalamaları aynı değildir p=",
      test$p.value, "\n")
} else {
  cat("d2 ve ppe ortalamaları aydır p=",
      test$p.value, "\n")
}
```

```
## d2 ve ppe ortalamaları aynı değildir p= 2.080542e-65
```

```
# Mann-Whitney U testini Uygulayalım
test = wilcox.test(d2, ppe, paired = FALSE, alternative = "g")

# Testi Yorumlayalım
if(test$p.value<0.05) {
  cat("d2 > ppe p=",
      test$p.value, "\n")
} else {
  cat("d2 ve ppe ortalamaları aydır p=",
      test$p.value, "\n")
}
```

```
## d2 > ppe p= 1.040271e-65
```

```
# Mann-Whitney U testini Uygulayalım
test = wilcox.test(d2, ppe, paired = FALSE, alternative = "l")

# Testi Yorumlayalım
if(test$p.value<0.05) {
  cat("d2 < ppe p=",
      test$p.value, "\n")
} else {
  cat("d2 ve ppe ortalamaları aydır p=",
      test$p.value, "\n")
}
```

```
## d2 ve ppe ortalamaları aydır p= 1
```

NOT

R koduna dikkat ederseniz, *wilcox.test* fonsiyonunun kullanıldığını görürsünüz. Bu durum R programcılar tarafından aşağıdaki şekilde açıklanmaktadır:

The literature is not unanimous about the definitions of the Wilcoxon rank sum and Mann-Whitney tests.

The two most common definitions correspond to the sum of the ranks of the first sample with the minimum value subtracted or not: R subtracts and S-PLUS does not, giving a value which is larger by $m(m+1)/2$ for a first sample of size m . (It seems Wilcoxon's original paper used the unadjusted sum of the ranks but subsequent tables subtracted the minimum.)

R's value can also be computed as the number of all pairs $(x[i], y[j])$ for which $y[j]$ is not greater than $x[i]$, the most common definition of the Mann-Whitney test.

Burada, R programcılarının literatürde de bu iki testin literatürdeki tanımları hakkında kabul görmüş bir tanım olmadığından bahsetmektedir. Temelde bu testi öneren Wilcoxon'dır ve önerdiği test eşit eleman sayısına sahip örnekler için geliştirmiştir. Mann ve Whitney ise bu testin eleman eşitliğini şartını kaldırarak genelleştirmiştir. Bu test aynı zamanda **Wilcoxon Sıralama Toplamı Testi** veya **Wilcoxon-Mann-Whitney Testi** olarakta adlandırılır.

7.2.2 Wilcoxon İşaretli Sıra Testi

Bu test bağımlı örnek t-Testinin alternatifidir. Burada ortalama yerine medyan değerlerinin farkından bahsedilmektedir. Test istatistiği aşağıdaki şekilde hesaplanır.

$$D_i^+ = \sum_{j=0}^n \begin{cases} 1 & x_{1j} > x_{2j} \\ 0 & x_{1j} \leq x_{2j} \end{cases}$$

$$D_i^- = \sum_{j=0}^n \begin{cases} 1 & x_{1j} < x_{2j} \\ 0 & x_{1j} \geq x_{2j} \end{cases}$$

$$t_w = \min \{D_i^+, D_i^-\}$$

Kurulacak olan hipotezler, bağımlı örnek t Testi ile aynıdır. Bağımlı örnek T-Testinde kullandığımız problemi Wilcoxon testi ile çözümü aşağıda verilmiştir.

```
library(foreign)

veri = read.spss('egitim.sav')

eo = veri$egitimoncesi
es = veri$egitimsonrası

# İki Yönlü Wilcoxon İşaretli Sayı Testini Uygulayalım
```

```
test = wilcox.test(eo, es, paired = TRUE)
```

```
# Testi Değerlendirelim
```

```
if(test$p.value<0.05) {  
  cat("Eğitim Öncesi Eğitim sonrasında farklıdır p=",  
      test$p.value, "\n")  
} else {  
  cat("Eğitim Öncesi Eğitim sonrası ile aynıdır p=",  
      test$p.value, "\n")  
}
```

```
## Eğitim Öncesi Eğitim sonrasında farklıdır p= 0.01387757
```

```
# Tek Yönlü Wilcoxon İşaretli Sayı Testini Uygulayalım
```

```
test = wilcox.test(eo, es, paired = TRUE, alternative = "g")
```

```
# Testi Değerlendirelim
```

```
if(test$p.value<0.05) {  
  cat("Eğitim Öncesi Eğitim sonrasında büyüktür p=",  
      test$p.value, "\n")  
} else {  
  cat("Eğitim Öncesi Eğitim sonrası ile aynıdır p=",  
      test$p.value, "\n")  
}
```

```
## Eğitim Öncesi Eğitim sonrası ile aynıdır p= 0.9933858
```

```
# İki Yönlü Wilcoxon İşaretli Sayı Testini Uygulayalım
```

```
test = wilcox.test(eo, es, paired = TRUE, alternative = "l")
```

```
# Testi Değerlendirelim
```

```
if(test$p.value<0.05) {  
  cat("Eğitim Öncesi Eğitim sonrasında küçüktür p=",  
      test$p.value, "\n")  
} else {  
  cat("Eğitim Öncesi Eğitim sonrası ile aynıdır p=",  
      test$p.value, "\n")  
}
```

```
## Eğitim Öncesi Eğitim sonrasında küçüktür p= 0.006938787
```

7.2.3 Kolmogorov-Smirnov İki Örnek Testi

Kolmogorov-Smirnov testinin bir diğer kullanım alanı da iki değişkenin dağılımlarının parametreleriyle birlikte aynı olup olmadığının test edilmesidir. Burada, hipotezler aşağıdaki gibi kurulur.

H_0 :	Dağılımlar Aynıdır
H_1 :	Dağılımlar Aynı Değildir

Örnek olarak, bir psikiyatri kliniğine başvuran hastalara uygulanan Beck Depresyon ölçeği değerlerinin kadın ve erkekler için aynı dağılıma sahip olup olmadığını inceleyelim. Veriler yine bir SPSS dosyasından yüklenmektedir.

```
veri = read.spss('beck_puan.sav')

cinsiyet = veri$cinsiyet[!is.na(veri$cinsiyet)]
beck_puan = veri$beckpuanı[!is.na(veri$beckpuanı)]

kadin_beck_puan = beck_puan[cinsiyet=="kadın"]
erkek_beck_puan = beck_puan[cinsiyet=="erkek"]

test = ks.test(erkek_beck_puan, kadın_beck_puan)

if(test$p.value<0.05) {
  cat("Erkek ve Kadınların depresyon puanları aynı dağılıma",
      "sahip değildir p=", test$p.value, "\n")
} else {
  cat("Erkek ve Kadınların depresyon puanları aynı dağılıma",
      "sahiptir p=", test$p.value, "\n")
}
```

Erkek ve Kadınların depresyon puanları aynı dağılıma sahiptir p= 0.4464094


Grafiksel olarak incelendiğinde, aşağıdaki sonuçlar elde edilecektir.

```
xMin = min(min(kadin_beck_puan), min(erkek_beck_puan))-2
xMax = max(max(kadin_beck_puan), max(erkek_beck_puan))+2

x = seq(from=xMin, to=xMax, length.out = 1000)

cdfv = ecdf(kadin_beck_puan)
cdfy = ecdf(erkek_beck_puan)

plot(x, cdfv(x), main = "Kadınlar ile Erkeklerin Beck Puanı O.Y.F.",
     type="s", col="red", lwd=2)
lines(x, cdfy(x), type="s", col="blue", lwd=2)
```

Kadınlar ile Erkeklerin Beck Puanı O.Y.F.

Uygulama: Uyku Anketi Değerlendirmesi

Bu uygulamada, sitedeki *Uyku Ölçeği* verisini indirip, aşağıdaki işlemleri gerçekleştiriniz. Aksi belirtilmediği sürece $\alpha = 0.05$ kullanınız.

- Nominal Değerli değişkenlerin frekans tablolarını oluşturunuz.
- Medeni hal değişkeni ile eğitim seviyesi değişkenleri için çapraz frekans tablosu, çapraz marjinal frekans tablosu ve oran tablolarını oluşturunuz.
- Medeni Hal ve Eğitim Seviyesi değişkenleri için pasta grafiği ve histogram oluşturunuz.
- Medeni Hal ile Uykuya Dalma Güçlüğü değişkenlerinin arasında anlamlı bir ilişki olup olmadığını belirleyiniz.
- Epworth Uyku Ölçeği, HADS Anksiyete ve HADS Depresyon ölçeği değerlerinin normallliğini belirleyiniz, mümkünse normalleştiriniz.
- Epworth Uyku Ölçeği değerinin ortalamasının 12'den, HADS Anksiyete ve HADS depresyon ölçeği skorlarının 10'dan büyük olup olmadığını belirleyiniz.
- Hafta İçi Uyku Süresinin, Hafta Sonu Uyku Süresi ile aynı olup olmadığını inceleyiniz.
- Erkeklerin uyku problemine sahip olmalarının oranının, kadınlarınkinden farklı olup olmadığını inceleyiniz.
- Erkekler ve kadınlar için epworth uyku ölçeği, HADS anksiyete ve HADS depresyon puanlarını farklarını inceleyiniz.

Çok Örnek Testleri

İstatistiksel olarak 2'den fazla örneğin karşılaştırılması gerektiğinde kullanılması önerilen testlerdir.

Bağımsız örneklerin test edilmesi sözkonusu olduğunda, 2 adet örnek için t-Testinin kullanılması gerektiğini öğrenmiştik. Eğer 2'den fazla bağımsız örneğin karşılaştırılması gerekli olduğu durumlarda ise t-Testinin anlamlılık seviyesi düşecektir. Her bir ikili için t-Testi kullanılması durumunda testlerin hepsinden %5 hata oranı gelecektir. Örneğin, 3 adet ikili karşılaştırma için testin gücü binom dağılımına göre aşağıdaki gibi hesaplanır.

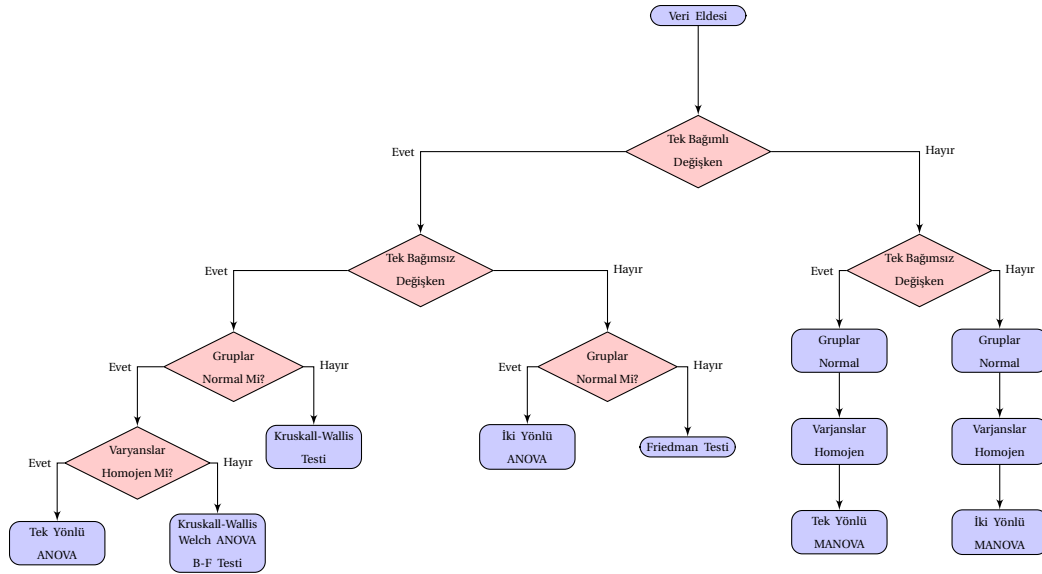
$$P(x = 3) = C_3^3 (0.95)^3 (0.05)^0 = 0.95^3 = 0.86$$

Bu durumda, $\alpha = 1 - \beta = 1 - 0.86 = 0.14$ olarak hesaplanır. Ancak, bütün bu işlemleri ANOVA (ANalysis Of VAriance) testi ile gerçekleştirmeniz durumunda $\alpha = 0.05$ olacak ve testinizin gücü artacaktır.

Anova testinin farklı varyasyonları bulunmaktadır. Bu varyasyonlar;

- Bir bağımsız değişkenin, bir bağımlı değişken üzerindeki etkisinin incelendiği, Tek Yönlü ANOVA
- İki bağımsız değişkenin, bir bağımlı değişken üzerindeki etkisinin incelendiği, İki Yönlü ANOVA
- İki'den fazla bağımlı örneğin karşılaştırılmasında kullanılan, Bağımlı Örnekler için ANOVA
- Bir bağımsız değişkenin, birden fazla bağımlı değişken üzerindeki etkisinin incelendiği, Tek Yönlü MANOVA
- İki bağımsız değişkenin, birden fazla bağımlı değişken üzerindeki etkisinin incelendiği, İki Yönlü MANOVA

Ayrıca ANOVA testinin parametrik olmayan karşılıkları da bulunmaktadır. Genellikle ANOVA'nın varsayımlarının sağlanamadığı koşullarda, Kruskal-Wallis (Tek Yönlü ANOVA) veya Friedman (İki Yönlü ANOVA) testi kullanılmaktadır. Aşağıdaki akış şemasında bu durum özetlenmektedir.



Anova testini bir modelleme aracı olarak da kabul etmek mümkündür. Zaten R ile yapacağınız testlerde anova modeli oluşturmanız gerekmektedir.

9.1 Tek Yönlü ANOVA Testi

Tek yönlü anova testinde; bağımlı değişkenin bağımsız değişkenin düzeylerine göre farklılaşıp farklılaşmadığı, farklı gruplardaki varyansların karşılaştırılması temeline dayanan F testi ile incelenmektedir. Anova testi parametrik bir testtir ve bu testte kullanılacak bütün örnekler parametrik test varsayımlarını sağlamalıdır.

Bu testin hipotezi aşağıdaki şekilde kurulur.

$$H_0 : \mu_1 = \mu_2 = \dots = \mu_k$$

$$H_1 : \mu_1 \neq \mu_2 \neq \dots \neq \mu_k$$

Kullanılacak test istatistiği aşağıdaki şekilde hesaplanır.

İlk olarak örneklerin ortalamaları hesaplanır. Bu ortalamalar kullanılarak genel ortalama aşağıdaki formül ile hesaplanır.

$$\bar{X} = \frac{\sum_i^{n_g} \bar{X}_i}{n_g}$$

Burada n_g grup sayısı, X_i 'de i. grup ortalamasını ifade eder. Sonra gruplar arası ortalama kareler farkı \bar{D}_{GA} aşağıdaki formül ile hesaplanır.

$$D_{GA} = n \sum_i^{n_g} (\bar{X}_i - \bar{X})^2$$

$$SD_{GA} = n_g - 1$$

$$\bar{D}_{GA} = \frac{D_{GA}}{SD_{GA}}$$

Grup içi ortalama kareler farkı \bar{D}_{Gi} da aşağıdaki şekilde hesaplanır.

$$D_{Gi} = \sum_i^n (X_i - \bar{X}_i)^2$$

$$SD_{Gi} = n_g(n - 1)$$

$$\bar{D}_{Gi} = \frac{D_{Gi}}{SD_{Gi}}$$

Burada n örneklerin eleman sayısıdır. Bu iki değer elde edildikten sonra kullanılacak olan F istatistiği aşağıdaki şekilde hesaplanır.

$$F = \frac{\bar{D}_{GA}}{\bar{D}_{Gi}}$$

Şimdi R ile anova testinin nasıl gerçekleştirildiğine bakalım. Bu işlem için R'in model (formül) yazımını kullanmalısınız. Bu yazımda, bağımlı değişken bağımsız değişkenlerle ifade edilir şeklinde bir ifade söz konusudur. Örneğin, $A \sim B$ şeklindeki bir ifade de A **bağımlı değişken**, B de **bağımsız** değişken olmaktadır. Örnek olarak, çeşitli bölgelerden elde edilmiş fil dişlerinin içerdiği kimyasal maddelerin farklarını incelemeniz istensin. Aşağıdaki R kodunu inceleyin.

```
veri = read.csv2('fildisi.csv')

aov.ornek = aov(delta13C~bolge, data = veri)

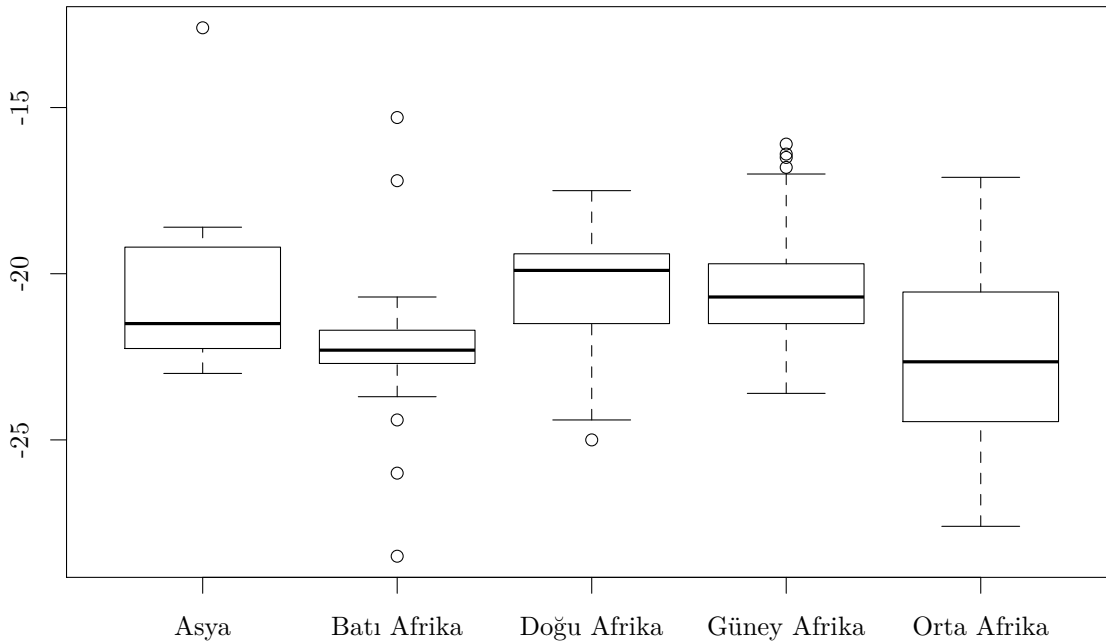
summary(aov.ornek)

##              Df Sum Sq Mean Sq F value Pr(>F)
## bolge         4  413.6   103.41    31.65 <2e-16 ***
## Residuals    490 1600.9     3.27
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Değişkenlerin ortalamaları arasında anlamlı bir fark çıktığından ötürü, hangi iki değişkenlerin arasında fark olduğunu öğrenmek için Post Hoc testlere başvurmalısınız.

Grafiksel olarak bu durumu incelendiğinde aşağıdaki durum ortaya çıkmaktadır.

```
boxplot(delta13C~bolge, data=veri)
```



9.1.1 Eşit Varyans Varsayımı ile Kullanılacak Post Hoc Testler

Burada ortalamaların farklarından bahsedebilmek için ilk olarak varyans homojenliği şartı kontrol edilmelidir. Bu işlem yine levene testi ile gerçekleştirilebilir.

```
library(car)
```

```
leveneTest(veri$delta13C, veri$bolge)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##      Df F value  Pr(>F)
## group  4 17.943 9.23e-14 ***
##      490
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Örnektende görüldüğü gibi eşit varyans varsayımı sağlanmamaktadır. Ancak, uygulama olması açısından tüm testler bu veriler üzerinde gerçekleştirilecektir.

9.1.1.1 Tukey Testi

Bu test ortalamaların güven aralıkları gerekliyse veya grupların eleman sayıları aynı değilse kullanılmalıdır. Aksi durumlarda Scheffe testi veya Aile Çapı Hata Oranı yöntemleri denenmelidir. Aşağıdaki R kodunu inceleyin.


```
TukeyHSD(x = aov.ornek, "bolge", conf.level = 0.95)
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = delta13C ~ bolge, data = veri)
##
## $bolge
##              diff          lwr          upr          p adj
## Batı Afrika-Asya -2.05452899 -3.9029126 -0.2061454 0.0207243
## Doğu Afrika-Asya -0.26385135 -2.1934931 1.6657904 0.9958149
## Güney Afrika-Asya -0.35771073 -2.1340552 1.4186337 0.9817489
## Orta Afrika-Asya -2.29916667 -4.1062811 -0.4920522 0.0048776
## Doğu Afrika-Batı Afrika 1.79067763 0.7822521 2.7991031 0.0000155
## Güney Afrika-Batı Afrika 1.69681826 1.0268898 2.3667468 0.0000000
## Orta Afrika-Batı Afrika -0.24463768 -0.9923457 0.5030703 0.8984088
## Güney Afrika-Doğu Afrika -0.09385938 -0.9632267 0.7755079 0.9983329
## Orta Afrika-Doğu Afrika -2.03531532 -2.9659401 -1.1046905 0.0000000
## Orta Afrika-Güney Afrika -1.94145594 -2.4872991 -1.3956127 0.0000000
```

Test sonuçlarına göre Doğu Afrika-Asya, Güney Afrika-Asya, Orta Afrika-Batı Afrika ve Güney Afrika-Doğu Afrika'da gerçekleştirilen ölçümler arasındaki farklar istatistiksel olarak anlamsızdır.

```
par(mar=c(5,11,4,2)+0.1)
plot(TukeyHSD(x = aov.ornek, "bolge", conf.level = 0.95),
     las = 1, cex.axis=1)
```

95% family-wise confidence level



9.1.1.2 Scheffe Testi

Genel olarak, çok fazla sayıda karşılaştırma olduğu durumlarda bu test Tukey testinden daha iyi sonuçlar vermektedir. Aşağıdaki R kodunu inceleyin.

```
library(agricolae)

test = scheffe.test(aov.ornek, "bolge", group = TRUE, console = TRUE)

##
## Study: aov.ornek ~ "bolge"
##
## Scheffe Test for delta13C
##
## Mean Square Error : 3.267213
##
## bolge, means
##
##          delta13C      std   r   Min   Max
## Asya          -20.18750 3.385869   8 -23.0 -12.6
## Batı Afrika   -22.24203 1.549327  69 -28.5 -15.3
## Doğu Afrika   -20.45135 1.899798  37 -25.0 -17.5
## Güney Afrika  -20.54521 1.413515 261 -23.6 -16.1
## Orta Afrika   -22.48667 2.439243 120 -27.6 -17.1
##
## alpha: 0.05 ; Df Error: 490
## Critical Value of F: 2.390132
##
## Harmonic Mean of Cell Sizes 27.98228
## Minimum Significant Difference: 1.494181
##
## Means with the same letter are not significantly different.
##
## Groups, Treatments and means
## a      Asya          -20.19
## a      Doğu Afrika   -20.45
## a      Güney Afrika  -20.55
## ab     Batı Afrika   -22.24
## b      Orta Afrika   -22.49
```

Sonuç tablosunda, aynı harf ile gösterilen ortalamalar arasındaki farklar istatistiksel olarak anlamlı değildir. Bu durumda Asya, Doğu Afrika, Güney Afrika ve Batı Afrika'da yapılan ölçümler arasındaki farklar ile Batı Afrika ve Orta Afrika'da yapılan ölçümler arasındaki farklar istatistiksel olarak anlamsızdır.

9.1.1.3 Aile Çapı Hata Oranı (Family-Wise Error Rate, FWER)

Bu testler, gruplar arası farkları ikili t-Testi kullanarak bakılmasına dayalı olarak yapılan testlerdir. Burada dikkat edilmesi gereken en önemli nokta, birden fazla ikili karşılaştırma işlemi gerçekleştirildiği için hesaplanan p değerlerinin düzeltilmesi gerektirir. Bu düzeltmeler için birden çok yöntem bulunmaktadır. R bu düzeltmeleri otomatik olarak yapmakta ve size karşılaştırma yapmanız gereken p değerlerini sunmaktadır. Ayrıca bu testlerin varyans homojenliği söz konusu olduğundan, hesaplanacak varyansın yerel olması gerekmektedir. Bu karşılaştırmaların, R ile gerçekleştirmeleri aşağıdaki şekildedir.

- Düzeltme olmadan yapılan karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                     p.adjust.method = "none",
                                     pool.sd = FALSE)
print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##           Asya  Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 0.132 -          -          -
## Doğu Afrika 0.836 6.6e-06    -          -
## Güney Afrika 0.774 7.1e-13    0.774    -
## Orta Afrika 0.098 0.401      1.1e-06    1.3e-13
##
## P value adjustment method: none
```

- Bonferroni Düzeltmesi ile karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                     p.adjust.method = "bonferroni",
                                     pool.sd = FALSE)
print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##           Asya  Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 1.00 -          -          -
## Doğu Afrika 1.00 6.6e-05    -          -
```

```
## Güney Afrika 1.00 7.1e-12      1.00      -
## Orta Afrika  0.98 1.00          1.1e-05    1.3e-12
##
## P value adjustment method: bonferroni
```

- Holm Düzeltmesi ile karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                       p.adjust.method = "holm",
                                       pool.sd = FALSE)
print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##           Asya Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 0.66 -          -          -
## Doğu Afrika 1.00 4.6e-05    -          -
## Güney Afrika 1.00 6.3e-12    1.00      -
## Orta Afrika 0.59 1.00       8.6e-06    1.3e-12
##
## P value adjustment method: holm
```

- Hochberg Düzeltmesi ile karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                       p.adjust.method = "hochberg",
                                       pool.sd = FALSE)
print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##           Asya Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 0.66 -          -          -
## Doğu Afrika 0.84 4.6e-05    -          -
## Güney Afrika 0.84 6.3e-12    0.84      -
## Orta Afrika 0.59 0.84       8.6e-06    1.3e-12
##
## P value adjustment method: hochberg
```

- Hommel Düzeltmesi ile karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                     p.adjust.method = "hommel",
                                     pool.sd = FALSE)

print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##           Asya Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 0.66 -          -          -
## Doğu Afrika 0.84 4.6e-05    -          -
## Güney Afrika 0.84 6.3e-12    0.84      -
## Orta Afrika 0.49 0.84      8.6e-06    1.3e-12
##
## P value adjustment method: hommel
```

- Benjamini & Hochberg Düzeltmesi ile karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                     p.adjust.method = "BH",
                                     pool.sd = FALSE)

print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##           Asya Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 0.22 -          -          -
## Doğu Afrika 0.84 1.7e-05    -          -
## Güney Afrika 0.84 3.5e-12    0.84      -
## Orta Afrika 0.20 0.57      3.6e-06    1.3e-12
##
## P value adjustment method: BH
```

- Benjamini & Yekutieli Düzeltmesi ile karşılaştırma

```
ikili.karsilastirma = pairwise.t.test(veri$delta13C, veri$bolge,
                                     p.adjust.method = "BY",
                                     pool.sd = FALSE)
print(ikili.karsilastirma)
```

```
##
## Pairwise comparisons using t tests with non-pooled SD
##
## data:  veri$delta13C and veri$bolge
##
##              Asya Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika  0.64 -              -              -
## Doğu Afrika  1.00 4.9e-05      -              -
## Güney Afrika 1.00 1.0e-11      1.00            -
## Orta Afrika  0.58 1.00          1.0e-05        3.9e-12
##
## P value adjustment method: BY
```

9.1.2 Eşit Varyans Varsayımı Sağlanmadığında Kullanılan Post Hoc Testler

Eşit varyans varsayımı sağlanmadığında kullanılacak post-hoc testleri aşağıda listelenmiştir. Genellikle, eşit örnek sayısı sağlanması ve bu testlerin tercih edilmemesi önerilmektedir. Ayrıca, bu testler Welch ve Brown-Forsythe testlerinin varsayılan PostHoc testleridir. Ama elinizdeki veri sizi sınırılıyorsa bu durumda aşağıdaki testleri kullanmanız önerilmektedir.

9.1.2.1 Dunnett C Testi

Bu test, varyans homojenliği sağlanamadığı durumlarda kullanılan PostHoc testlerden biridir. Örneklerin eşit sayıda olması ve varyans homojenliği sağlanmadığı durumunda tercih edilmesi önerilmektedir. Sadece bir kontrol değişkeni ile diğerlerinin farklarının anlamlılık düzeylerini inceler. Kullanımı aşağıdaki gibidir.

```
library(DescTools)

DunnettTest(delta13C~bolge, data = veri, control="Asya")

##
## Dunnett's test for comparing several treatments with a control :
## 95% family-wise confidence level
##
## $Asya
##              diff      lwr.ci      upr.ci      pval
## Batı Afrika-Asya -2.0545290 -3.558167 -0.5508907 0.0054 **
## Doğu Afrika-Asya -0.2638514 -1.833592  1.3058894 0.9214
```

```
## Güney Afrika-Asya -0.3577107 -1.802746 1.0873245 0.8020
## Orta Afrika-Asya -2.2991667 -3.769233 -0.8291004 0.0011 **
##
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

9.1.2.2 Dunnet T3 Testi

Bu test, Tukey-Cramer testinin varyans homojenliği sağlanmadığı ve/veya örnek sayısının eşit olmadığı durumda kullanılabilecek halidir. Tamhane T2 testinin gelişmiş halidir. Standart R kurulumunda bulunmamakla beraber, DTK paketi ile bilgisayarınızda kullanılabilir hale gelir. Aşağıdaki R kodunu inceleyin.

```
library(DTK)
```

```
ikili.karsilastirma = DTK.test(veri$delta13C, veri$bolge)
print(ikili.karsilastirma)
```

```
## [[1]]
## [1] 0.05
##
## [[2]]
##
##           Diff    Lower CI    Upper CI
## Batı Afrika-Asya    -2.05452899 -6.3671207  2.2580627
## Doğu Afrika-Asya    -0.26385135 -4.6676740  4.1399713
## Güney Afrika-Asya   -0.35771073 -4.6302559  3.9148344
## Orta Afrika-Asya    -2.29916667 -6.6334371  2.0351038
## Doğu Afrika-Batı Afrika  1.79067763  0.5054660  3.0758893
## Güney Afrika-Batı Afrika  1.69681826  0.9689647  2.4246718
## Orta Afrika-Batı Afrika -0.24463768 -1.2708412  0.7815658
## Güney Afrika-Doğu Afrika -0.09385938 -1.2529513  1.0652325
## Orta Afrika-Doğu Afrika -2.03531532 -3.4060561 -0.6645745
## Orta Afrika-Güney Afrika -1.94145594 -2.7910103 -1.0919015
```

Grafiksel olarak aşağıdaki şekilde gösterilebilir.

```
DTK.plot(ikili.karsilastirma)
```



```
##      Effect          W          p p<.05
## 2   ipucu 0.8765435 0.8013532
##
## $`Sphericity Corrections`
##      Effect      GGe      p[GG] p[GG]<.05      HFe      p[HF] p[HF]<.05
## 2   ipucu 0.9270926 5.722687e-37      * 1.102133 1.076345e-39      *
```

Çıktıya dikkatlice baktığınızda 3 farklı test sonucunu göreceksiniz. İlk olarak, size iki örnek bağımsız örnek için ANOVA tablosu gösterilmektedir. Bu tablo, varyans homojenliği şartı sağlandığında kullanacağınız değerleri içermektedir. İkinci tabloda, size varyans homojenliği hakkında bilgi vermektedir. Bağımlı örnekler için bir test gerçekleştirdiğimizden, burada sadece varyans homojenliği söz konusu değildir. Kovaryanslarında varyans homojenliği üzerine olan etkisinin karşılaştırılması gereklidir. Bu sebeple, burada levene testi yerine Mauchly'nin Küresellik testi kullanılır. Bu test size ilk tablodaki hangi satırları kullanacağınızı söyler. Örnekte, varyans homojenliği sağlandığı için ilk tablodaki satırlar kullanılabilir. Üçüncü tablo ise varyans homojenliği sağlanmadığı durumda, kullanmanız gereken değerleri sunmaktadır. Burada genellikle GG değerlerinin kullanılması tavsiye edilmekle beraber, GGe değerinin 0.75'ten büyük olduğu durumda, p[GG] veya p[HF] değerlerinden istediğinizi kullanabilirsiniz.

9.3 İki Yönlü ANOVA Testi

Bu test ile bağımlı değişkenin birdan fazla bağımsız değişkene göre gruplandırılması söz konusudur. Kullanımı, tek yönlü anova ile hemen hemen aynıdır. Örneğin, üniversite öğrencileri arasında gerçekleştirilen bir araştırmada, cinsiyet ve spor yapmanın kızgınlık ifadesine olan etkisi ölçülmek istensin. Aşağıdaki R Kodunu inceleyiniz.

```
library(foreign)

veri = read.dbf('ikitable.dbf')

aov.ornek = aov(Anger_Expr~Gender*Sports, data=veri)

summary(aov.ornek)
```

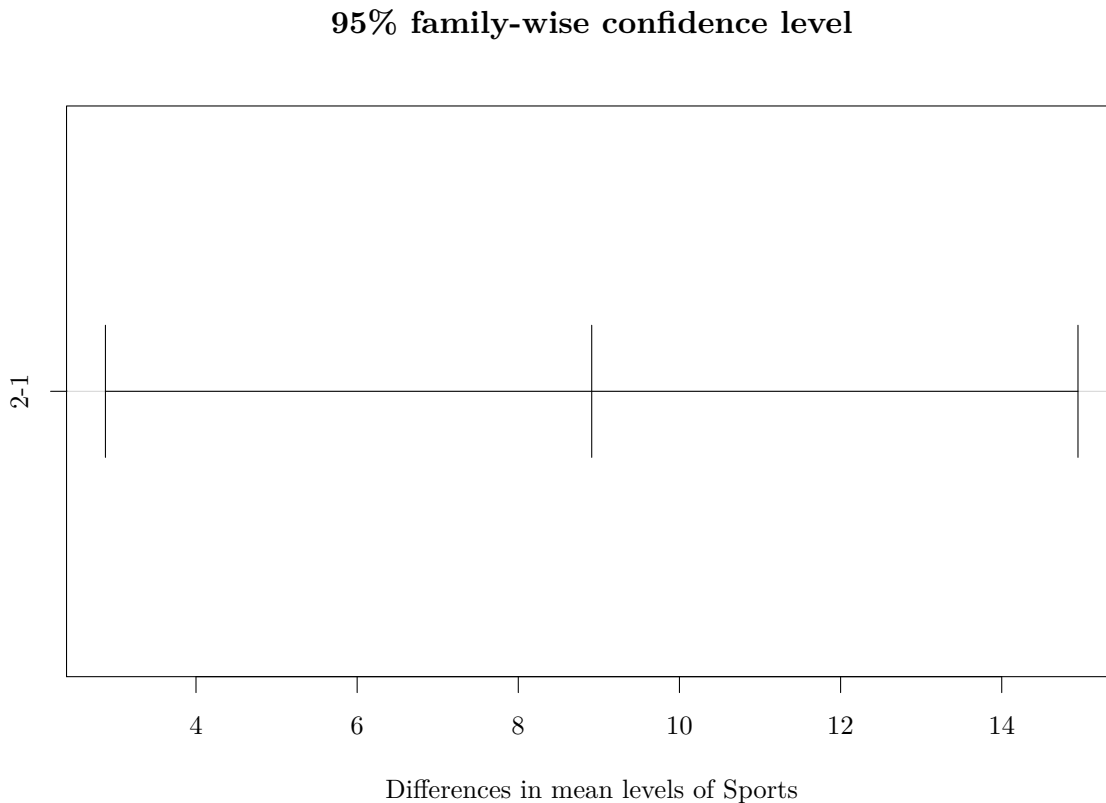
```
##              Df Sum Sq Mean Sq F value Pr(>F)
## Gender         1      1      1.4    0.009 0.92598
## Sports         1   1357   1357.2    8.709 0.00424 **
## Gender:Sports   1      5      5.2    0.034 0.85505
## Residuals     74  11532   155.8
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Örneğe göre sadece spor faktörünün kızgınlık ifadesi üzerinde etkisi anlamlı farklılıklar göstermektedir. Bu durumda Post Hoc testlerini sadece Sport faktörüne göre gerçekleştirebilirsiniz.

```
TukeyHSD(x=aov.ornek, which="Sports")
```

```
## Tukey multiple comparisons of means
## 95% family-wise confidence level
##
## Fit: aov(formula = Anger_Expr ~ Gender * Sports, data = veri)
##
## $Sports
##      diff      lwr      upr      p adj
## 2-1 8.911132 2.875994 14.94627 0.0043509
```

```
plot(TukeyHSD(x=aov.ornek, which="Sports"))
```



Burada da görüldüğü gibi 1 nolu spor grubu ile 2 nolu spor grubu arasındaki fark istatistiksel olarak anlamlıdır.

İlk çıktıya dikkat ettiyseniz, çıktıda belirtmediğiniz halde üç faktörün etkisi gözükmemektedir. Bunlar, *Sports*, *Gender* ve *Sports:Gender* olarak sıralanmaktadır. Üçüncü faktör, iki değişkenin bileşke etki faktörüdür ve bu faktörde anlamlı bir fark bulunursa, bu faktör ile ilgili ikili fark testleri aşağıdaki şekilde gerçekleştirilebilir.

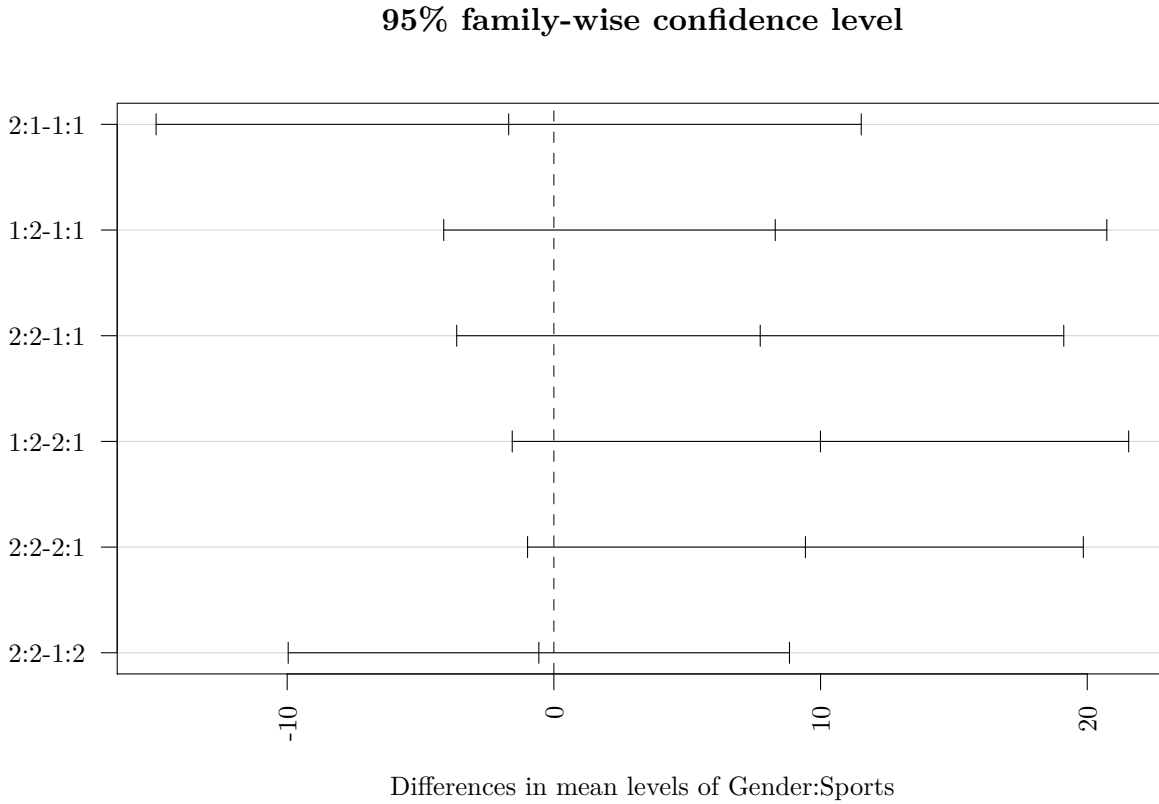
```
TukeyHSD(x=aov.ornek, which="Gender:Sports")
```

```
## Tukey multiple comparisons of means
```



```
##      95% family-wise confidence level
##
## Fit: aov(formula = Anger_Expr ~ Gender * Sports, data = veri)
##
## $`Gender:Sports`
##              diff          lwr          upr      p adj
## 2:1-1:1 -1.6948052 -14.9150197 11.525409 0.9867186
## 1:2-1:1  8.3014354  -4.1298588 20.732730 0.3031425
## 2:2-1:1  7.7379679  -3.6435272 19.119463 0.2877415
## 1:2-2:1  9.9962406  -1.5607567 21.553238 0.1136570
## 2:2-2:1  9.4327731  -0.9867058 19.852252 0.0900007
## 2:2-1:2 -0.5634675  -9.9617941  8.834859 0.9985940
```

```
plot(TukeyHSD(x=aov.ornek, which="Gender:Sports"), las=2)
```



9.4 Tek Yönlü MANOVA Testi

Tek yönlü MANOVA testi birden çok bağımlı değişkenin, bağımsız gruplara göre ortalamalarının farkını ölçmek amacıyla kullanılır. Varsayımları tek yönlü ANOVA testi ile aynıdır. Yalnız normallik testini gerçekleştirebilmeniz için, tek değişkenli normallik testleri yerine çok değişkenli normallik testlerini kullanmanız gerekmektedir. Hacettepe üniversitesi tarafından geliştirilmiş olan **MVN**

kütüphanesini kullanabilirsiniz. Bu kütüphanede 3 adet çok değişkenli normal dağılım test fonksiyonu bulunmaktadır; bunlar: *mardiaTest*, *hzTest* ve *roystonTest* fonksiyonlarıdır.

Örnek olarak, bir tarım ürününün verimini, kuru ağırlığını ve optik yoğunluğunu ölçmek için yapılan deneylerde sıcaklık ve gübre etken maddesi ölçülmüştür. İlk olarak, değişkenlerin çok boyutlu normal dağılıma sahip olup olmadıklarına bakalım. Aşağıdaki R kodunu inceleyiniz.

```
library(MVN)
veri = read.dbf('manova.dbf')

t = mardiaTest(veri[c('Dry_weight', 'Optical_de', 'Product_yi')])
print(t)
```

```
##      Mardia's Multivariate Normality Test
## -----
##      data : veri[c("Dry_weight", "Optical_de", "Product_yi")]
##
##      g1p           : 4.359416
##      chi.skew       : 87.18832
##      p.value.skew   : 1.929952e-14
##
##      g2p           : 24.37664
##      z.kurtosis     : 9.376643
##      p.value.kurt   : 0
##
##      chi.small.skew : 90.4898
##      p.value.small  : 4.282393e-15
##
##      Result        : Data are not multivariate normal.
## -----
```

```
t = hzTest(veri[c('Dry_weight', 'Optical_de', 'Product_yi')])
print(t)
```




```
##      Henze-Zirkler's Multivariate Normality Test
## -----
##      data : veri[c("Dry_weight", "Optical_de", "Product_yi")]
##
##      HZ           : 1.164483
##      p-value      : 0.007373855
##
##      Result      : Data are not multivariate normal.
## -----
```

```
t = roystonTest(veri[c('Dry_weight', 'Optical_de', 'Product_yi')])
print(t)
```

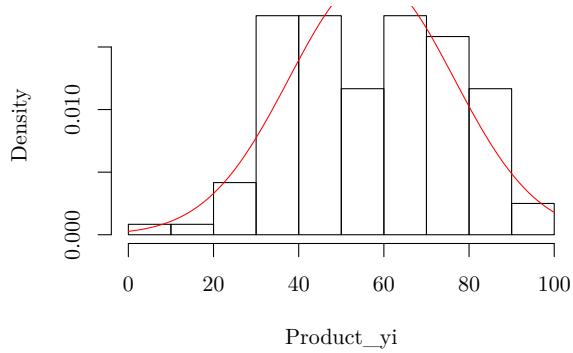
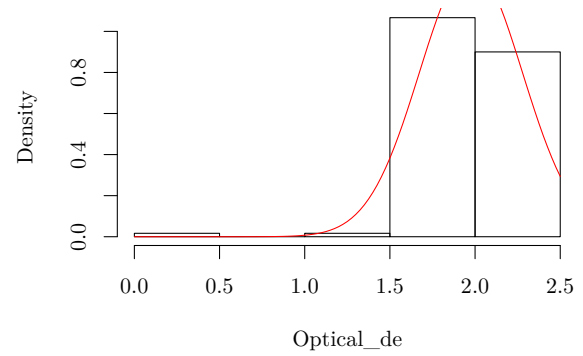
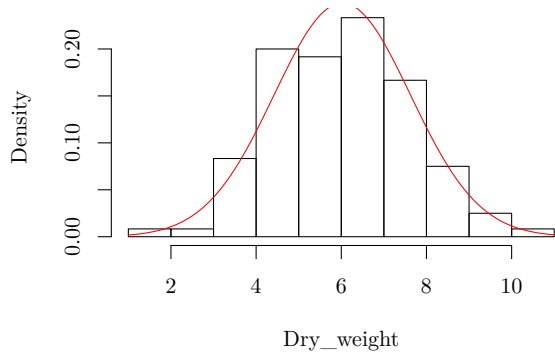
```
##   Royston's Multivariate Normality Test
##   -----
##   data : veri[c("Dry_weight", "Optical_de", "Product_yi")]
##
##   H      : 40.81487
##   p-value : 6.40649e-09
##
##   Result  : Data are not multivariate normal.
##   -----
```

Ayrıca, bu durum grafiksel olarak incelenebilir.


```
uniPlot(veri[c('Dry_weight', 'Optical_de', 'Product_yi')],
        type = "qqplot")
```



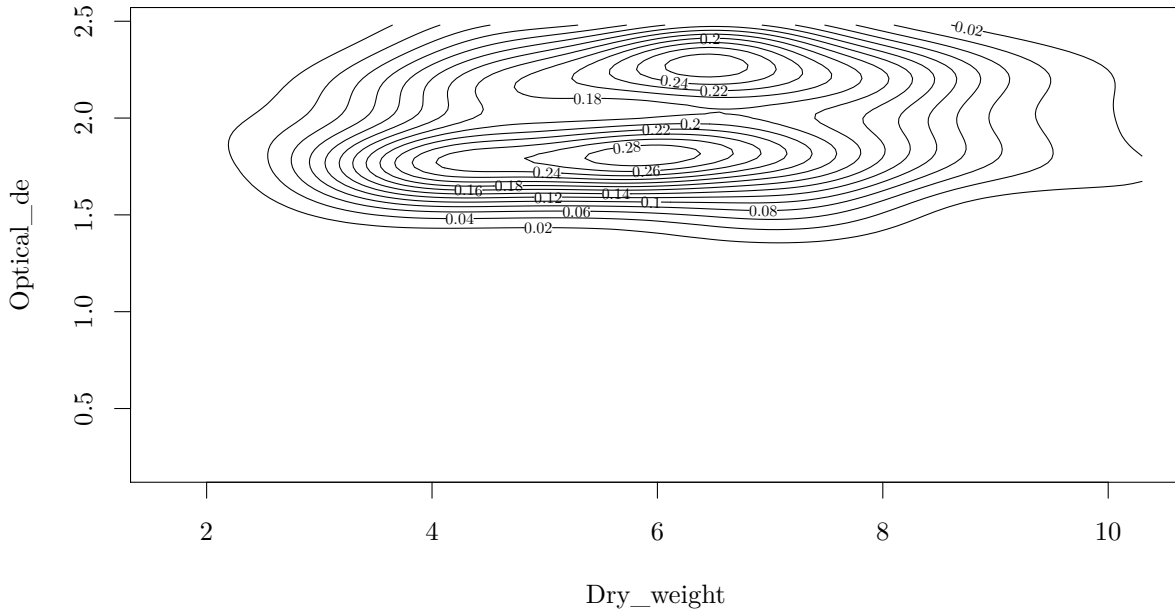
```
uniPlot(veri[c('Dry_weight', 'Optical_de', 'Product_yi')],
        type = "histogram")
```



```
result = hzTest(veri[c('Dry_weight', 'Optical_de')])
mvnPlot(result, type="persp", default = TRUE)
```



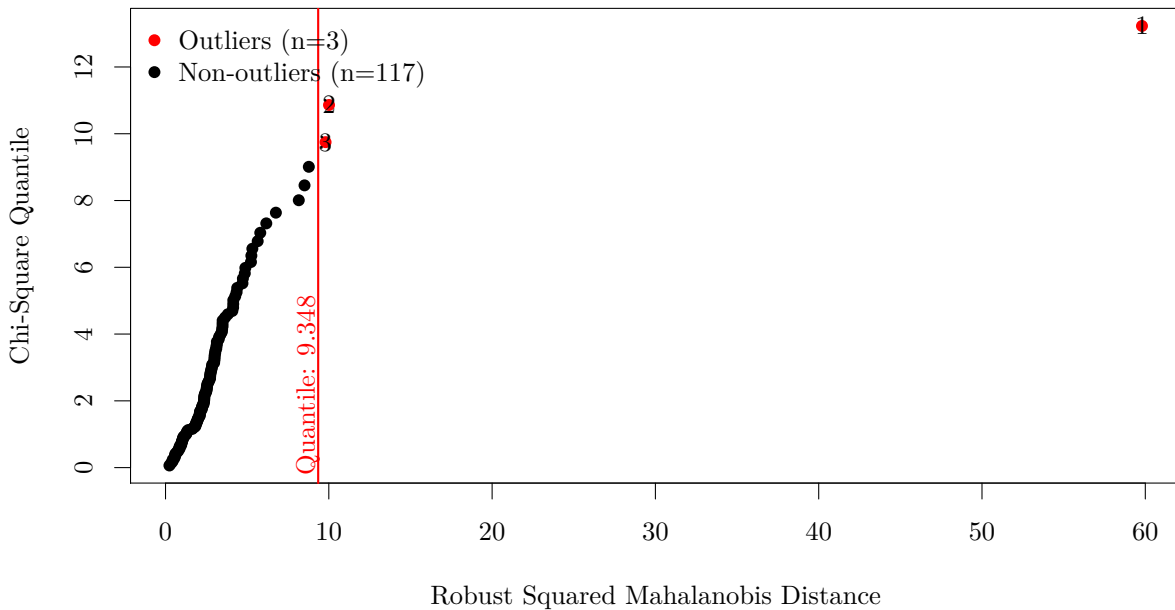
```
result = hzTest(veri[c('Dry_weight', 'Optical_de')])
mvnPlot(result, type="contour", default = TRUE)
```



MANOVA aykırı değerlerden çok fazla etkilendiği için bu değerlerin bulunması ve gerekliyse veriden ayıklanması önemlidir. Bu sebeple yine **MVN** kütüphanesindeki fonksiyonlar kullanılabilir.

```
result <- mvOutlier(veri[c('Dry_weight', 'Optical_de', 'Product_yi')],
                    qqplot = TRUE, method = "quan")
```

Chi-Square Q-Q Plot



```
print(result)
```

Örneğe göre, verimiz normal olmamasına rağmen uygulama olması açısından manova testi gerçekleştirilecektir. Tek yönlü manova testinde birden çok bağımlı değişken ve tek faktör değişkeni mevcuttur. Aşağıdaki R kodunu inceleyiniz.

```
man.ornek = manova(cbind(Product_yi, Optical_de)~Temperatur, data=veri)

summary(man.ornek)
```

```
##              Df    Pillai approx F num Df den Df Pr(>F)
## Temperatur    2 0.025337  0.75063      4    234 0.5585
## Residuals   117
```

Bu çıktıda, MANOVA testi için *Pillai* düzeltmesi yapılmıştır. Alternatifleriniz aşağıda belirtilmiştir.

```
summary(man.ornek, test="Pillai")
```

```
##              Df    Pillai approx F num Df den Df Pr(>F)
## Temperatur    2 0.025337  0.75063      4    234 0.5585
## Residuals   117
```

```
summary(man.ornek, test="Wilks")
```

```
##              Df   Wilks approx F num Df den Df Pr(>F)
## Temperatur    2 0.9747  0.74801      4    232 0.5602
## Residuals   117
```

```
summary(man.ornek, test="Hotelling-Lawley")
```

```
##              Df Hotelling-Lawley approx F num Df den Df Pr(>F)
## Temperatur    2      0.025924  0.74533      4    230 0.562
## Residuals   117
```

```
summary(man.ornek, test="Roy")
```

```
##              Df      Roy approx F num Df den Df Pr(>F)
## Temperatur    2 0.02448  1.4321      2    117 0.243
## Residuals   117
```

Örneğin detaylı çıktısı için *summary.aov* fonksiyonu kullanılmalıdır.

```
summary.aov(man.ornek)
```

```
## Response Product_yi :
##              Df Sum Sq Mean Sq F value Pr(>F)
## Temperatur    2     81   40.46   0.106 0.8995
## Residuals   117  44659   381.70
##
## Response Optical_de :
##              Df Sum Sq Mean Sq F value Pr(>F)
## Temperatur    2  0.1656  0.082808   0.9035  0.408
## Residuals   117 10.7237  0.091656
```

9.5 İki Yönlü MANOVA Testi

İki yönlü ANOVA testinin, birden çok bağımlı değişkene sahip halidir. Bu sebeple, ANOVA'nın bütün varsayımlarına sahiptir. İki yönlü ANOVA testi için kullandığımız örneği, değiştirip bağımlı değişkenlerin sayısını 2'ye çıkartalım. Aşağıdaki R kodunu inceleyiniz.

```
library(foreign)

veri = read.dbf('ikitable.dbf')

man.ornek = manova(cbind(Anger_In, Anger_Out)~Gender*Sports, data=veri)

summary(man.ornek)
```

```
##              Df Pillai approx F num Df den Df Pr(>F)
## Gender         1 0.015597   0.5783      2    73 0.5634
## Sports         1 0.100906   4.0964      2    73 0.0206 *
## Gender:Sports  1 0.000101   0.0037      2    73 0.9963
## Residuals      74
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Detaylı farklarda aşağıdaki gibi olacaktır.

```
summary.aov(man.ornek)
```

```
## Response Anger_In :
##              Df Sum Sq Mean Sq F value Pr(>F)
## Gender         1   10.16   10.155   0.4849 0.48839
## Sports         1  139.04  139.037   6.6389 0.01197 *
## Gender:Sports  1    0.10    0.096   0.0046 0.94631
```

```
## Residuals      74 1549.75  20.943
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Response Anger_Out :
##           Df Sum Sq Mean Sq F value Pr(>F)
## Gender      1   11.69  11.6926   0.6498 0.4228
## Sports      1   26.18  26.1827   1.4550 0.2316
## Gender:Sports 1    0.05   0.0478   0.0027 0.9590
## Residuals   74 1331.62  17.9948
```

Detaylı incelememize göre *Anger_In* değişkeninin *Sports* değişkenine farkı istatistiksel olarak anlamlıdır.

9.6 Kruskal Wallis Testi

Kruskal-Wallis testi tek yönlü ANOVA testinin parametrik olmayan halidir. Grupların Normal dağılması varsayımını göz ardı etmesine rağmen, gruplara ait dağılımların şekillerinin aynı olması varsayımı bulunmaktadır. Bu sebeple, bu testi yapmaya geçmeden önce grup dağılımlarının benzer şekilli olmasını test etmelisiniz. Aşağıdaki R kodlarını inceleyin.

```
veri = read.csv2('fildisi.csv')
kw.ornek = kruskal.test(delta13C~bolge, data = veri)

print(kw.ornek)
```

```
##
## Kruskal-Wallis rank sum test
##
## data:  delta13C by bolge
## Kruskal-Wallis chi-squared = 108.33, df = 4, p-value < 2.2e-16
```

Örnekte de gördüğümüz gibi, gruplar arasında anlamlı farklılıklar bulunmaktadır. Bu durumda, Kruskal-Wallis PostHoc testleri ile farkın hangi gruplar arasında olduğunun incelenmesi gerekmektedir. Aşağıda, R ile kullanabileceğiniz Kruskal-Wallis Post Hoc testlerinin bir listesi bulunmaktadır.

- Dunn Testi (Burada method yerine FWER'deki bütün değerleri kullanabilirsiniz.)

```
library(FSA)
t=dunnTest(delta13C~bolge, data = veri, method = "bonferroni")
print(t)
```



```
##              Comparison      Z      P.unadj      P.adj
## 1      Asya - Batı Afrika  2.1374935 3.255788e-02 3.255788e-01
## 2      Asya - Doğu Afrika -0.8541105 3.930438e-01 1.000000e+00
## 3  Batı Afrika - Doğu Afrika -5.5522548 2.820082e-08 2.820082e-07
## 4      Asya - Güney Afrika -0.6928241 4.884199e-01 1.000000e+00
## 5  Batı Afrika - Güney Afrika -7.7345599 1.037614e-14 1.037614e-13
## 6  Doğu Afrika - Güney Afrika  0.4801572 6.311156e-01 1.000000e+00
## 7      Asya - Orta Afrika  1.7741102 7.604492e-02 7.604492e-01
## 8  Batı Afrika - Orta Afrika -0.9962281 3.191393e-01 1.000000e+00
## 9  Doğu Afrika - Orta Afrika  5.2160090 1.828193e-07 1.828193e-06
## 10 Güney Afrika - Orta Afrika  8.1281850 4.357658e-16 4.357658e-15
```

- Nemenyi Testi (Burada dist değişkenine “tukey” veya “chisq” değerlerini verebilirsiniz)

```
library(DescTools)
t = NemenyiTest(x = veri$delta13C, g=veri$bolge, dist = "tukey")
print(t)
```

```
##
## Nemenyi's test of multiple comparisons for independent samples (tukey)
##
##              mean.rank.diff      pval
## Batı Afrika-Asya          -114.17120 0.2043
## Doğu Afrika-Asya           47.62669 0.9135
## Güney Afrika-Asya          35.56394 0.9581
## Orta Afrika-Asya          -92.64583 0.3889
## Doğu Afrika-Batı Afrika    161.79788 2.8e-07 ***
## Güney Afrika-Batı Afrika    149.73513 1.3e-13 ***
## Orta Afrika-Batı Afrika     21.52536 0.8573
## Güney Afrika-Doğu Afrika   -12.06275 0.9892
## Orta Afrika-Doğu Afrika    -140.27252 1.8e-06 ***
## Orta Afrika-Güney Afrika   -128.20977 6.6e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- İkili Mann-Whitney U Testleri

```
t = pairwise.wilcox.test(veri$delta13C, veri$bolge,
                          p.adjust.method = "bonferroni")
print(t)
```

```
##
## Pairwise comparisons using Wilcoxon rank sum test
##
```

```
## data: veri$delta13C and veri$bolge
##
##           Asya Batı Afrika Doğu Afrika Güney Afrika
## Batı Afrika 0.43 -           -           -
## Doğu Afrika 1.00 4.0e-06    -           -
## Güney Afrika 1.00 < 2e-16    1.00        -
## Orta Afrika 0.57 1.00      9.1e-05     4.1e-13
##
## P value adjustment method: bonferroni
```

9.7 Friedman Testi

Bu test iki yönlü ANOVA testinin parametrik olmayan halidir. Kruskal-Wallis ile aynı varsayımlara sahiptir. Ayrıca, deneyin tam anlamıyla dengeli olmasını yani her grupta eşit eleman ve en az iki grup olmasını gerektirmektedir. Örneğin, öğrencilerin dersi sevmeleri ders veren öğretim elemanları ve sınavları okuyan kişilere göre değişip değişmediği ölçülmek istensin. Bu test aşağıdaki şekilde R ile gerçekleştirilebilir.

```
library(foreign)
veri = read.dbf('ikitable.dengeli.dbf')
t=friedman.test(Likert~Instructor|Rater, data = veri)
print(t)

##
## Friedman rank sum test
##
## data: Likert and Instructor and Rater
## Friedman chi-squared = 23.139, df = 4, p-value = 0.0001188
```

Bu test için kullanacağınız PostHoc Testlerde aşağıdaki gibidir.

- İkili İşaret Testi (Her faktör için ayrı ayrı gerçekleştirilir.)

```
library(rcompanion)
t = pairwiseSignMatrix(Likert ~ Instructor,
                        data = veri,
                        method = "bonferroni")
print(t)

## $Unadjusted
##           Bob Belcher Gene Belcher Linda Belcher Louise Belcher
## Bob Belcher           NA          0.6875          0.015630          0.070310
## Gene Belcher           NA           NA          0.007813          0.007813
## Linda Belcher           NA           NA           NA          0.375000
```

```
t = pairwiseSignMatrix(Likert ~ Rater,
                        data    = veri,
                        method = "bonferroni")
print(t)
```

```
## $Unadjusted
##      a      b      c      d      e      f      g      h
## a NA 0.375 1.000 1.0000 0.2500 0.6250 0.6250 0.3750
## b NA    NA 0.375 0.0625 0.0625 0.0625 0.0625 0.0625
## c NA    NA    NA 0.5000 0.1250 0.3750 0.2500 0.1250
## d NA    NA    NA    NA 0.5000 0.6250 0.2500 0.2500
## e NA    NA    NA    NA    NA 1.0000 1.0000 0.6250
## f NA    NA    NA    NA    NA    NA 1.0000 1.0000
## g NA    NA    NA    NA    NA    NA    NA 0.6250
## h NA    NA    NA    NA    NA    NA    NA    NA
##
## $Method
## [1] "bonferroni"
```

```
##
## $Adjusted
##  a b c d e f g h
## a 1 1 1 1 1 1 1 1
## b 1 1 1 1 1 1 1 1
## c 1 1 1 1 1 1 1 1
## d 1 1 1 1 1 1 1 1
## e 1 1 1 1 1 1 1 1
## f 1 1 1 1 1 1 1 1
## g 1 1 1 1 1 1 1 1
## h 1 1 1 1 1 1 1 1
```

- Conover Testi

```
library(PMCMR)
t = posthoc.friedman.conover.test(y      = veri$Likert,
                                   groups = veri$Instructor,
                                   blocks  = veri$Rater,
                                   p.adjust.method="bonferroni")

print(t)
```

```
##
## Pairwise comparisons using Conover's test for a two-way
## balanced complete block design
##
## data:  veri$Likert , veri$Instructor and veri$Rater
##
##          Bob Belcher Gene Belcher Linda Belcher Louise Belcher
## Gene Belcher  1.00000      -          -          -
## Linda Belcher 0.00014    2.3e-06      -          -
## Louise Belcher 5.7e-06    1.1e-07    1.00000      -
## Tina Belcher  0.00223    3.5e-05    1.00000    0.36077
##
## P value adjustment method: bonferroni
```

9.8 Welch ve Brown-Forsythe Testleri

ANOVA testinin varyans homojenliği şartı sağlanmadığı durumlarda, kruskall-wallis testine alternatif güçlü (robust) bir alternatiftir. Welch testi, test istatistiğinin serbestlik derecesini değiştirirken, Brown-Forsythe ise farklı bir F istatistiği kullanmaktadır. Yapılan araştırmalarda Welch testinin istatistiksel gücünün fazla olduğu bulunmuştur. Bu testlerin R ile kullanımları aşağıdaki şekilde verilmiştir.

```
library(onewaytests)
veri = read.csv2('fildisi.csv')
t = bf.test(veri$delta13C, veri$bolge)
```

```
##
##   Brown-Forsythe Test
## -----
##   data : veri$delta13C and veri$bolge
##
##   statistic   : 18.68663
##   num df      : 4
##   denom df    : 26.17584
##   p.value     : 2.282741e-07
##
##   Result      : Difference is statistically significant.
## -----
```

```
t = welch.test(veri$delta13C, veri$bolge)
```

```
##
##   Welch's Heteroscedastic F Test
## -----
##   data : veri$delta13C and veri$bolge
##
##   statistic   : 28.55471
##   num df      : 4
##   denom df    : 43.38833
##   p.value     : 1.175298e-11
##
##   Result      : Difference is statistically significant.
## -----
```

Bu testleri gerçekleştirdikten sonra, kullanılacak post hoc testler, varyans homojenliği sağlanmadığı durumda kullanılacak ANOVA post hoc testleri ile aynıdır.

Uygulama: New York Belediyesi Eğitim Durumu Değerlendirmesi

New York Belediyesinin, şehir genelinde düzenlenen İngilizce ve Sanat Sınavı ile ilgili istatistikleri içeren sınavına ait veriler *sitemizde* verilmiştir. Verinin yapısı aşağıdaki gibidir.

Alan Adı	Açıklama
Okul.Adı	Okul Adı
Sınıf	Sınıf
Yıl	Sınav Yılı
Okul.Tur	Okul Türü
OgrenciSayisi	Sınava Katılan Öğrenci Sayısı
Ortalama.Puan	Öğrencilerin Ortalama Başarı Puanları
Seviye.1.Sayi	Sınav Sonucu 1. Seviye Öğrenci Sayısı
Seviye.1.Yuzde	Sınav Sonucu 1. Seviye Öğrenci Yüzdesi
Seviye.2.Sayi	Sınav Sonucu 2. Seviye Öğrenci Sayısı
Seviye.2.Yuzde	Sınav Sonucu 2. Seviye Öğrenci Yüzdesi
Seviye.3.Sayi	Sınav Sonucu 3. Seviye Öğrenci Sayısı
Seviye.3.Yuzde	Sınav Sonucu 3. Seviye Öğrenci Yüzdesi
Seviye.4.Sayi	Sınav Sonucu 4. Seviye Öğrenci Sayısı
Seviye.4.Yuzde	Sınav Sonucu 4. Seviye Öğrenci Yüzdesi
Seviye.3.ve.4.Sayi	Sınav Sonucu 3. ve 4. Seviye Öğrenci Sayısı
Seviye.3.ve.4.Yuzde	Sınav Sonucu 3. ve 4. Seviye Öğrenci Yüzdesi

Bu verileri indirip, aşağıdaki analizlerin sonuçlarını elde etmek için gerekli R komutlarını yazınız.

Aşağıdaki değişkenler için gerekli tabloları oluşturunuz. Veri bir RData dosyası olduğundan aşağıdaki gibi yüklenmelidir.

```
load('NewYorkAnalizUygulama.RData')
```

10.1 Uygulama 1: Tanımlayıcı İstatistikler

- Verinin Tanımlayıcı İstatistiklerini Bulan R Kodunu yazınız.
- Yıllara Göre Bütün Sayısal Değişkenlerin Tanımlayıcı İstatistiklerini Bulunuz.
- Sınıflara Göre Bütün Sayısal Değişkenlerin Tanımlayıcı İstatistiklerini Bulunuz.

10.2 Uygulama 2: Çapraz Tablolar

- Okul Türü ile Sınıf arasındaki çapraz tabloyu oluşturup, aralarında ilişki olup olmadığını bulunuz.
- Okul Türü ile Yıl arasındaki çapraz tabloyu oluşturup, aralarında ilişki olup olmadığını bulunuz.
- Sınıf ile Yıl arasındaki çapraz tabloyu oluşturup, aralarında ilişki olup olmadığını bulunuz.

10.3 Uygulama 3: Tek Örnek Testleri

- Öğrenci sayılarının ortalamasının veya medyanının (hangisi olduğunu siz seçmelisiniz) 20 olup olmadığını bulunuz. Gerekli ise 20'den büyüklük küçüklük hakkında bilgi veriniz.
- Öğrenci ortalamasının veya medyanının 300 olup olmadığını bulunuz. Gerekli ise 300'den büyüklük küçüklük hakkında bilgi veriniz.
- 1. Seviye öğrenci sayılarının ortalamasının veya medyanının 15 olup olmadığını bulunuz. Gerekli ise 15'ten büyüklük küçüklük hakkında bilgi veriniz.
- 1. Seviye öğrenci yüzdelerinin ortalamasının veya medyanının 50 olup olmadığını bulunuz. Gerekli ise 50'den büyüklük küçüklük hakkında bilgi veriniz.
- 2. Seviye öğrenci sayılarının ortalamasının veya medyanının 15 olup olmadığını bulunuz. Gerekli ise 15'ten büyüklük küçüklük hakkında bilgi veriniz.
- 2. Seviye öğrenci yüzdelerinin ortalamasının veya medyanının 50 olup olmadığını bulunuz. Gerekli ise 50'den büyüklük küçüklük hakkında bilgi veriniz.
- 3. Seviye öğrenci sayılarının ortalamasının veya medyanının 10 olup olmadığını bulunuz. Gerekli ise 10'ten büyüklük küçüklük hakkında bilgi veriniz.
- 3. Seviye öğrenci yüzdelerinin ortalamasının veya medyanının 10 olup olmadığını bulunuz. Gerekli ise 10'den büyüklük küçüklük hakkında bilgi veriniz.
- 4. Seviye öğrenci sayılarının ortalamasının veya medyanının 5 olup olmadığını bulunuz. Gerekli ise 5'ten büyüklük küçüklük hakkında bilgi veriniz.
- 4. Seviye öğrenci yüzdelerinin ortalamasının veya medyanının 10 olup olmadığını bulunuz. Gerekli ise 10'den büyüklük küçüklük hakkında bilgi veriniz.

10.4 Uygulama 4: İki Örnek Testleri

- 1. Seviye Öğrenci Sayılarının 2. Seviye Öğrenci Sayılarına eşit olup olmadığını bulunuz. Gerekli ise büyüklük ve küçüklük hakkında bilgi veriniz.
- 3. Seviye Öğrenci Sayılarının 4. Seviye Öğrenci Sayılarına eşit olup olmadığını bulunuz. Gerekli ise büyüklük ve küçüklük hakkında bilgi veriniz.

10.5 Uygulama 5: Çok Örnek Testleri

- Yıllara Göre Öğrenci ortalamaları arasında fark olup olmadığını inceleyiniz. Farklı olan yılları belirleyiniz.
- Okul Türlerine Göre Öğrenci ortalamaları arasında fark olup olmadığını inceleyiniz. Farklı olan okul türlerini belirleyiniz.
- Sınıflara Göre Öğrenci ortalamaları arasında fark olup olmadığını inceleyiniz. Farklı olan sınıfları belirleyiniz.
- Yıllara Göre 1. seviye öğrenci sayıları ve yüzdeleri arasında fark olup olmadığını inceleyiniz. Farklı olan yılları belirleyiniz.
- Okul Türlerine Göre 2. seviye öğrenci sayıları ve yüzdeleri arasında fark olup olmadığını inceleyiniz. Farklı olan okul türlerini belirleyiniz.
- Sınıflara Göre 3. seviye öğrenci sayıları ve yüzdeleri arasında fark olup olmadığını inceleyiniz. Farklı olan sınıfları belirleyiniz.
- Okul Türlerine Göre 4. seviye öğrenci sayıları ve yüzdeleri arasında fark olup olmadığını inceleyiniz. Farklı olan sınıfları belirleyiniz.

Aynı istatistiksel işlemleri New York Belediyesinin matematik sınavlarında uygulayınız.

Korelasyon ve Regresyon Analizi

İstatistik hemen hemen bütün bilim dallarında kullanılmaktadır. Bazı araştırmalarda, birden fazla değişkenin arasındaki ilişkinin incelenmesi gerekmektedir. Bu inceleme sonucunda beklenen değişkenler arasındaki ilişkinin yönü, kuvveti ve yapısının ortaya çıkarılmasıdır. Bu amaçla kullanılması gereken istatistiksel yöntemler regresyon ve korelasyon analizidir.

11.1 Korelasyon

Korelasyon ile iki değişkenin değişimlerinin birbirleri ile bağlantılı olup olmadığı araştırılır. Bu bağlantının yönü ve kuvveti *Korelasyon Katsayısı* ile belirlenir. Burada dikkat edilmesi gereken en önemli nokta, değişkenler arasındaki ilişkinin doğrusal olması gerektiğidir. Doğrusal olmayan bir ilişkinin korelasyonundan bahsedilemez.

11.1.1 Korelasyon Katsayısının Hesaplanması

Korelasyon iki değişkenin değişiminin bağlantısını ifade ettiğinden, ilk olarak bir değişkenin değişiminin nasıl incelendiğine bakalım. Burada, bir değişkenin değişiminin incelenmesi amacıyla, değişkenin aldığı değerlerin ortalama etrafındaki dağılımını ölçen varyans ölçüsü kullanılır. Bu tanımdan yola çıkarak, iki değişkene ait değerlerin ortalamaları etrafındaki dağılımın incelenmesi için kovaryans (covariance) ölçüsü kullanılmaktadır. Bu ölçü, $Cov(X, Y)$ şeklinde veya σ_{xy} şeklinde gösterilir ve aşağıdaki şekilde hesaplanır.

$$Cov(X, Y) = \sigma_{XY} = \frac{\sum_{i=1}^N (X_i - \mu_x)(Y_i - \mu_y)}{N}$$

Burada hesaplanan kovaryans anakütle kovaryansı olup, örneklemden hesaplanan yansız kovaryans formülü aşağıdaki gibi olmaktadır.

$$cov(x, y) = S_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

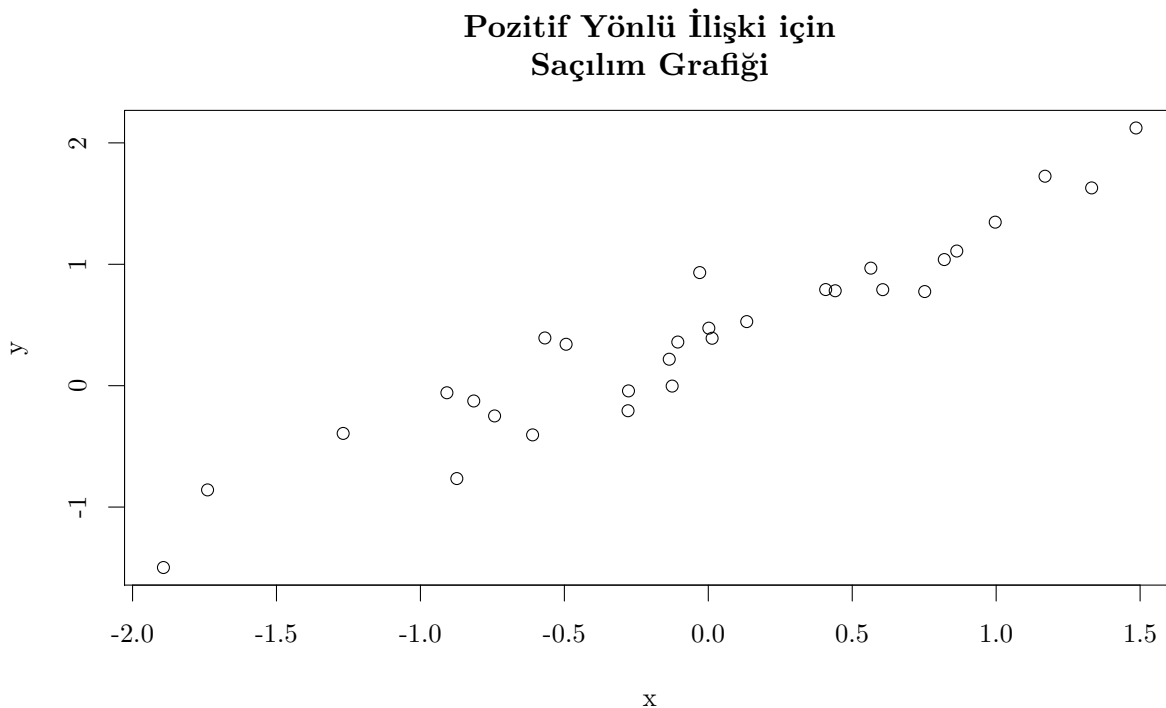
Ancak kovaryans sadece değişken değişimlerinin yönü hakkında bilgi verir. Eğer iki değişken arasındaki kovaryans 0 ise, *değişkenlerin değişimi birbirlerinden bağımsızdır*. Aksi durumlarda, iki değişken arasındaki kovaryans pozitif ise, *değişkenlerin değişimi birbirlerini doğru yönlü olarak (yani bir artarken öbürü de artar)*, veya iki değişken arasındaki kovaryans negatif ise, *değişkenlerin değişimi birbirlerini test yönlü olarak (yani biri artarken öbürü azalır)* etkilemektedir. Bu durumu en iyi şekilde saçılım grafiği ile görselleştirebilirsiniz. Aşağıda R ile iki değişken arasındaki saçılım grafiğinin oluşturulması için gerekli kodlar verilmiştir.

```
set.seed(127)

x = rnorm(30)
e = runif(30)

y = x+e


plot(x,y, main = "Pozitif Yönlü İlişki için\nSaçılım Grafiği")
```



```
y = -2*x+runif(30)


plot(x,y, main="Negatif Yönlü İlişki için\nSaçılım Grafiği")
```

Negatif Yönlü İlişki için
Saçılım Grafiği



```
y = rnorm(30)
plot(x,y, main="Bağımsızlık için\nSaçılım Grafiği")
```

Bağımsızlık için
Saçılım Grafiği



Ancak kovaryans değişkenler arası ilişkinin gücünü ölçmek amacıyla kullanılabilecek bir **ölçü** değildir. Bu amaçla kullanılmak üzere korelasyon katsayısı önerilmiştir. Korelasyon katsayısı,

kovaryans ifadesinin normalleştirilmesi sonucu elde edilen bir ifadedir ve aşağıdaki şekilde hesaplanır.

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

Bu ifadede, ρ_{XY} X ve Y değişkenleri arasındaki korelasyon katsayısını ifade etmektedir. Bu ifade, ana kütle korelasyonu için kullanılacak bir ifade olup, örneklem için hesaplanacak korelasyon katsayısı için σ_{XY} yerine S_{xy} , σ_X yerine S_x ve σ_Y yerine S_y konulur.

$$\begin{aligned} S_{xy} &= \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1} \\ S_x &= \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} \\ S_y &= \sqrt{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1}} \\ r &= \frac{S_{xy}}{S_x S_y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \end{aligned}$$

Son formülde yer alan r değişkeni örneklem için hesaplanan korelasyon katsayısıdır. Gerekli düzenlemeler yapıldığı takdirde r katsayısı aşağıdaki şekilde hesaplanabilir duruma gelecektir.

$$r = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{\sqrt{(\sum_{i=1}^n x_i^2 - n\bar{x}^2)(\sum_{i=1}^n y_i^2 - n\bar{y}^2)}}$$

Korelasyon katsayısı -1 ile +1 arasında değer alır ($-1 \leq r \leq +1$) ve aşağıdaki şekilde yorumlanır.

- $r=0$ ise, değişkenler arasında ilişki bulunmamaktadır.
- $r<0$ ise, değişkenler arasında negatif yönlü bir ilişki bulunmaktadır.
- $r>0$ ise, değişkenler arasında pozitif yönlü bir ilişki bulunmaktadır.

denir. İlişkinin gücü hakkında ise aşağıdaki yorumlarda bulunulabilir.

- $|r| \approx 1$ ise, değişkenler arasında güçlü bir ilişki bulunmaktadır.
- $|r| \approx 0.5$ ise, değişkenler arasında orta dereceli bir ilişki bulunmaktadır.
- $|r| \approx 0$ ise, değişkenler arasında zayıf bir ilişki bulunmaktadır.

11.1.2 İki Değişken Arasındaki Korelasyonun Test Edilmesi

Örneklemden hesaplanan iki değişkenin korelasyon katsayısının istatistiksel olarak anlamlı olup olmadığı test edilmelidir. Bu amaçla kurulacak hipotez testi aşağıdaki gibidir.

$$H_0 : \rho = 0$$

$$H_1 : \rho \neq 0$$

$$H_1 : \rho > 0$$

$$H_1 : \rho < 0$$

Bu testin gerçekleştirilebilmesi için gerekli test istatistiği aşağıdaki şekildedir.

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

Test istatistiğinden de anlaşılacağı gibi kullanılan dağılım $n-2$ serbestlik dereceli t -dağılımıdır. Şimdi biraz önce grafiklerini çizdiğimiz değişkenler arasındaki korelasyon katsayısının anlamlılığını test edelim. Bunun için r ile beraber gelen *cor.test* fonksiyonunu kullanacağız. Bu fonksiyon hem parametrik hemde parametrik olmayan korelasyon katsayısı testini içermektedir. Değişkenlerimizin ikisi de normal dağılıma sahip olduğu için parametrik korelasyon katsayısı testi olan “Pearson Korelasyon Testini” gerçekleştirelim.

```
set.seed(127)

x = rnorm(30)
e = runif(30)

y = x+e

t = cor.test(x,y,method = "pearson")

if(t$p.value<0.05) {
  # Korelasyon katsayısı 0'dan farklı
  # Acaba sıfırdan büyük mü?
  t = cor.test(x,y,method = "pearson", alternative = "g")
  if(t$p.value<0.05) {
    # Evet Büyük
    cat("Korelasyon katsayısı 0'dan büyüktür r=",
        t$estimate," p=",t$p.value,"\n")
  } else {
    # Hayır Küçük
    cat("Korelasyon katsayısı 0'dan küçüktür r=",
        t$estimate," p=",1-t$p.value,"\n")
  }
} else {
  # Korelasyon katsayısı 0'dan farklı değil!
```

```
cat("Korelasyon katsayısı 0'dır r=",
    t$estimate, " p=", t$p.value, "\n")
}
```

```
## Korelasyon katsayısı 0'dan büyüktür r= 0.9476611 p= 1.027784e-15
```

```
y = -2*x+runif(30)

t = cor.test(x,y,method = "pearson")

if(t$p.value<0.05) {
  # Korelasyon katsayısı 0'dan farklı
  # Acaba sıfırdan büyük mü?
  t = cor.test(x,y,method = "pearson", alternative = "g")
  if(t$p.value<0.05) {
    # Evet Büyük
    cat("Korelasyon katsayısı 0'dan büyüktür r=",
        t$estimate, " p=", t$p.value, "\n")
  } else {
    # Hayır Küçük
    cat("Korelasyon katsayısı 0'dan küçüktür r=",
        t$estimate, " p=", 1-t$p.value, "\n")
  }
} else {
  # Korelasyon katsayısı 0'dan farklı değil!
  cat("Korelasyon katsayısı 0'dır r=",
      t$estimate, " p=", t$p.value, "\n")
}
```

```
## Korelasyon katsayısı 0'dan küçüktür r= -0.9851325 p= 0
```

```
y = rnorm(30)

t = cor.test(x,y,method = "pearson")

if(t$p.value<0.05) {
  # Korelasyon katsayısı 0'dan farklı
  # Acaba sıfırdan büyük mü?
  t = cor.test(x,y,method = "pearson", alternative = "g")
  if(t$p.value<0.05) {
    # Evet Büyük
    cat("Korelasyon katsayısı 0'dan büyüktür r=",
        t$estimate, " p=", t$p.value, "\n")
  } else {
```



```

# Hayır Küçük
cat("Korelasyon katsayısı 0'dan küçüktür r=",
    t$estimate, " p=", 1-t$p.value, "\n")
}
} else {
# Korelasyon katsayısı 0'dan farklı değil!
cat("Korelasyon katsayısı 0'dır r=",
    t$estimate, " p=", t$p.value, "\n")
}

```


```
## Korelasyon katsayısı 0'dır r= 0.1260301 p= 0.5069351
```

Gördüğünüz gibi rastgele sayılar ile oluşturduğumuz test ortamında korelasyon katsayıları ile ilgili test x ve y değişkeni arasındaki ilişkinin yönünü doğru olarak buldu. Şimdi gerçek bir veride bu testleri gerçekleştirelim. Ancak burada bütün değişkenler arasındaki ilişkinin bulunması işlemini grafiksel olarak yapmaya çalışalım. İlk olarak, saçılım grafiğinin bütün değişkenler için yapılan hali olan *Çoklu Saçılım Grafiğini* inceleyelim. Çoklu saçılım grafiği *pairs* fonksiyonu ile yapılır. Aşağıdaki R kodlarını inceleyiniz.

```

veri = read.csv2('imports-85.csv')
sVeri = veri[c("Fiyat", "MotorHacmi", "BeygirGucu",
               "SehirIciHarcama", "SehirDisiHarcama")]
# Fiyat, Motor Hacmi ve Beygir Gucu arasındaki ilişkiyi
# Grafiksel olarak çizelim.
pairs(~Fiyat+MotorHacmi+BeygirGucu, data=sVeri,
      main="Çoklu Saçılım Grafikleri")

```

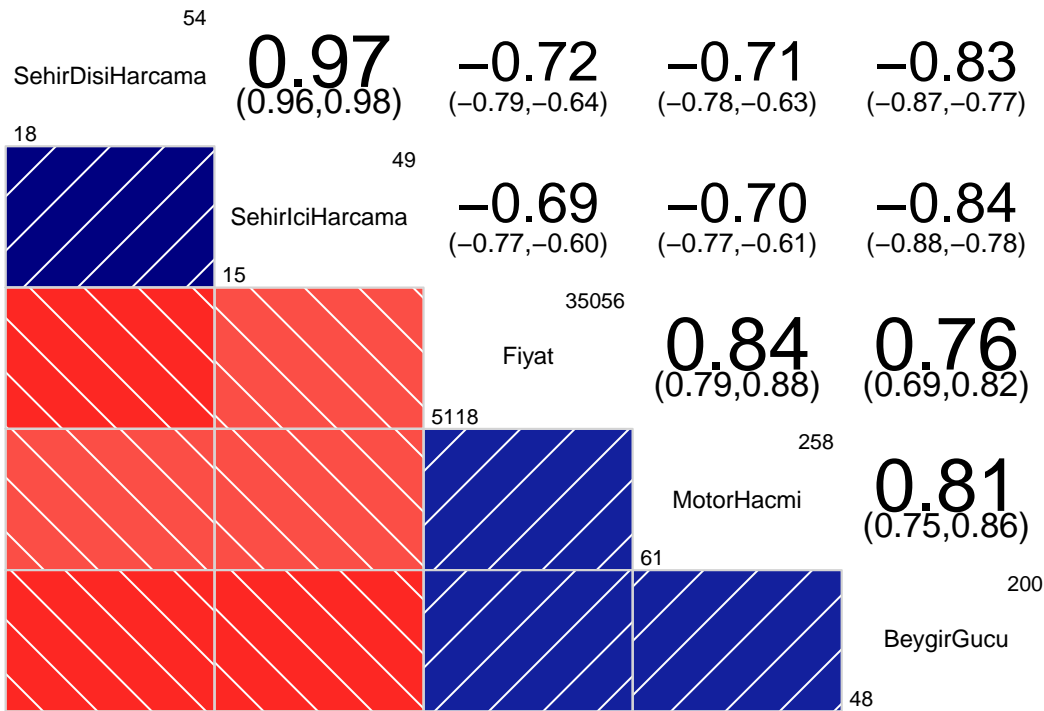


Çoklu saçılım grafiği değişkenler arasındaki korelasyon hakkında bilgi vermemektedir. Bu sebeple, *corrgram* paketinde yer alan **corrgram** fonksiyonunu kullanmanız yeterlidir. Aşağıdaki R kodlarını inceleyiniz.

```
library(corrgram)

corrgram(sVeri, order = TRUE, lower.panel = panel.shade,
         upper.panel = panel.conf, diag.panel = panel.minmax,
         main = "Pearson Korelogram", cor.method = "pearson")
```

Pearson Korelogram



Pearson korelasyon testi *normal dağılıma* sahip değişkenler arasındaki farkları incelemek için kullanılmaktadır. **Buradaki normallikten kasıt, incelenecek olan değişkenlerin ortak olarak normal dağılıma yani çok değişkenli normal dağılıma sahip olmalarıdır.** Ancak pratikte, iki değişkende tek başlarına normalse, çok boyutlu normallik varsayımının sağlandığı kabul edilebilir. Aksi durumlarda, Pearson korelasyon yerine, *Spearman Sıra Sayı Korelasyonu* yöntemi kullanılmalıdır. R ile Spearman korelasyon testi yine *cor.test* fonksiyonu ile gerçekleştirilir. Aşağıda Pearson korelasyon için gerçekleştirilen örneklerin Spearman korelasyon ile gerçekleştirilmiş durumları yer almaktadır. (NOT: Örneklerin normal dağılıma sahip olduğu görülmektedir. Aşağıda amaç sadece Spearman korelasyon testinin kullanımını **anlatmaktır**.)

```
set.seed(127)
```

```
x = rnorm(30)
```

```

e = runif(30)

y = x+e

t = cor.test(x,y,method = "spearman")

if(t$p.value<0.05) {
  # Korelasyon katsayısı 0'dan farklı
  # Acaba sıfırdan büyük mü?
  t = cor.test(x,y,method = "spearman", alternative = "g")
  if(t$p.value<0.05) {
    # Evet Büyük
    cat("Korelasyon katsayısı 0'dan büyüktür r=",
        t$estimate," p=",t$p.value,"\n")
  } else {
    # Hayır Küçük
    cat("Korelasyon katsayısı 0'dan küçüktür r=",
        t$estimate," p=",1-t$p.value,"\n")
  }
} else {
  # Korelasyon katsayısı 0'dan farklı değil!
  cat("Korelasyon katsayısı 0'dır r=",
      t$estimate," p=", t$p.value,"\n")
}

```

```
## Korelasyon katsayısı 0'dan büyüktür r= 0.9461624  p= 0
```

```

y = -2*x+runif(30)

t = cor.test(x,y,method = "spearman")

if(t$p.value<0.05) {
  # Korelasyon katsayısı 0'dan farklı
  # Acaba sıfırdan büyük mü?
  t = cor.test(x,y,method = "spearman", alternative = "g")
  if(t$p.value<0.05) {
    # Evet Büyük
    cat("Korelasyon katsayısı 0'dan büyüktür r=",
        t$estimate," p=",t$p.value,"\n")
  } else {
    # Hayır Küçük
    cat("Korelasyon katsayısı 0'dan küçüktür r=",
        t$estimate," p=",1-t$p.value,"\n")
  }
}

```

```

} else {
  # Korelasyon katsayısı 0'dan farklı değil!
  cat("Korelasyon katsayısı 0'dır r=",
      t$estimate, " p=", t$p.value, "\n")
}

```

```
## Korelasyon katsayısı 0'dan küçüktür r= -0.9657397 p= 0
```

```

y = rnorm(30)

t = cor.test(x,y,method = "spearman")

if(t$p.value<0.05) {
  # Korelasyon katsayısı 0'dan farklı
  # Acaba sıfırdan büyük mü?
  t = cor.test(x,y,method = "spearman", alternative = "g")
  if(t$p.value<0.05) {
    # Evet Büyük
    cat("Korelasyon katsayısı 0'dan büyüktür r=",
        t$estimate, " p=", t$p.value, "\n")
  } else {
    # Hayır Küçük
    cat("Korelasyon katsayısı 0'dan küçüktür r=",
        t$estimate, " p=", 1-t$p.value, "\n")
  }
} else {
  # Korelasyon katsayısı 0'dan farklı değil!
  cat("Korelasyon katsayısı 0'dır r=",
      t$estimate, " p=", t$p.value, "\n")
}

```

```
## Korelasyon katsayısı 0'dır r= 0.1470523 p= 0.4364424
```

Şimdide spearman korelasyon değerleri için korelogram grafiği oluşturalım.

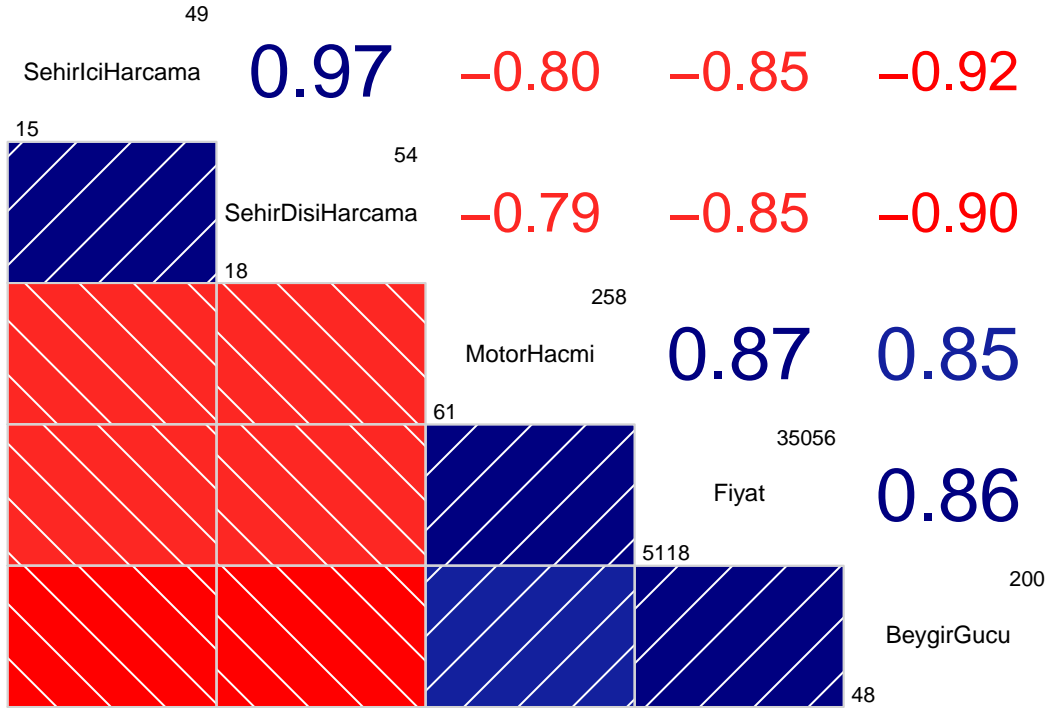
```

library(corrgram)

corrgram(sVeri, order = TRUE, lower.panel = panel.shade,
         upper.panel = panel.cor, diag.panel = panel.minmax,
         main = "Spearman Korelogram", cor.method = "spearman")

```

Spearman Korelogram



11.2 Regresyon Analizi

Korelasyon katsayısı iki değişkenin değişimlerinin birbirleri ile etkileşimi hakkında bilgi verir, fakat aralarındaki ilişkinin matematiksel yapısı hakkında bilgi vermez. Regresyon analizinde ise iki değişken arasındaki ilişki matematiksel bir formül veya *model* aracılığı ile açıklanmaya çalışılır. Bu denklemin yapısı basit doğrusal bir yapıda olabileceği gibi doğrusal olmayan bir yapıda da olabilir. Doğrusal yapıya sahip regresyon modeline *Doğrusal Regresyon*, doğrusal yapıya sahip olmayan regresyon modeline de *Doğrusal Olmayan Regresyon* adı verilir.

11.2.1 Basit Doğrusal Regresyon

Bir adet bağımlı değişken ve bir adet bağımsız değişkenden oluşan regresyon modeline **Basit Doğrusal Regresyon** modeli denir. Bu model aşağıdaki şekilde ifade edilir.

$$Y_i = \beta_0 + \beta_1 X_i$$

Bu modelde, X değişkeninin alabileceği bütün değerler için bir Y değeri bulunabilir ve bu değerlerde aynı doğru üzerindedir. Uygulamada bu şekilde bir model ortaya çıkması mümkün değildir. Bu sebeple yukarıdaki modele bir hata terimi eklenir ve aşağıdaki hale gelir.

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i$$

Bu ifade regresyon modeli olarak adlandırılır. Burada, Y_i değişkenine bağımlı veya etkilenen, X_i değişkenine de bağımsız veya etkileyen değişken adı verilir. Burada yer alan regresyon modeli anakütle için kullanılacak olan regresyon modelidir. Örneklemden hesaplanan regresyon modeli ise aşağıdaki şekilde hesaplanır.

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i + e_i$$

Burada $\hat{\beta}_i$, β_i nin e_i ise ϵ_i için kullanılan tahmin edicilerdir. Bu tahmin edicilerin hesaplanması aşağıdaki şekilde gerçekleştirilir.

$$\begin{aligned} \sum_{i=1}^n Y_i &= n\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^n X_i \\ \sum_{i=1}^n X_i Y_i &= \hat{\beta}_0 \sum_{i=1}^n X_i + \hat{\beta}_1 \sum_{i=1}^n X_i^2 \end{aligned}$$

Bu denklemlerden $\hat{\beta}_0$ çekilip yerine yazılırsa $\hat{\beta}_1$;

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n X_i Y_i - n\bar{X}\bar{Y}}{\sum_{i=1}^n X_i^2 - n\bar{X}^2}$$

olarak ve β_0 'da,

$$\hat{\beta}_0 = \bar{Y} - \beta_1 \bar{X}$$

şeklinde hesaplanır.

R ile basit doğrusal regresyon modeli *lm* fonksiyonu ile oluşturulur. Korelasyon için oluşturduğumuz örnek sanal değişkenlerin regresyon modeli ile test edelim.

```
set.seed(127)

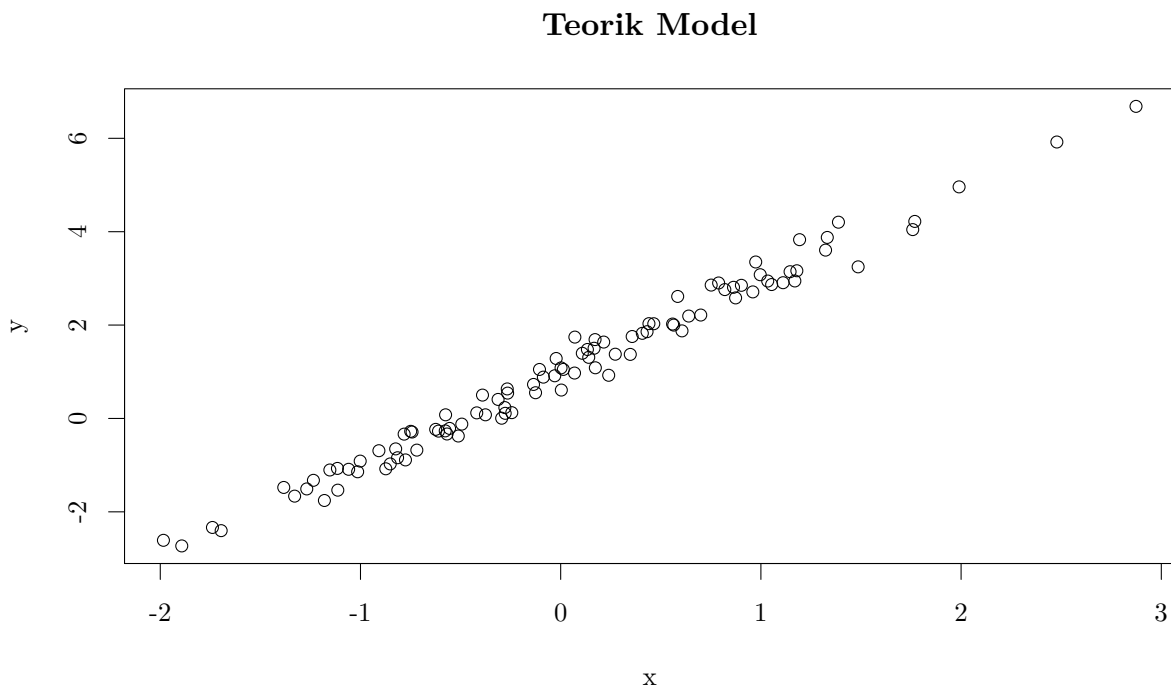
# Bağımsız Değişkeni Oluşturalım
x = rnorm(100)
# Bağımsız değişkeni sıralayalım
x = sort(x)

# Rastgele Hata Değişkenimizi Oluşturalım
```

```
e = rnorm(100, mean = 0, sd = 0.25)

B0 = 1
B1 = 2
# Teorik modeli oluřturalım B0=1 B1=2
y = B0 + B1*x + e

# Saęılım Grafięine Bakalım
plot(x,y,main="Teorik Model")
```



```
# Regresyon Modelini oluřturalım
regresyon.modeli = lm(y~x)

# Regresyon modelinden hesaplanan katsayıları öğrenelim
katsayilar = coefficients(regresyon.modeli)

print(katsayilar)
```


```
## (Intercept)          x
##  0.9776659    1.9731948
```

```
# Tahmin edilen katsayıları deęiřkenlere aktaralım
B0Sapka = katsayilar[1]
B1Sapka = katsayilar[2]
```

```
# Tahmin modelini çalıştıralım
ySapka = B0Sapka+B1Sapka*x

# Tahmin modeli ile Teorik modeli grafiksel olarak inceleyelim
plot(x,y,main="Tahmin Modeli ile Teorik Model Arasındaki İlişki")
lines(x,ySapka,col="red")
```

Tahmin Modeli ile Teorik Model Arasındaki İlişki



Örnekten de gördüğünüz gibi doğrusal regresyon modelimizden elde edilen parametre tahmin edicileri, teorik modelde kullandığımız parametreler ile benzerlik göstermektedir.

11.2.2 Belirlilik Katsayısı

Regresyon modeli bağımlı değişkende oluşan değişimin bir kısmını açıklar, geri kalan kısmı ise açıklanamaz. Aşağıda bu değişimlerin matematiksel ifadeleri yer almaktadır.

$$TD = \sum_{i=1}^n (Y_i - \bar{Y})^2$$

$$AD = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2$$

$$AD_1 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2$$

Burada, TD toplam değişim miktarını, AD açıklanan değişim miktarını ve AD_1 'de açıklanamayan değişim miktarını göstermektedir. Belirlilik katsayısı, açıklanan değişim miktarının toplam değişim miktarına oranlanması ile bulunur. $0 \leq R^2 \leq 1$ dir. Formülü aşağıdaki gibidir.

$$R^2 = \frac{AD}{TD} = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2}$$

R^2 değeri regresyon modelinin açıklayıcılığının ölçüsüdür.

R ile oluşturduğunuz modellerde belirleyicilik katsayısı otomatik olarak hesaplanır. Bir önceki başlıkta oluşturduğumuz model için belirleyicilik katsayısını bulan R kodu aşağıda verilmiştir.

```
model.ozeti = summary(regresyon.modeli)

r2 = model.ozeti$r.squared

print(r2)

## [1] 0.7166659
```

11.2.3 Katsayıların Testi

Regresyon modelinde hesaplanan katsayıların (β_0 ve β_1) istatistiksel olarak anlamlı olup olmadığını ölçmek gereklidir. Bu amaçla oluşturacağınız hipotez aşağıdaki gibidir.

$$H_0 : \beta_i = 0$$

$$H_1 : \beta_i \neq 0$$

R, model özetinde size hesapladığı katsayılar için gerekli test istatistiğini ve p değerini hesaplar. Aşağıdaki R kodunu inceleyin.

```
print(model.ozeti$coefficients)

##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept) 1.155797   0.2086572  5.539214 6.367339e-06
## x           2.071917   0.2461979  8.415656 3.744993e-09
```

Bu tabloda $Pr(>|t|)$ sütunu kullanacağınız p değerlerini gösterir. Burada $\hat{\beta}_0$ (*Intercept*) olarak, $\hat{\beta}_1$ de x ile ifade edilmektedir.

11.2.4 Regresyon Modeli ile Tahmin

Regresyon modelinizi oluşturduktan sonra bilinmeyen bir x değeri için y değerini tahmin etmeye çalışalım. Aşağıdaki R kodunu inceleyiniz.

```
# Bilinmeyen bir x değeri alalım
bilinmeyen.x = 35

# Modelimizi çalıştıralım
tahmin.y = B0Sapka+B1Sapka*bilinmeyen.x

# Tahmin Edilen Y Değeri
print(tahmin.y)
```

```
## (Intercept)
##      73.67288
```

11.2.5 Gerçek Veri ile Uygulama

Dersin sitesinden TÜFE verisini indirin. Bu veride, yıllara göre tüketici fiyat endeksine göre hesaplanan enflasyon değerleri ve nüfus bilgisi bulunmaktadır. Yıllara göre nüfus için bir regresyon modeli oluşturup, 2016, 2017 ve 2018 için nüfusumuzu tahmin etmeye çalışalım. Aşağıdaki R kodlarını çalıştırın.

```
tufe.veri = read.csv2("TUFE.csv")

nufus.model = lm(NUFUS~YIL, data=tufe.veri)

katsayilar = coefficients(nufus.model)

B0Sapka = katsayilar[1]
B1Sapka = katsayilar[2]

nufus.ozet = summary(nufus.model)

r2 = nufus.ozet$r.squared

print(r2)
```

```
## [1] 0.9985873
```


```
print(nufus.ozet$coefficients)
```

```
##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept) -1805989694.9 9508066.363 -189.9429 5.565373e-78
## YIL          934619.8    4783.775  195.3729 1.217343e-78
```

```
nufusSapka = B0Sapka+B1Sapka*tufe.veri$YIL

# Tahmin modeli ile Teorik modeli grafiksel olarak inceleyelim
plot(tufe.veri$YIL,tufe.veri$NUFUS,
     main="Tahmin Modeli ile Teorik Model Arasındaki İlişki")
lines(tufe.veri$YIL,nufusSapka,col="red")
```

Tahmin Modeli ile Teorik Model Arasındaki İlişki



```
# Tahmin için gerekli değerleri oluşturalım

yillar = c(2016, 2017, 2018)

nufus.tahmin = B0Sapka+B1Sapka*yillar

print(nufus.tahmin)
```

```
## [1] 78203788 79138408 80073028
```

Gördüğünüz üzere modelimiz 2016, 2017 ve 2018 yılları için nüfusumuzu sırasıyla 78.203.788, 79.138.408 ve 80.073.028 olarak tahmin etmiştir.

11.2.6 Doğrusal Olmayan Modeller

Bu modeller gerçekte doğrusal olan ve gerçekte doğrusal olmayan modeller olmak üzere ikiye ayrılırlar. Gerçekte doğrusal olan modeller, değişken dönüşümleri yardımıyla doğrusallaştırılabilen modellerdir. Bu bölümde sadece bu modellerden bahsedilecektir.

11.2.6.1 Kareli Model

Değişkenlerin saçılım grafiği incelendiğinde tek maksimum veya tek minimum yapması durumunda kareli model doğrusal modelden daha fazla açıklayıcılığa sahip olabilir. Bu durumda teorik model aşağıdaki gibi olur.

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \epsilon_i$$

Bu durumu R ile inceleyelim.

```
set.seed(127)

# Bağımsız değişkenimizi oluşturalım.
x = rnorm(100)
# Bağımsız değişkeni sıralayalım
x = sort(x)


# Kare değişkenimizi oluşturalım
x2 = x * x

# Hata oranımızı oluşturalım
e = rnorm(100, mean = 0, sd = 0.25)

# Model parametrelerini oluşturalım
B0 = 5
B1 = 3
B2 = 4

# Modeli kurup y değişkenimizi oluşturalım
y = B0+B1*x+B2*x2+e

# Saçılım Grafiğine bakalım
plot(x,y)
```



```
# Regresyon modelimizi oluřturalım
polinom.model = lm(y~x+x2)

# Regresyon Modeli Katsayılarına Bakalım
katsayilar = coefficients(polinom.model)

print(katsayilar)
```

```
## (Intercept)          x          x2
##    4.975865    2.972448    4.002021
```

```
# Belirleyicilik Katsayısını Bulalım
polinom.ozet = summary(polinom.model)

r2 = polinom.ozet$r.squared

print(r2)
```

```
## [1] 0.998577
```


```
# Katsayıların anlamlılığını ölçelim
print(polinom.ozet$coefficients)
```

```
##           Estimate Std. Error  t value      Pr(>|t|)
## (Intercept) 4.975865 0.03076840 161.7200 8.681556e-120
## x           2.972448 0.02728135 108.9553 3.041549e-103
## x2          4.002021 0.02019247 198.1937 2.492997e-128
```

```
# Tahmin Modelini Çalıştıralım
ySapka = katsayilar[1]+katsayilar[2]*x+katsayilar[3]*x2
```

```
# Teorik model ile regresyon modelinin karşılařtırılma
plot(x, y, main = "Teorik Model ile\nRegresyon Modelinin Karşılařtırması")
lines(x, ySapka, col="red")
```


Teorik Model ile Regresyon Modelinin Karşılaştırması



Gördüğünüz üzere regresyon modeli teorik modele yakın ve istatistiksel olarak anlamlı sonuçlar verdi. Bir önceki verimizde yer alan TÜFE verilerini incerseniz de kareli regresyonun doğrusal regresyondan daha uygun bir açıklayıcılığa sahip olacağını görürsünüz. Şimdi elimizdeki verileri kullanıp gelecek 3 yıl için TÜFE değerlerini tahmin etmeye çalışalım.

```
tufe.veri = read.csv2("TÜFE.csv")
```

```
plot(tufe.veri$YIL, tufe.veri$TÜFE)
```



```
tufe.veri$YIL2 = tufe.veri$YIL*tufe.veri$YIL

tufe.model = lm(TUFE~YIL+YIL2, data=tufe.veri)

katsayilar = coefficients(tufe.model)

B0Sapka = katsayilar[1]
B1Sapka = katsayilar[2]
B2Sapka = katsayilar[3]

tufe.ozet = summary(tufe.model)

r2 = tufe.ozet$r.squared

print(r2)
```

```
## [1] 0.5837935
```


```
print(tufe.ozet$coefficients)
```

```
##              Estimate  Std. Error  t value    Pr(>|t|)
## (Intercept) -3.770924e+05 4.511567e+04 -8.358346 3.008068e-11
## YIL          3.791632e+02 4.540152e+01  8.351334 3.086142e-11
## YIL2         -9.529671e-02 1.142169e-02 -8.343486 3.175948e-11
```

```
tufeSapka = B0Sapka+B1Sapka*tufe.veri$YIL+B2Sapka*tufe.veri$YIL2

# Tahmin modeli ile Teorik modeli grafiksel olarak inceleyelim
plot(tufe.veri$YIL,tufe.veri$TUFE,
     main="Tahmin Modeli ile Teorik Model Arasındaki İlişki")
lines(tufe.veri$YIL,tufeSapka,col="red")
```

Tahmin Modeli ile Teorik Model Arasındaki İli



Tahmin için gerekli değerleri oluşturalım

```
yillar = c(2016, 2017, 2018)
yillar2 = yillar*yillar

tufe.tahmin = B0Sapka+B1Sapka*yillar+B2Sapka*yillar2

print(tufe.tahmin)
```

```
## [1] -9.487104 -14.655488 -20.014465
```

Modelimizin tahminlerine göre önümüzdeki üç yıl TÜFE endeksi negatif olacak :).

11.2.6.2 Tam Logaritmik Model

Bu modelin teorik yapısı aşağıdaki gibidir.

$$Y_i = \beta_0 X_i^{\beta_1} e^{e_i}$$

Teorik modelin her iki tarafının logaritması alınırsa, model aşağıdaki hale gelecektir.

$$\ln Y_i = \ln \beta_0 + \beta_1 \ln X_i + e_i$$

Bu modeli R ile inceleyelim.


```
set.seed(127)


# Bağımsız değişkenimizi oluşturalım.
x = rnorm(100, mean = 10, sd=2)
# Bağımsız değişkeni sıralayalım
x = sort(x)

# Hata oranımızı oluşturalım
e = rnorm(100, mean = 0, sd = 0.25)

# Model parametrelerini oluşturalım
B0 = 5
B1 = 3

# Modeli kurup y değişkenimizi oluşturalım
y = B0*(x^B1)*exp(e)

# Saçılım Grafiğine bakalım
plot(x,y)
```



```
# Regresyon modelimizi oluşturalım
log.model = lm(log(y)~log(x))

# Regresyon Modeli Katsayılarına Bakalım
katsayilar = coefficients(log.model)

print(katsayilar)
```

```
## (Intercept)      log(x)
##      1.902981      2.861748
```

```
# Belirleyicilik Katsayısını Bulalım
```

```
log.ozet = summary(log.model)
```

```
r2 = log.ozet$r.squared
```

```
print(r2)
```

```
## [1] 0.8320554
```

```
# Katsayıların anlamlılığını ölçelim
```

```
print(log.ozet$coefficients)
```

```
##              Estimate Std. Error   t value    Pr(>|t|)
## (Intercept)  1.902981   0.2987114   6.370633 6.136969e-09
## log(x)       2.861748   0.1298749  22.034652 9.492986e-40
```


```
# Tahmin Modelini Çalıştıralım
```

```
ySapka = exp(katsayilar[1])*x^katsayilar[2]
```

```
# Teorik model ile regresyon modelinin karşılaştıralım
```

```
plot(x, y, main = "Teorik Model ile\nRegresyon Modelinin Karşılaştırması")
```

```
lines(x, ySapka, col="red")
```



11.2.6.3 Doğrusal Logaritmik Model

Bu modelin teorik yapısı aşağıdaki gibidir.

$$Y_i = \beta_0 + \beta_1 \ln X_i + e_i$$

Bu modeli R ile inceleyelim.

```
set.seed(127)


# Bağımsız değişkenimizi oluşturalım.
x = rnorm(100, mean = 10, sd=2)
# Bağımsız değişkeni sıralayalım
x = sort(x)

# Hata oranımızı oluşturalım
e = rnorm(100, mean = 0, sd = 0.25)

# Model parametrelerini oluşturalım
B0 = 5
B1 = 3

# Modeli kurup y değişkenimizi oluşturalım
y = B0+B1*log(x)+e

# Saçılım Grafiğine bakalım
plot(x,y)
```



```
# Regresyon modelimizi oluşturalım
log.model = lm(y~log(x))

# Regresyon Modeli Katsayılarına Bakalım
katsayilar = coefficients(log.model)

print(katsayilar)
```

```
## (Intercept)      log(x)
##      5.293543      2.861748
```

```
# Belirleyicilik Katsayısını Bulalım
log.ozet = summary(log.model)

r2 = log.ozet$r.squared

print(r2)
```


```
## [1] 0.8320554
```

```
# Katsayıların anlamlılığını ölçelim
print(log.ozet$coefficients)
```

```
##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept)  5.293543   0.2987114 17.72126 2.516169e-32
## log(x)       2.861748   0.1298749 22.03465 9.492986e-40
```

```
# Tahmin Modelini Çalıştıralım
ySapka = katsayilar[1]+katsayilar[2]*log(x)

# Teorik model ile regresyon modelinin karşılaştırılma
plot(x, y, main = "Teorik Model ile\nRegresyon Modelinin Karşılaştırması")
lines(x, ySapka, col="red")
```



11.2.6.4 Logaritmik Doğrusal Model

Bu modelin teorik yapısı aşağıdaki gibidir.

$$Y_i = e^{\beta_0 + \beta_1 X_i + e_i}$$

Teorik modelin her iki tarafının logaritması alınırsa model aşağıdaki şekle dönüşecektir.

$$\ln Y_i = \beta_0 + \beta_1 X_i + e_i$$

Bu modeli R ile inceleyelim.

```
set.seed(127)


# Bağımsız değişkenimizi oluşturalım.
x = rnorm(100)
# Bağımsız değişkeni sıralayalım
x = sort(x)

# Hata oranımızı oluşturalım
e = rnorm(100, mean = 0, sd = 0.25)

# Model parametrelerini oluşturalım
B0 = 0.5
B1 = 1
```

```
# Modeli kurup y değişkenimizi oluşturalım  
y = exp(B0+B1*x+e)
```

```
# Saçılım Grafiğine bakalım  
plot(x,y)
```



```
# Regresyon modelimizi oluşturalım  
log.model = lm(log(y)~x)
```

```
# Regresyon Modeli Katsayılarına Bakalım  
katsayilar = coefficients(log.model)
```

```
print(katsayilar)
```

```
## (Intercept)          x  
##  0.4776659    0.9731948
```

```
# Belirleyicilik Katsayısını Bulalım  
log.ozet = summary(log.model)
```

```
r2 = log.ozet$r.squared
```

```
print(r2)
```


```
## [1] 0.934121
```

```
# Katsayıların anlamlılığını ölçelim
print(log.ozet$coefficients)
```

```
##              Estimate Std. Error  t value    Pr(>|t|)
## (Intercept) 0.4776659 0.02483380 19.23451 4.838042e-35
## x            0.9731948 0.02610711 37.27700 1.092270e-59
```

```
# Tahmin Modelini Çalıştıralım
ySapka = exp(katsayilar[1]+katsayilar[2]*x)

# Teorik model ile regresyon modelinin karşılaştıralım
plot(x, y, main = "Teorik Model ile\nRegresyon Modelinin Karşılaştırması")
lines(x, ySapka, col="red")
```



11.2.6.5 Ters Model

Bu modelin teorik yapısı aşağıdaki gibidir.

$$Y_i = \beta_0 + \beta_1 \frac{1}{X_i} + e_i$$

Bu modeli R ile inceleyelim.

```
set.seed(127)


# Bağımsız değişkenimizi oluşturalım.
x = rnorm(100, mean = 10, sd = 1)
# Bağımsız değişkeni sıralayalım
x = sort(x)

# Hata oranımızı oluşturalım
e = rnorm(100, mean = 0, sd = 0.01)

# Model parametrelerini oluşturalım
B0 = 5
B1 = 3

# Modeli kurup y değişkenimizi oluşturalım
y = B0+B1*(1/x)+e

# Saçılım Grafiğine bakalım
plot(x,y)
```



```
# Dönüşüm Değişkeni oluşturalım
invX = 1/x;

# Regresyon modelimizi oluşturalım
ters.model = lm(y~invX)

# Regresyon Modeli Katsayılarına Bakalım
katsayilar = coefficients(ters.model)
```



```
print(katsayilar)
```

```
## (Intercept)      invX  
##      4.987958      3.110511
```

```
# Belirleyicilik Katsayısını Bulalım
```

```
ters.ozet = summary(ters.model)
```

```
r2 = ters.ozet$r.squared
```

```
print(r2)
```

```
## [1] 0.8998785
```

```
# Katsayıların anlamlılığını ölçelim
```

```
print(ters.ozet$coefficients)
```

```
##              Estimate Std. Error  t value      Pr(>|t|)  
## (Intercept) 4.987958 0.01058146 471.38674 2.985563e-166  
## invX        3.110511 0.10480706  29.67845 8.984535e-51
```

```
# Tahmin Modelini Çalıştıralım
```

```
ySapka = katsayilar[1]+katsayilar[2]*(1/x)
```

```
# Teorik model ile regresyon modelinin karşılaştıralım
```

```
plot(x, y, main = "Teorik Model ile\nRegresyon Modelinin Karşılaştırması")  
lines(x, ySapka, col="red")
```

**Teorik Model ile
Regresyon Modelinin Karşılaştırması**

